

泛工业场景中机器人操作方案设计与落地

Design and Implementation of Robotic Manipulation Solutions in General Industrial Scenarios

何泳浩 博士

地瓜机器人-具身智能负责人



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

具身的战略聚焦

➤ **1**

具身智能的两大应用场景

具身智能技术的应用场景主要可以划分为两大领域：一是面向日常生活的服务场景，如家庭服务、医疗护理等（To C）；二是面向生产制造的泛工业场景，涵盖仓储物流、装配智造等（To B）

➤ **2**

首要任务：解放泛工业场景生产力

在我们看来，具身智能技术当前最核心、最紧迫的任务，是聚焦并解放泛工业场景中被束缚的生产力。这是目前具身智能的当务之急，应对未来的人口老龄化危机，更是核心价值的重要体现

➤ **3**

坚定的战略选择

坚定地瞄准泛工业场景，解放生产力。我们致力于构建一套从硬件选型、算法优化到数据采集的完整解决方案，以应对泛工业场景的复杂性和多样性。

目录

01 问题定义

02 硬件方案

03 算法方案

04 数采方案

01 问题定义

更加深刻理解场景和任务

泛工业场景介绍



泛工业场景并非完全的无结构环境，其布局 and 任务流程往往具有一定的规律性和重复性，存在一定的动态变化和不确定性。这种“半结构化”的特性使得我们可以相对容易切入和进行方案设计。

半结构化，复杂度可控



许多泛工业场景，如铸造车间、矿山、化工环境等，普遍存在高温、高湿、高噪音、粉尘、有毒气体等恶劣条件。这些环境对人类工人的身心健康构成威胁，而机器人则可以在这些环境中稳定、持续地工作。

声/光/气污染，条件恶劣



泛工业场景中大量存在着搬运、装卸、装配等重体力劳动，这些工作不仅效率低下，而且容易导致工人受伤。引入机器人可以有效替代人类完成这些繁重的体力工作，将工人从重复性的体力劳动中解放出来。

重体力劳动

泛工业场景中的任务分类

操作任务的精度要求

厘米级，毫米级，亚毫米级

操作对象的物理可预测性

刚体，铰接刚体，柔体，软体，流体等



任务感知复杂度

视觉，力觉，触觉

任务执行效率要求

分钟级，秒级，毫秒级

维度划分

典型任务——物流仓储中的箱体码垛与搬运

1 物理可预测性

刚体，形状相对固定

2 精度要求

厘米级，容错误差大



3 感知复杂度

视觉为主，无需力、触觉

4 执行效率

秒级为主，吞吐量适中

典型任务——零部件装配与螺丝拧紧

1 物理可预测性

刚体，或者铰接刚体

2 精度要求

毫米级



3 感知复杂度

视觉与力觉

4 执行效率

秒级到分钟级

典型任务——精密装配与线缆插接

1


物理可预测性

刚体，但是元件小

2

精度要求

亚毫米级



3

感知复杂度

视觉，力觉和触觉

4

执行效率

秒级，如果是流水线，可能要求吞吐量较高


具身智能方案 vs 工业自动化

更好的场景适应性

- 对结构化的依赖降低
- 跨任务的泛化能力
- 动态异常处理和自主纠错

更优的成本边际效应

- 标准硬件本体结构
- 软件定义
- RaaS (Robot as a Service)



为什么更需要具身智能方案
ROI

任务难度分级框架



当前关注的任务类型



02 硬件选型

各种硬件本体与场景的适应性

● 硬件本体——移动底盘

轮式




足式



轮足



履带式



速度

快

慢

快

中等

越障

低

高

高

中等

效能

高

低

中等

中等

控制难度

低

高

高

中等

典型场景

室内物流/送餐/巡检


复杂地形/抢险

—

户外探索/军事/农业

● 硬件本体——上半身(躯干)

外部垂直导轨



集成伸缩柱



折叠式



机械刚性

高

中

低

运动灵活

低

中

高

环境密封

差

优

中

空间占用

大

中

变动

● 硬件本体——上半身(臂)

工业协作臂



仿生机械臂



核心特点	追求安全和高协作性	追求仿生结构，自由灵活
性能优势	运动稳定丝滑，重复精度高	柔顺，更易遥操
局限性	可达空间受限，体积和重量较大	控制相对复杂，承重较弱，稳定性可能欠佳

● 硬件本体——上半身(末端执行器)

	2指(夹爪)	3指	4指	5指(仿生灵巧手)
核心特点	平行或角度开合	三点围合，常呈120°布局	冗余设计，多为2对2或3+1布局	仿生人手结构
性能优势	结构最简单、成本低、可靠性极高、控制逻辑成熟	具备自对中能力，抓取球形物体极其稳定，性价比高	接触面积大，对大型，柔软物体的压力分布更均匀，稳定性极佳	灵巧度最高，完全适配人类设计的工具，具有极强的普适性
局限性	灵巧度极低，难以处理球形或不规则物体，无法实现“手内操作”	复杂度高于2指，在狭窄空间内的适应性略逊于精细灵巧手低	处于3指与5指的中间态，商业化成熟度略低于工业级3指	结构最复杂、驱动电机数量多、成本最高、算法控制难度极大
典型应用	工业搬运/结构化零件抓取	高实验室研究/圆筒类容器抓取	柔软包装、大型易碎品搬运	高端人形机器人/精细服务场景

目前，执行末端集成了最丰富的多模态感知能力：视觉，力觉，触觉

硬件本体——传感器

	双目深度相机	结构光深度相机	iToF深度相机	面阵dToF相机	激光雷达LiDAR
					
测距原理	双目视觉(被动三角法)	结构光(编码图案+三角法)	iToF(间接飞行时间·测相位)	dToF(直接飞行时间·测脉冲)	dToF + 扫描机构
室内适配性	中	高	高	高	高
室外适配性	高	极低	低	中	极高(抗雨雾/强光)
测距范围	0.3~20m	0.05~5m	0.1~10m	0.3~20m	0.5~200m+
成本等级	低	中	中低	中	高
适用场景	室外机器人/自动驾驶视觉	工业精密检测/机械臂抓取	体感交互/扫地机器人	室内建模/近距离机器人避障	自动驾驶/工业测绘

03 算法方案

高潜的方案路径

为什么VA比VLA更适配泛工业场景

VLA (Vision-Language-Action Model) vs VA (Vision-Action Model)

- 语言模态的价值在泛工业场景的价值几乎没有。相对标准化的流程，可拆分，任务执行推进完全无需语言，程序化流程即可。语言的最核心的价值在于提供人机交互的媒介，更适合通用场景。
- 语言模态的加入，势必引入Language Encoder或者完整的VLM (Vision-Language Models)，会使得模型变得庞大，导致推理效率很低。
- 在引入VLM的前提下，需要训练的数据量也会增多，可能还需要大规模的预训练。当前的数据形式对于语言的利用也是极其低效的。

- VLA更像是一个纯学术研究方向，应该以探索人机交互的有效性为重点
 - VA更多是直面控制问题，解决在观测引导下的合理轨迹动作生成

我们要以目标为导向去构建方案，不需要提前“站队”属于哪个路线，现在不存在一条清晰的路径

高潜的VA模型技术路线

阶段1

感知模态:
视觉 (单目第三视角)

时序:
单帧静态

动作预测:
CNN + DDPM

阶段2

感知模态:
视觉 (多目第三视角, 腕部视角等等)

时序:
单帧静态

动作预测:
DiT+FlowMatching

阶段3

感知模态:
视觉 (多目第三视角, 腕部视角等等)
力觉 (关节力矩, 腕部六维力)
触觉 (末端执行器指端)

时序:
单帧静态

动作预测:
DiT+FlowMatching

阶段4

感知模态:
视觉 (多目第三视角, 腕部视角等等)
力觉 (关节力矩, 腕部六维力)
触觉 (末端执行器指端)

时序:
Transformer Fuser with KV cache

动作预测:
DiT+FlowMatching


世界模型：一种自监督（即预测未来状态）的多模态表示学习框架

主要价值在于预训练阶段，让多模态特征能够在隐空间中进行对齐

高潜的VA模型技术路线——阶段1

VO-DP (Vision-Only Diffusion Policy) ——单目VA方案

- 纯视觉方案性能超过RGB-D方案\泛化性和鲁棒性超过当前的VLA
- 3D-Aware预训练可明显提升任务的成功率



高潜力的VA模型技术路线——阶段1

VO-DP: 单目VA方案

TABLE II: RoboTwin Benchmark Results. DP: Diffusion policy[9], DP3: 3D diffusion policy[1], VO-DP: $T = 3$, VO-DP-1: $T = 1$

Method	Block Hammer Beat	Block Handover	Bottle Adjust	Container Place	Empty Cup Place
DP	0.7±0.9	77.7±4.5	39.3±0.5	14.0±6.9	69.3±2.5
DP3	79.3±1.2	97.7±1.2	85.3±0.5	83.7±1.7	88.7±1.7
VO-DP	85.0±1.4	89.7±0.5	63.3±1.2	43.0±3.7	82.0±2.2
VO-DP-1	78.7±5.2	94.7±0.5	69.3±2.5	31.3±2.6	77.3±1.7

Method	Pick Apple Messy	Put Apple Cabinet	Dual Bottles Pick (Easy)	Dual Bottle Pick (Hard)	Diverse Bottles Pick
DP	31.0±0.8	63.6±1.9	73.7±1.2	63.3±0.5	7.3±1.2
DP3	18.7±2.9	84.7±0.5	83.3±0.5	64.0±0.8	60.7±0.5
VO-DP	80.0±0.8	94.3±2.3	88.3±0.9	67.3±3.3	32.3±3.3
VO-DP-1	81.7±0.9	98.0±0.8	86.3±0.5	60.3±1.2	31.3±1.7

Method	Shoe Place	Dual Shoes Place	Tool Adjust	Blocks Stack (Easy)	AVG. (↑)
DP	19.3±1.2	4.7±0.5	20.0±2.9	3.7±1.2	34.8
DP3	56.3±1.7	13.7±1.7	58.3±0.5	22.0±2.2	64.0
VO-DP	43.0±0.8	17.0±0.8	58.3±3.9	52.3±2.5	63.9
VO-DP-1	52.0±0.8	19.3±0.9	55.3±2.6	69.3±2.5	64.6

仿真实验




TABLE V: Real-world Performance. In the four real-world tasks, it can be observed that VO-DP significantly outperforms the other two methods.

Method	PPSC	PPBC	CC	SC	AVG. (↑)
DP	23.3	16.7	3.3	1.7	11.2±9.1
DP3	73.3	68.3	75.0	53.3	67.5±8.5
VO-DP-1	96.7	91.7	93.3	70.0	87.9±10.5

真机实验

高潜力的VA模型技术路线——阶段1

VO-DP: 单目VA方案




TABLE VII: Appearance Robustness. Train: ■ cubes; Test: ■, ■, ■, ■ cubes.

■	■	■	■	AVG.
85.0	50.0	40.0	90.0	66.3±21.6




TABLE IX: Background Robustness. Train: desktop surface; Test: desktop surface, ■, ■ and ■ surface.

desktop surface	■	■	■	AVG.
85.0	90.0	80.0	95.0	87.5±5.6



TABLE VI: Size Robustness. Train: 3.0 cm cubes; Test: 2.5 cm, 3.0 cm and 5 cm cubes.

3.0 cm	2.5 cm	5.0 cm	AVG.
85.0	60.0	50.0	65.0±14.7





TABLE VIII: Illumination Robustness. Train: Normal; Test: Normal, Light Switch, Blinking.

Normal	Light Switch	Blinking	AVG.
85.0	80.0	85.0	83.3±2.4


鲁棒性实验



高潜力的VA模型技术路线——阶段2

VO-DP+ (Vision-Only Diffusion Policy) ——多视角VA方案

- 从单一第三视角，提升为多视角，可以多个第三视角或者腕部视角；视觉编码器优化
- 使用 DiT+FlowMatching 的Policy Head，便于融合多视角特征



高潜力的VA模型技术路线——阶段2


VO-DP+ (Vision-Only Diffusion Policy) ——多视角VA方案

Policy Head	observation	Encoder	Param	Adjust Bottle(%)	Beat Block Hammer(%)	Click Alarmclock(%)	Click Bell(%)
CFM	single-view	VGGT	1B	99	88	55	79
	multi-view	DINOv3 DiT (ViT-H+)	840M	99	94	72	92
		DINOv3 DiT (ViT-L)	300M	99	94	59	87
		DINOv3 DiT (ViT-B)	86M	99	96	68	100
		DINOv3 CNN (CNN-L)	198M	100	93	68	92

高潜力的VA模型技术路线——阶段3

MMA (Multi-Modal Action Model) ——多模态动作模型

- 多视角视觉感知
- 力觉和触觉






高潜力的VA模型技术路线——阶段4


Context-aware MMA (Multi-Modal Action Model) ——长上下文的多模态动作模型

- 多视角视觉感知
- 力觉和触觉
- 长上下文支持



高潜力的VA模型技术路线——世界模型的预训练

世界模型下的预训练框架



03 数采方案

多种数采方案的优劣和具体实现



操作数据的格式介绍

一图读懂操作数据格式，以单个Episode为例。

多模态数据定义

语言与任务 (Language)

描述: 全局指令或单步任务语义

示例: "将红色的方块放入蓝色的碗中"

视觉帧 (Vision)

频率: ~10Hz - 30Hz (低频基准)

包含: 多视角 RGB 图像流

动作与本体 (Action)

频率: ~50Hz - 500Hz (中高频)

包含: 关节角、速度、末端 6D 位姿

触觉 (Tactile)

频率: ~50Hz - 100Hz (中频)


包含: 夹爪指尖阵列或视触觉传感器数据

力觉 (Force)

频率: ~1000Hz+ (极高频连续流)

包含: F/T六维力矩传感器反馈

多模态数据帧率展示



当前主流的数采方案——遥操作 (Teleoperation)

同构臂遥操

主臂与从臂在运动学结构上一致，通常采用关节级一一映射进行遥操。

优势

- **高保真**：无需复杂 IK 映射，可直接采集与目标机器人一致的关节轨迹。
- **力控友好**：若支持力反馈，可提升接触任务的稳定性与可操作性。

劣势

- **通用性差**：往往需针对目标机器人单独设计主臂。
- **易疲劳**：物理回拖或长时间操作的人机负担较重。
- **人机工效受限**：部分布局下会出现遮挡、操作空间受限等问题。

适用场景

高精度、强接触、双臂协同任务，如装配、叠衣服、打包；常用于采集高质量专家示教数据做微调。这个是泛工业场景数据获取的主要手段。



当前主流的数采方案——遥操作 (Teleoperation)

VR遥操

操作员通过 VR / XR / 动捕设备输入头手或全身位姿，系统经运动重定向与实时控制求解，驱动机器人跟随。

优势

- 轻便省力，适合长时操作
- 结合vr沉浸式第一人称视角利于全身协同控制

劣势

- 力觉通常不足，接触密集任务难
- 人机骨骼差异会带来映射误差与动作失真

适用场景

人形机器人全身数采；低力控要求、强视觉依赖的遥操与示教；常用于采集专家演示数据做微调。



当前主流的数采方案——UMI

UMI (Universal Manipulation Interface)

操作员手持带腕部相机的独立夹爪，系统记录末端 6D 位姿与夹爪开合状态，同步采集局部交互视频。

优势


- 轻便低成本，适合真实环境的大规模采集
- 同一类策略接口较易迁移到不同机械臂平台

劣势

- 位姿估计精度受视觉重建影响
- 局部视角容易遮挡、缺少全局信息
- 人类示教与机器人执行之间存在 embodiment gap

适用场景

更适合大规模预训练和泛化学习；高精度接触任务通常还需更高保真数据补充微调。



当前主流的数采方案——Ego-Centric

Ego-Centric 采集

操作员佩戴头戴/胸戴/腕戴等第一人称设备执行任务，记录视觉、手部/腕部运动，以及可选的触觉或受力信息。

优势

- 适合在真实场景中大规模采集
- 视角贴近人类操作
- 若结合手部动捕，可覆盖精细操作与接触过程

劣势

- 手部高精追踪难、易遮挡
- 人类动作迁移到机器人仍需额外对齐

适用场景

大规模预训练：人形机器人全身协同学习



关键数据获取的方法——Dagger (Dataset Aggregation)

Dagger (Dataset Aggregation) 是“让机器人在自己会犯错的地方继续学习”的方法。它不是只学专家一开始做对的轨迹，而是让机器人先自己执行，再让专家告诉它：如果你走偏了，这时候应该怎么改回来。本质上是一种 Human-in-the-Loop 的 corner case 的收集策略。


Dagger 原理示意图

让机器人在自己会犯错的地方继续学习 (Dataset Aggregation)




不可或缺的数据源——仿真

仿真在机器人操作中的核心价值：操作数据生成和闭环测试




不可或缺的数据源——仿真场景生成工作TabletopGen

TabletopGen: 一个完全自动化的agent框架, 给定图像生成各种类型的3D桌面场景。





Task: place the cucumber into the bowl, and subsequently move the carrot and salt shaker onto the cutting board.



不可或缺的数据源——仿真场景生成工作MarketGen

MarketGen: 一个完全自动化的agent框架，通过PCG的方式生成规模化的超市场景



简单有效的数据预处理策略——ISR

ISR (Information-Standardized Resampling) 优化episode采样流程, 使得采样后的数据更加标准化, 分布更加一致, 从而使得模型学习更容易, 能够得到更高的操作成功率

1

人类遥操作轨迹存在速度波动、停顿和冗余采样


2

固定3倍降采样无法区分无效停顿与关键操作阶段

3

需要一种面向信息分布的轨迹标准化方法


- 从黎曼流形视角重新定义轨迹上的“距离”
- 用统一度量表征轨迹的运动学与动力学特征
- 在压缩冗余动作的同时保留关键操作阶段




简单有效的数据预处理策略——ISR

更少数据，更高成功率

Method	Place&Cover	Place&Stack	Push-T	AVG.(↑)
$3\times + \pi_{0.5}$	45.8 (33.3)	48.6 (33.3)	48.9 (33.3)	47.8
ISR + $\pi_{0.5}$	72.2 (28.9)	72.2 (28.2)	71.1 (40.2)	71.8
$3\times + \text{VO-DP}$	56.9 (33.3)	66.7 (33.3)	64.4 (33.3)	62.7
ISR + VO-DP	77.8 (28.9)	91.6 (28.2)	71.1 (40.2)	80.2




多人采集数据，ISR显著提升成功率



QCon
全球软件开发大会

THANKS

数字世界和物理世界的AGI正在发生



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

