

QCon

全球软件开发大会

DeepResearch X OpenClaw: 实现路径与 Token 成本控制

卢亿雷

白海科技创始人 & CEO



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👤 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👤 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👤 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👤 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

01

行业现状与挑战

02

DeepResearch x 龙虾

03

系统架构总览

04

核心技术设计

05

配置体系与平台化能力


06

Token成本优化及总结展望

01

行业现状挑战

为什么需要 Deep Research?



核心价值：用户不再需要手动搜索、整理、总结 — 智能体自主完成从「问题」到「报告」的全流程

Deep Research 行业竞争格局

2024.12 Google 首发 Deep Research → 2025.02 OpenAI 跟进 → 各厂商快速入局 → 2026 进入成熟竞争期

10+

主要产品/团队

3-30min

报告生成耗时范围

48.9

DR Bench 最高分 (Gemini)

25%

传统搜索量预计下降(2026)

主要玩家

Google Gemini

免费可用 · Gemini 3 Pro · DR Bench 领先

OpenAI ChatGPT

o3/o4-mini · 技术深度强 · 30次/月(Plus)

Perplexity

速度最快(3-5min) · 100-300引用 · 过程透明

Anthropic Claude

安全审慎 · 多视角推理 · 可验证引用

xAI Grok

实时数据 · 与Perplexity集成 · 快速迭代

主流 Deep Research 产品深度对比

维度	Google Gemini	OpenAI ChatGPT	Perplexity	Claude
底层模型	Gemini 3 Pro	o3 / o4-mini	多模型混合	Claude Opus 4
生成耗时	5-20 分钟	5-30 分钟	3-5 分钟	5-20 分钟
报告长度	~12,000 字	10,000-16,000 字	5,000-10,000 字	视任务而定
引用数量	20-50	20-50	100-300	20-40
研究规划	可编辑计划	自动规划	实时展示	多视角分析
核心优势	搜索生态集成	技术深度	速度与透明度	安全与准确性
主要短板	创意性不足	速度较慢	报告偏短	搜索源较少

市场洞察：Gemini 凭借 DR Bench 48.9 分暂时领先，但各家差距不到 4 分 — 竞争焦点正从「能力」转向「体验」和「生态」

技术趋势与演进方向

从 Chat 到 Agent

- 对话范式已终结
- 竞争转向"能办事"的智能体
- Gartner: 2026年 40% 企业应用
- 将嵌入任务型 AI Agent
- Agentic Search 成为新战场

深度研究民主化

- 免费额度逐步开放
- ChatGPT 免费用户可用(受限)
- Gemini 提供免费 Deep Research
- 技术门槛持续降低

生态与平台竞争

- Google/Microsoft 生态优势凸显
- 企业 LLM API 份额: Claude 32% · OpenAI 25% · Google 20%
- 企业 AI 投资 370 亿美元 (2025)
- 差异化从能力转向体验

定位

聚焦企业级场景: 可配置的研究流程 · 多搜索源适配 · 多租户隔离 · 双模通信保障稳定性 — 面向 B 端提供可运营的 Deep Research 服务

Deep Research 落地的核心技术难题

各家产品能力趋同，真正的壁垒在工程落地。以下是我们在实践中识别的共性难题：

1

长任务稳定性

研究任务 20-30 分钟是常态，SSE 长连接在这个时间尺度上极不稳定。如何保证内容不丢、进度可追、断点可恢复？

2

研究过程的可控性

模型自主循环检索，但用户和运营方需要控制研究深度、指定搜索源、随时终止任务、过滤无关输入。如何在“自主”和“可控”之间取得平衡？

3

多租户下的配置复杂度

不同客户对报告形式、搜索服务、澄清方式的诉求各不相同，且每次调用可能还要临时覆盖。如何设计一套不失灵活的配置体系？

4

多格式输出一致性

同一份报告要输出 PDF、Word、HTML 三种格式，还要精确还原引用角标。Markdown 到三种格式的渲染如何保证一致？

02

DeepResearch X 龙虾

OpenClaw: 2026 年第一现象级 AI 项目

320K+

GitHub Stars

60天超越 React 十年纪录

1,000+

全球贡献者

每周活跃提交者 1,000+

30,000+

Clawhub skills

可扩展 Agent 能力边界


什么是 OpenClaw?

奥地利工程师 Peter Steinberger 于2025年11月发布的开源 AI Agent 框架。

核心定位：本地优先、自主执行。用户通过 IM (Slack/Whatsapp等) 用自然语言下达指令，AI 自主规划并执行文件操作、浏览器自动化、数据抓取等复杂任务。

2026.2.14 创始人被 OpenAI 收编，项目移交开源基金会。

数据查询与 2026 年 3 月 20 日



OpenClaw的技术架构

Chat channels (聊天渠道)：通过 聊天工具与 OpenClaw 交互，适配器统一各平台消息格式。


Gateway (网关核心)：Node.js 核心进程，含三大子系统——Session manager 隔离会话、Lane queue 编排任务、Skill selector 按需注入技能。

Memory system (记忆系统)：双层结构。每日日志提供短期上下文，MEMORY.md 存储长期信息，/compact 命令压缩时先持久化防遗忘。

Trigger / heartbeat (触发/心跳)：通过 cron、webhook、Gmail 等机制主动唤醒 AI，无需用户先开口即可行动。

AI model (大模型)：Gateway 将上下文发送给 LLM (Claude、GPT 或本地模型)，返回推理结果和工具调用指令。

Local tools (本地工具)：浏览器控制、Shell 命令、日历邮箱等 50+ 集成，全部运行在用户本地，数据不外泄。



All components run on your own hardware (laptop, Mac Mini, VPS)

「养龙虾」到底在养什么？



操作电脑

浏览器自动化、文件管理、多步骤任务串联



IM 交互

企微 / 飞书 / 钉钉 / Slack / Whatsapp等原生接入



培育专属 Agent

持续投喂指令 + 偏好校准 + 经验沉淀



24/7 运行

Token 消耗是对话的百倍至千倍



从「对话交互时代」迈入「行动执行时代」

全球巨头 + 国内大厂全面入局

海外巨头

OpenAI 收编创始人，整合 Agent 能力；
NVIDIA GTC 发布 NemoClaw / OpenShell

国内企业动态

智谱、月之暗面、MiniMax、阿里、字节、百度、
腾讯、有道、小米等 13+ 企业集体入局
云端 SaaS + 本地部署两条路线并行

国内「类龙虾」产品全景

智谱 AutoClaw/澳龙

月之暗面 Kimi Claw

MiniMax MaxClaw

阿里 CoPaw (开源)

字节 ArkClaw

百度 DuClaw

腾讯 QClaw/WorkBuddy

有道 LobsterAI

小米 miclaw

阿里云 JVS Claw

在 OpenClaw 中实现 Deep Research: 要点与难点

实现要点

- 1 Skill 插件封装**
将 Deep Research 三阶段流程封装为 SKILL.md 插件，复用 OpenClaw 技能系统
- 2 多模型路由**
利用 OpenClaw 的 model failover 能力，按研究阶段选择最优模型（规划用强模型、检索用快模型）
- 3 消息通道适配**
通过 OpenClaw 的 23+ 消息通道统一输出研究报告，适配不同平台的消息长度限制
- 4 本地数据安全**
OpenClaw 本地优先架构天然满足数据隐私需求，研究过程数据不离开用户设备

核心难点

- 1 长任务与消息通道冲突**
研究任务 20-30 分钟，但 WhatsApp/Telegram 有消息超时和长度限制，需要增量推送+断点恢复
- 2 多平台渲染差异**
Markdown 报告在 Signal/Slack/Web 中渲染效果不同，需要按通道自适应格式化
- 3 Token 消耗放大**
Agent 框架增加工具调用上下文开销，单次研究 Token 消耗可能是直连 API 的 3-5 倍
- 4 并发与隔离**
多用户同时发起研究任务，本地资源有限，需要任务队列管理与上下文隔离


我们的思路

不重新造轮子，而是将成熟的 Deep Research 引擎以 Skill 插件形式集成到 OpenClaw。核心研究能力（规划、检索、生成）由后端服务提供，OpenClaw 负责通道适配、用户交互和任务管理。下文详述的架构设计正是基于这一分层思路。


03 系统架构总览

系统架构全景


Deep Research 系统架构



DeepResearch模型训练



DeepResearch模型训练



三阶段流程设计

1

需求分析

- 意图识别与拒答判断
- 需求澄清交互
- 自然语言 / 表单式
- 报告形式预判

2

研究规划

- 自动生成研究计划
- 复杂度评估
- 用户确认(可跳过)
- 搜索策略制定

3

深度研究与报告

- 循环检索与分析
- 增量内容输出
- 进度百分比追踪
- 多格式报告生成

核心设计原则



可配置性

三层配置逐层覆盖
每个环节可定制
灵活适应不同场景



可观测性

实时进度百分比
中间处理信息输出
多维数据监控



多租户隔离

账户级数据隔离
独立鉴权Token
配置互不干扰



双模通信

轮询模式保稳定
SSE模式保实时
按需选择

04


核心技术设计

通信方案 · 增量输出 · 进度追踪 · 任务控制

通信方案选型：轮询 vs SSE

轮询模式 vs SSE 模式 — 通信方案对比

轮询模式 (Polling)




核心设计

- 每 5 秒轮询 (可调) 避免 20min+ 长连接稳定性风险
- 增量输出：仅返回新产生的内容块
- 内容块带 JSON 标识/编号, 支持客户端拼装
- 进度百分比 = 当前轮数 / 循环硬上限
- 处理信息：标题 + 详情, 首次轮询返回全部历史
- 循环结束固定输出 100%

VS

SSE 流式模式 (Server-Sent Events)



核心设计

- 端到端纯流式输出, 实时性最优
- 单次长连接, 无轮询开销
- 适合短-中等时长任务
- 浏览器原生支持 EventSource API
- 风险：超长任务(20min+)连接可能中断
- 适用场景：对实时性要求高的客户端

增量内容输出机制

内容块设计

```
{
  "task_id": "dr_20240315_001",
  "blocks": [
    {
      "block_id": "blk_007",
      "type": "content",
      "text": "根据检索结果...",
      "sequence": 7
    }
  ],
  "progress": 45,
  "is_complete": false
}
```

- 每个内容块带唯一编号
- JSON 格式标识，支持客户端拼装
- 增量输出，仅返回新产生内容

输出流程

- 1 模型生成内容片段
- 2 服务端缓存内容块 + 编号
- 3 客户端轮询请求
- 4 返回增量内容块 + 进度
- 5 客户端拼装渲染

首次轮询返回第三阶段所有已产生历史

进度与过程可视化

进度百分比


45%

进度 = 当前循环轮数 / 循环轮数硬上限
循环结束 → 固定输出 100%

处理信息

```
"process_info": [  
  { "title": "搜索行业报告",  
    "detail": "检索到 15 篇相关文献..." },  
  { "title": "分析竞品数据",  
    "detail": "提取了 8 个关键指标..." }  
]
```

轮询间输出示意



任务控制：终止与拒答

终止研究任务

- 支持研究过程中随时终止
- 终止后释放模型和服务占用
- 保证资源不被长期占用
- 客户端收到终止确认后停止轮询

1. 客户端发起终止
2. 服务端中断模型调用
3. 释放计算资源
4. 返回终止确认

拒答机制

- 对用户输入进行意图识别
- 拒绝与深度研究无关的输入
- 判定拒答时直接终止任务
- 向客户端输出特定拒答标识

开关控制

默认关闭

关闭时跳过拒答判断，直接执行研究任务

端到端交互时序

Deep Research 三阶段交互流程

阶段一：需求分析


阶段二：研究规划

阶段三：深度研究与报告生成

用户

模型

模型



图例： 阶段一 阶段二 阶段三 输出

可配置项：澄清形式·研究规划确认开关·报告形式·报告复杂度·搜索服务选择·拒答开关

05

配置体系与平台化能力

三层配置 · 搜索集成 · 报告输出

三层配置架构

三层配置架构 — 逐层覆盖机制

第一层：默认配置 (Default Config)

系统预设值，开箱即用

- 搜索服务 = 白海搜索(默认)
- 报告复杂度 = 复杂
- 拒答开关 = 关闭
- 澄清形式 = 自然语言
- 研究规划确认 = 不跳过
- 报告形式 = 通用

▼ 覆盖

第二层：静态配置 (Static Config) — 账户级

通过 Config API 管理，长期存储

- | | | |
|--|---|--|
| 基础服务设置 | 外部服务设置 | 偏好设置 |
| <ul style="list-style-type: none">• 默认报告复杂度覆盖• 默认搜索服务覆盖 | <ul style="list-style-type: none">• 外部搜索鉴权凭证• 搜索服务选择 | <ul style="list-style-type: none">• 报告风格偏好• 其他个性化配置 |

▼ 覆盖

第三层：参数配置 (Parameter Config) — 调用级

每次 API 调用时传入，最高优先级

- | | |
|---|---|
| <ul style="list-style-type: none">• 报告形式（优先于模型分析结果）• 澄清形式• 研究规划确认开关 | <ul style="list-style-type: none">• 报告复杂度• 搜索服务选择• 拒答开关 |
|---|---|

优先级：参数配置 > 静态配置 > 默认配置

研究过程可定制

澄清形式

自然语言澄清 · 表单式澄清

默认：自然语言

根据场景选择最适合的用户交互方式

研究规划确认

需要确认 · 跳过确认

默认：不跳过

跳过时直接使用模型生成规划执行

报告复杂度

简单 · 复杂 · 自动

默认：复杂

影响研究深度、循环轮数和最终质量

报告形式

通用 · 自动

默认：通用

优先级高于需求分析阶段的模型判断

多格式报告输出

纯文本模式

Markdown 渲染结果输出为:

PDF

渲染后的排版文档

Word

可编辑的文档格式

HTML

网页版报告

纯文本 + 可视化报告

在纯文本基础上额外输出:

- 纯文本的 PDF / Word / HTML
- **模型生成的 HTML 可视化报告**
- 包含图表、交互式内容

文件角标还原

生成 Word & PDF 时, 基于 URL 编号结果, 使用固定格式替换模型原始输出的 [ref_n] 标记, 实现引用角标的精确还原。

文件支持按需查询、获取和分享。

外部搜索服务集成

白海搜索

默认

标准搜索引擎
内置集成
无需额外配置

百度搜索

可选

中文搜索增强
需提供鉴权凭证
适合中文场景

阿里搜索

可选

多模态搜索
需提供鉴权凭证
适合电商/技术

选择逻辑

- 调用接口: 参数指定 > 账户静态配置 > 系统默认
- 调用方提供外部搜索服务对应的鉴权凭证

账户与鉴权管理

账户体系

账户

唯一 ID + 账户名称
数据完全隔离 (输入 & 输出)

Token A (生产环境)

启用

Token B (测试环境)

启用

Token C (已禁用)

禁用

Token 管理 & 数据隔离

Token 管理

- 每个账户可拥有多个鉴权 Token
- Token 支持设置别名 (必须)
- 支持新增、禁用和恢复操作

数据隔离

- 传入 DR 服务的所有数据 — 隔离
- DR 服务输出的所有数据 — 隔离
- 不同账户间严格隔离

数据监控与服务配置

数据监控

支持任意数据 × 任意维度的交叉统计

统计维度	示例数据
账户	调用次数 / Token用量
时间	日均任务数 / 峰值并发
搜索源	各搜索服务调用量
复杂度	简单/复杂任务分布
状态	成功/失败/终止率

服务配置管理

账户级静态配置，通过独立 **Config API** 管理

基础服务设置

报告复杂度 · 搜索服务 · 拒答开关

外部服务设置

搜索鉴权凭证 · 服务端点配置

偏好设置

报告风格 · 澄清形式 · 个性化项

06

Token 消耗优化

Token是智能时代的“电力”与“流量”



Sources: Introl Blog, Sanand LLM Pricing, FinOps Foundation

Token成本全栈公式

Total Cost Per Request =

**(Input × P_in) + (Output × P_out) + Retrieval + Embedding + Orchestration +
Observability – Cache**

Input Tokens **30-40%**

用户Prompt消耗

Output Tokens **40-50%**

模型生成输出

Retrieval **5-10%**

RAG检索查询

Embedding **3-5%**

向量嵌入维护

Orchestration **5-15%**

Agent编排开销

Cache Savings **10~30%⁻**

缓存节省（减项）

Deep Research Token 成本分析

单次深度研究的 Token 消耗远超普通对话，优化空间巨大

需求分析阶段

~10%

总消耗占比

Input: 2-5K tokens

Output: 1-3K tokens

澄清问题+研究计划

深度研究阶段

~75%

总消耗占比

Input: 50-200K tokens

Output: 10-30K tokens

多轮检索+上下文累积

报告生成阶段

~15%

总消耗占比

Input: 20-50K tokens

Output: 5-15K tokens

长报告+引用整理

核心发现

深度研究阶段占 75% 成本，多轮检索的上下文窗口持续膨胀是主因。Output Token 单价是 Input 的 3-5 倍，控制输出长度的 ROI 最高。

单次研究总消耗可达 80K-300K tokens，Agent 框架（如 OpenClaw）还会额外增加 30-50% 的工具调用开销。

Deep Research 龙虾 Token 降本策略全景

1 语义缓存

请求前

对相似研究请求做语义匹配，命中则跳过 LLM 调用直接返回

2 Prompt Cache

请求前

固定系统提示词为前缀，利用 API 原生缓存减少重复计费

3 模型路由

请求中

按子任务复杂度分流：规划用强模型，摘要/提取用轻量模型

4 输入压缩与裁剪

请求中

滑动窗口+历史摘要替代全文，控制每轮上下文长度上限

5 Output 精确控制

响应控制

中间轮次只要结构化摘要不要全文，Output 单价远高于 Input

6 研究轮次收敛

流程控制

设定信息增益阈值，新一轮检索无显著新信息时提前终止

Token 优化实战：行业数据与落地效果

按请求生命周期分层优化

请求前

语义缓存 · Prompt Cache
命中即跳过，不产生调用

请求中

模型路由 · 上下文裁剪
选对模型，压缩输入

响应后

Output 精控 · 轮次收敛
控制输出量，减少总轮次

行业实测数据

优化手段	实测效果	数据来源
模型路由 o3→o4-mini	\$10→\$0.9 /次	Artificial Analysis
语义缓存	↓~73% 高重复场景	Redis LangCache
Prompt Cache	↓~90% 重复前缀	Anthropic/OpenAI
上下文压缩	↓~80% Input tokens	Zylos Research
综合叠加	↓60-80% 总成本	多源交叉验证

关键结论

单次 Deep Research 原始成本: o3 约 \$10/次, o4-mini 约 \$0.9/次 (Artificial Analysis 实测 10 queries)
组合优化后可控制在 **\$1-3/次** — 模型路由是 ROI 最高的单一策略, 缓存+压缩进一步叠加
先量化再优化, 降本不降质 — 全链路 Token 监控 + 研究质量评测 (RAGAS) 守住质量红线

数据来源: Artificial Analysis, Redis, Zylos Research, Anthropic/OpenAI 官方文档

LLMLingua 提示词压缩

Microsoft Research

压缩流程



2-5x

提示词压缩率，几乎无质量损失

技术演进

V1: 信息熵启发式压缩

V2: GPT-4蒸馏BERT编码器, Token级二分类

已集成: [LangChain](#) + [LlamaIndex](#)

每次调用隐形节省360+ tokens

FrugalGPT 模型级联策略




Stanford研究实证结果

↓
推理成本削减 **98%** +4%

核心逻辑

- 小模型先试 + 置信度评估器
- 绝大多数流量在低成本层消化
- 只有复杂任务触发旗舰模型
- 测试集: HEADLINES / OVERRULING / COQA

推测解码 Speculative Decoding



111%

吞吐量提升
EAGLE-3

60%

预处理消耗降低
Amdocs

3x

吞吐量提升
Snap

80%

延迟缩减
Amdocs

总结与展望

关键收获

1 双模通信保障稳定

轮询保稳定 + SSE 保实时，按需选择

2 三层配置灵活可控

默认→静态→参数，逐层覆盖满足多样需求

3 开源框架可集成

OpenClaw 等开源 Agent 框架是 Deep Research 落地的有效载体

4 Token 降本 65%+

缓存+路由+裁剪三层降本，质量不降

5 平台化多租户

账户隔离 + 监控 + 服务配置，可规模化运营


未来方向

多 Agent 协作 · 更智能的自适应规划 · 多模态研究能力 · 实时数据源接入 · 开源生态持续降本

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海
站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参
会
咨
询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁洁楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

