

QCon
全球软件开发大会

构建：AI的“第二大脑”、 Agent的“记忆护照”

大规模多模态记忆平台技术实践

 MemoryLake

周 祥

质变科技（DataCloud）产品负责人、首席架构师

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

- 01 企业AI落地的“失忆困境”
- 02 AI"第二大脑"的架构设计与核心技术
- 03 生产级实践的痛与解
- 04 OpenClaw 专属版 MemoryLake
- 05 未来展望

企业 AI 落地的‘失忆’困境

第1周:

精准回答行业分析问题，团队欢呼

第3周:

反复回答相同的错误结论，因为它‘忘了’上周的修正

第5周:

在董事会汇报中引用了已被否定的数据，造成决策偏差

第7周:

项目暂停，‘AI不可信’成为共识

问题不在于AI不够聪明，而在于它每次醒来都是一张白纸。

从"能对话"到"会决策"的鸿沟

企业AI落地的真实鸿沟

能对话

- 单轮问答准确率高
- 展示效果好、领导喜欢
- POC通过率 > 90%

这个鸿沟的名字叫 →

记忆

会决策

- 需要跨会话的上下文延续
- 需要结合历史决策轨迹
- 需要多模态数据的精准理解
- 需要可解释、可干预、可追溯
- 生产部署率 < 6% (当前行业数据)

现有方案为什么不够？

RAG、向量数据库、长上下文——都不是“记忆”

方案	做了什么	缺了什么
RAG	检索外部文档片段注入上下文	无状态 ——不记得上次检索了什么；无法关联多次交互； 无记忆管理
向量数据库	提供高效的相似度检索	只是存储层 ——没有理解、没有推理、没有遗忘与压缩
长上下文窗口（2M token）	一次性塞入更多信息	成本爆炸 （\$0.5/次）、 延迟高 （~分钟级）、 无法持久化 、 fine-tune难度高
Mem0 / 会话记忆	记住对话中的关键事实	仅纯文本会话 、 无多模态 、 无企业级特性 、 无大规模验证

这些方案解决的是‘数据接入’问题，不是‘记忆’问题。

记忆 = 理解 + 存储 + 组织 + 推理 + 遗忘 + 演进

问题不是个案，是系统性的

企业生产级Agent占比

< 6%

行业调研

主流模型DABStep准确率

< 30%

Google DABStep Benchmark

Kramabench端到端得分

< 50%

Kramabench

企业响应新数据需求周期


1-4 周

客户调研

55%的员工不会使用分析工具，49%的企业认为"缺乏内部技能"是AI落地的关键障碍。
问题不只是技术——是基础设施缺位。

LLM 是"第一大脑", 记忆平台是"第二大脑"

思考 (LLM)



记忆 (MemoryLake)

AI时代的数据基础设施, 将从"记录行为"演进到"记录决策轨迹", 用户从"人"演进到"Agent", 规模将大幅提升。

单机时代

Apps → OS → CPU → Memory → Disk

大数据时代

BI/AI → Distributed Computing → Distributed Storage

AI时代

Agents/Skills/Apps → **Memory** → Tools/API → LLM(OS)

Gartner

\$28B

AI Memory市场 2028 · Gartner

参考: Snowflake市值\$76B, Databricks估值\$130B

"AI"第二大脑"的架构设计与核心技术

从"数据为中心"到"记忆为中心"的范式转变

从"数据为中心"到"记忆为中心"


维度	数据为中心（传统）	记忆为中心（AI原生）
存储对象	结构化表、文件	认知状态（事实+关系+上下文+时序）
写入方式	ETL批量灌入	持续理解+提取+压缩+演进
读取方式	SQL / API查询	多跳推理 + 上下文感知召回
管理方式	Schema设计、索引优化	记忆策略（遗忘/合并/溯源/冲突检测）
一致性模型	ACID / 最终一致性	认知一致性（逻辑冲突检测+多版本）
用户	人（DBA/分析师）	Agent（千万级并发）

数据是**死的** ——存进去什么样，读出来什么样。
记忆是**活的** ——它会理解、压缩、关联、遗忘、演进。

MemoryLake 三层技术栈总览

MemoryLake 架构：大规模、分布式、自演进、高准确性

Any Data to LLM Context



- Anywhere / Anytime / Anysize
- 生态：Mem0 / MCP / OpenMemory 兼容

91% ↓
Token


98%
准确性 (vs LLM + raw files)

95% ↓
延迟

1000x
数据规模 (vs ChatGPT/Claude)

突破1：多模态数据统一表征与跨模态关联对齐

“企业的知识散落在PDF、Excel、PPT、会议录音、聊天记录、数据库中。如何让AI像人一样“理解”这些异构信息，而不只是“看到”？”



Skills Center自定义


分布式处理+动态图

高扩展性

大规模: 1000+ Pages / 10G+ Volume


TableBench / DABStep Benchmark 全球第一 🏆

MemoryLake-D1：生产环境中的多模态理解



Excel

多子表 Excel（多个worksheet，嵌套结构）



PDF

多布局 PDF（图文混排，跨页表格）




MemoryLake-D1

多模态大模型



发票

多层级发票/采购单（中英文混排，复杂表头）



财报

财务报表（合并单元格，千万级行数据）

千万级行

高并发处理

双重校验

视觉+逻辑严格验证

EOB #1


TableBench / DABStep

核心技术2——记忆的动态组织

突破2：记忆引擎的动态组织——不只是存储，是'活'的记忆

能力	说明	技术实现
 提取	从原始数据中抽取结构化记忆	MemoryLake-D1 + Agent Skills
 组织	构建记忆之间的关联关系	时序图谱 + 实体关系链
 压缩	长期记忆的渐进式压缩	分层压缩策略（场景意识→短期→中期→长期→工作记忆）
 遗忘	过期/低价值记忆的淘汰	Evict策略 + 时间衰减函数
 去重	重复记忆的合并	De-duplication + 语义相似度合并
 冲突检测	矛盾记忆的识别与处理	逻辑冲突 / 隐性知识冲突 / 幻觉冲突，多版本管理
 演进	记忆随时间自动更新	RL驱动的记忆策略优化

记忆层次模型（类比人脑）：



记忆不只是'事实'——六类记忆的完整体系

Background	背景设定	"用户是一位金融分析师，关注新能源赛道"
Facts	基础事实	"用户的花生过敏"
Events	事件流	"2025-03-15 用户提交了Q1报告"
Conversations	对话记录	"多轮会话的关键信息提取与压缩"
Actions	行动记录	"Agent执行了SQL查询并生成了图表"
Reflections	反思	"上次的分析路径效率低，下次应先检查数据质量"

关键：每种记忆类型有不同的存储策略、衰减曲线和压缩规则。

核心技术3——亚秒级多跳推理

突破3：亚秒级多跳推理查询引擎

QueryAgent 推理流程



关键技术：

- 时序图谱构建：跨session的实体关系链，支持复杂时序推理
- 多路索引融合：关键词 + 向量 + 图谱 三路并行，取并集
- 增广预提问：自动生成补充查询，提高召回覆盖率
- Self-consistency：多重验证机制——提取记忆时检查语义一致性，最终回答时仔细检查问题与召回记忆的匹配度

LoCoMo Benchmark 结果

模型/记忆体	LoCoMo得分
MemoryLake	94.0%
Mem Product 1	92.3%
Mem Product 2	92.1%
Mem Product 3	91.7%
人类标注	87.9% 人类标注
Mem Product 4	75.1%
Mem Product 5	68.4%

LoCoMo: 为什么这个Benchmark很难，我们为什么能赢

LoCoMo的5类挑战:

类型	描述	示例	我们的技术
单跳问题	单个session里直接找到答案	“上次聊做饭时我说最拿手的是哪道菜？”	传统RAG多路索引
多跳问题	跨session的多步推理	“我什么时候开始在游戏公司上班的？是在搬家之后还是之后入职？”	时序图谱 + 跨session实体关系链 + 增广预提问
时间推理	基于时间线索的推理	“我第一次脚踝受伤到后来完全恢复，大概过了多久？”	相对时间→绝对时间归一化 + 事件时间轴构建
世界知识问题	结合个人记忆+常识回答	“我和罗伯特约会时应该避免哪类零食？”（对话中说过花生过敏）	记忆-参数协同：记忆检索+模型通用知识查询并行
对抗性问题	故意误导的问题	“我有三个孩子，最小的是女儿几岁？”（实际从未提过最小的孩子）	多重验证：self-consistency检查 + 问题与召回记忆匹配度校验

突破4：分布式记忆计算与Sandbox安全隔离

“当记忆规模到10万亿级记录时，传统的检索和计算模式全部失效。”

1

计划生成：10层以上DAG执行逻辑，可解释、可干预

2


Code Sandbox：安全隔离的代码执行环境（Python/JavaScript/…）

3

分布式执行：大规模并行Task，支持GB~PB级数据处理

4

AgentRL：PPO + Actor-Critic RL，自动优化分析路径——越用越聪明



突破5：记忆血缘追踪与推理路径可解释性

企业客户最常问的问题："这个结论是怎么得出来的？依据是什么？能不能改？"

层次	能力	实现
记忆来源识别	每条记忆标注来源（哪个文档/哪次会话/哪个API）	记忆写入时自动打标 + 来源链路存储
记忆Time Travel	回溯任意时间点的记忆状态	多版本管理 + 时间戳索引 + 快照机制
推理路径可视化	展示从查询→检索→推理→生成的完整链路	每步推理输出中间结果 + 引用的记忆片段标注

🕒 Time Travel

用户问："为什么上季度华东区销售下降了？"

推理路径：

Step 1: 检索记忆

→ [Q3销售报告.xlsx, 行12-45] [华东区会议纪要.pdf, 页3]

Step 2: 关联分析

→ 发现价格调整事件（2025-07-15）与销售下降时间吻合

Step 3: 交叉验证

→ [竞品分析.pptx, 页7] 确认同期竞品降价


Step 4: 生成结论

→ "华东区Q3销售下降主因是7月价格调整后竞品跟进降价..."

↑ 每步可点击查看原始数据源

MemoryLake Skills: 开放技能网络，深度链接数据、知识、经验和决策

Skills Center——开放技能网络



基础知识注入

术语、基础契约、Skill —
任意维度的共享/隔离

领域知识注入

学术、金融等10+领域知识, **10PB+**
— 任意维度的共享/隔离

业务知识注入

元数据注释、术语映射、计算指标、业
务规则、实体定义、示例问题库

生产级实践的痛与解

在超大规模客户场景中踩过的坑

我们经历过的生产规模



国内头部办公文档服务

1亿+ 文档

超大规模文档处理 + 99.8%召回率要求



新加坡M客户

10万亿+ 记录

跨云部署 + 毫秒级延迟



头部游戏公司

百万级玩家实时记忆

1秒延迟 + 并发 + 世界观一致性

以下痛点和解法，全部来自这些客户的真实生产经验。

痛点1：多模态数据理解的"最后一公里"

“问题描述：OCR + 通用模型在复杂业务场景中频繁失效：

- 复杂业务表格（合并单元格、转置表、嵌套子表）
- 手写批注、盖章遮挡
- 会议录音中的情绪/语气识别

我们踩过的坑：

场景	通用方案准确率	问题
多子表Excel	~55%	无法识别一个worksheet里的多个逻辑表
跨页PDF表格	~40%	表头丢失、行错位
中英文混排发票	~60%	字段映射错误
财务合并报表	~45%	合并单元格语义丢失

我们的解法：

1. 专用提取Pipeline而非通用VLM：Excel流程 + PDF流程
2. 语序恢复：结合语义的OCR后处理，修复布局识别导致的语序错误
3. 视觉+逻辑双重验证：提取结果与原始文档视觉比对 + 逻辑一致性校验
4. Skills自定义：客户可以为特定文档类型定义专属提取规则

办公场景准确率从行业平均60-70% → 99.8% 召回率

60-70%



99.8% 召回率

痛点2：10万亿级记录下的检索成本失控

痛点2——检索成本失控

向量检索在千万级规模就开始出现延迟与精度的trade-off。到10万亿级，问题呈指数恶化。

数据（某客户实测）：

记录规模	纯向量检索延迟	精度(Recall)
100万	10ms	95%
1亿	80ms	95%
100亿	600ms	95%
10万亿	timeout	

<200ms

10万亿级记录检索延迟
(vs 之前timeout)

95%+

精度保持

30x

成本降低

我们的解法——混合检索 + 记忆分层：

- 1

多路索引融合：关键词索引（精确匹配）+ 向量索引（语义匹配）+ 图索引（关系匹配），三路并行取并集
- 2

记忆分层存储：

热记忆 - 亚毫秒

温记忆 - 毫秒级

冷记忆 - 100ms级
- 3

渐进式压缩：冷记忆不是删除——是压缩。保留关键事实和关系，丢弃原始细节
- 4

查询路由：QueryAgent根据问题类型自动选择检索路径（不需要每次都查全量）

痛点3：不接受不可解释的决策，不接受不可干预的系统

“如果AI说该买这只股票，我需要知道它为什么这么说，引用了什么数据，推理过程是什么。否则我不可能用。”—— 某基金合伙人



-  Code注入检测、危险操作拦截 (DROP/DELETE等)
-  角色体系、表级权限、行级权限
-  敏感信息保护：SSN / ID / Password，三方加密
-  操作日志、异常告警

OpenClaw & Hermes 专属版MemoryLake

为 AI Agent 生态打造的记忆基础设施



HERMES-AGENT

OpenClaw & Hermes专属版：Agent 原生的记忆基础设施


数据源支持

Database、Data Lake、OpenAPI
多模态文件（PDF/Excel/图片/音视频）
会话数据

高准确度的召回/生成

智能语义理解：上下文感知多轮对话，理解代词指代和省略表达
复杂Code生成和执行：10层以上DAG执行逻辑

Agent 原生能力（核心差异化）



能力

说明

AgentRL

PPO + Actor-Critic RL —— 越用越聪明，自动优化分析路径

冲突检测

逻辑冲突 / 隐性知识冲突 / 幻觉冲突，多版本管理

记忆溯源

记忆Time Travel + 记忆来源识别

多粒度记忆管理

Instance / Agent / Session 三层维度，任意维度的共享/隔离

基础知识注入

术语、基础契约、Skill —— 任意维度的共享/隔离

领域知识注入

学术、金融等10+领域，**10PB+** —— 任意维度的共享/隔离

OpenClaw & Hermes Agents 一键搜索全球高质量数据集

学术论文

4000万+论文

来自 arXiv、PubMed、bioRxiv 和 medRxiv 的学术论文

来源:   

临床试验

50万+试验

来自 ClinicalTrials.gov 的临床试验记录

来源: 

药物数据库

200万+化合物

来自 ChEMBL、PubChem、DrugBank、FDA 药品标签和 Open Targets 的药物和化合物数据

来源:   

经济数据

全球覆盖


来自 FRED、BLS、Destatis、世界银行和 USAspending 的经济指标

来源:  


金融数据

实时数据

股票、加密货币、外汇、基金和大宗商品的实时和历史价格

来源:   

专利搜索

1000万+美国专利

USPTO 专利记录和知识产权申请

来源: 

SEC 文件

300万+文件

SEC 申报文件、收益、资产负债表、利润表、现金流量、股息和内部人交易

来源: 

多粒度记忆管理深度讲解

多粒度记忆管理：让每个Agent都有自己的“脑”

三层记忆维度：



核心设计：

- **Instance级**：全局共享的组织记忆（所有Agent可读）
- **Agent级**：每个Agent的私有记忆（角色定义、专属知识）
- **Session级**：每次会话的临时记忆（上下文、短期事实）
- **任意维度可配置共享/隔离** — 通过策略矩阵灵活控制

场景示例 — 游戏AI

- Instance**：世界观设定（所有NPC共享）
- Agent**：NPC角色记忆（每个NPC独立）
- Session**：玩家本次对话上下文（会话结束后压缩入Agent记忆）

MemoryLake: AI时代的“数字脑”,Agent的“记忆护照”



未来展望

记忆的下一步：从智能体到具身智能



当AI Agent从屏幕走进物理世界，记忆的重要性将提升10倍。一个不记得上次任务的机器人，和一个失忆的人一样无法工作。

AI 的‘第二大脑’，Agent的‘记忆护照’，从今天开始构建

- 1 记忆是AI从Demo到生产的关键缺失层 — 不是模型不够好，是基础设施缺位
- 2 记忆 ≠ 存储 — 记忆是活的：理解、组织、压缩、遗忘、演进
- 3 生产级记忆工程有三个硬门槛：多模态精准理解、超大规模低成本检索、可解释可干预
- 4 MemoryLake：全球唯一兼具‘记忆 + 平台 + 大规模生产验证’的解决方案



Julian Zhou

浙江 杭州



THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

