

QCon
全球软件开发大会

面向 AI 原生负载的统一弹性调度体系： Aether 架构实践

季万强

京东零售 高级技术专家



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon


全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

京东零售九数AI平台

九数是京东零售的AI基础设施平台，服务于零售算法团队，为AI研发全链路提供底层算力、引擎、平台能力，支撑算法团队的模型开发与训练推理，提高研发效率，支撑业务增长。



目录

01 背景与痛点

02 整体架构设计

03 关键技术挑战

04 业务落地实践

05 总结与展望

01 背景与痛点

AI原生工作负载的“三驾马车”

高吞吐 · 高算力 · 低延迟

数据处理：高吞吐 · 并行清洗 · 特征工程


高吞吐并行处理，以数据管道为脉络，完成清洗、标注与特征工程，将原始数据转化为高质量“燃料”

模型训练：迭代调优 · 算力密集 · 反向传播

算力密集的迭代探索，在反向传播中驱动参数寻优，于精度与泛化间反复博弈，追求最优收敛

模型推理：低延迟 · 高并发 · 资源弹性

低延迟响应的实时推演，以轻量化部署承载高并发请求，将训练成果转化为业务价值输出。



训推集群面临的痛点



推理服务白天承载高并发流量，训练任务夜间抢占算力资源。训推混部场景下，潮汐式负载波动引发资源争抢，如何在保障推理延迟SLA的同时实现训练任务的高效利用，成为调度系统的核心矛盾。

时间复用



万卡级集群中，GPU/NPU故障、显存ECC错误、网络丢包等硬件异常从“偶发事件”变为“常态存在”。训练任务频繁中断需检查点恢复，推理节点抖动影响服务可用性，集群需具备自愈与韧性调度能力。

常态故障



分布式训练需整卡甚至整机规格，而集群中大量单卡、半卡等碎片化资源无法被大任务有效利用。资源看似充裕却“看得见用不上”，导致整体利用率陷入瓶颈，亟需精细化调度与碎片聚合能力。

空间错配



集群混部多厂商、多代际的GPU与NPU，算力规格、显存容量、算子兼容性各异。上层框架需适配底层硬件差异，调度系统需在异构资源池中实现统一抽象与智能分配，复杂度呈指数级上升。

硬件多样性

弹性调度架构的关键特性

条件

何时触发

定义扩缩容的触发机制，
是弹性的“感知层”

策略

如何执行

定义扩缩容的行为模式，
是弹性的“决策层”

粒度

以何粒度

定义扩缩容的最小操作单元，
是弹性的“执行层”


速度

多快完成

定义扩缩容的时间响应特性，
是弹性的“效率层”

02 整体架构设计

调度整体架构全景图



如何实现大模型训练、推理、服务的弹性调度和SLA保障

1 动态SLA规则


- 人工设置：根究经验预先配置计算所需要的全部卡时
- 自动生成：依据模型复杂度、数据特征等多维指标

2 自适应资源调度

- 资源智能预测：基于集群空闲资源与在线服务的资源需求
- 智能弹性伸缩：基于SLA规则及资源画像，自动实现弹性伸缩

3 预测性保障与自愈

- 故障检测：及时发现故障机并将其隔离
- 自动容错：节点故障后可以继续运行
- 弹性计算：可以随时增减作业的节点数量





弹性调度核心引擎

SLA规则引擎

规则管理

规则知识库

数据分析器

模型分析器

调度编排引擎

workflow编排

DAG

状态机

触发器

资源预测与编排

资源预测模型

任务协调器

资源冲突仲裁

调度器插件

优先级队列插件

资源预留插件

负载感知插件

Aether - 弹性计算引擎

Aether
Brain

Aether-Driver (主节点)

探针

计划器

调度器

Aether-Executor (工作节点)


指标采集

进程监控

弹性组网

Ray

弹性调度核心引擎交互流程



调度编排引擎核心组件

1 workflow编排


- 触发器：条件、定时等
- DAG：完整描述作业的DAG图

2 调度器框架


- 入队阶段：全局队列统一管理作业
- 排序阶段：排序 + 打分
- 绑定阶段：绑定到具体的K8s集群

3 资源编排

- 资源预占：预占K8s集群的资源
- 部署分发：分发到K8s集群



Aether 核心架构图



Aether 核心组件

1 Brain


- 作业历史服务：收集Aether Job执行历史

2 Driver

- 优化器：请求Brain获取优化后的参数或资源配比
- 计划器：生成逻辑执行计划
- 调度器：输入执行计划进行调度执行

3 Executor


- 弹性组网：分布式动态组网
- 进程监控：训练、推理、服务进程
- 指标采集：负载指标、硬件指标等




03

关键技术挑战


Aether 云原生融合




Aether 动态资源优化与调度





Aether 自动故障检测与隔离



Aether 动态组网与拓扑自愈



Aether 动态组网与拓扑自愈



04


业务落地实践

落地实践：京东零售 - 训练、批量推理、PD分离

训练：有效训练时间占比（ETTR）提升至 97%

批量推理：端到端任务处理时间缩短 10%，资源成本降低 30%

模型服务：部署 PD 分离服务的端到端效率提升 5%



某弹性推理作业的扩缩频率



某个集群提供的弹性卡时

05

总结与展望

Aether Roadmap



THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

