


QCon
全球软件开发大会

Qwen3-VL- Embedding: 统一多 模态表征与排序

张延钊
通义实验室算法工程师



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

01

背景介绍：什么是表征与排序模型

02


方法介绍：模型、数据、训练与算法

03

结果介绍：评估与使用

● 背景介绍-Embedding模型是什么

将文本，图片等对象映射为向量，应用于检索、分类和聚类NLP核心任务




检索



从大规模数据中找到最相关的文本

聚类



根据文本相似度进行聚类、分析




根据文本和标签的向量相似度进行分类

● 背景介绍- Embedding Model 历史



背景介绍- Embedding Model 训练过程

对比学习：拉近正样本距离，推远负样本距离



Query


北医三院

Positive

北京大学第三医院



Negative

北京大学医学部




背景介绍- RAG范式下的Embedding与Rerank

Embedding检索 → Rerank重排序 → LLM生成




背景介绍- Rerank 模型介绍

Cross-Encoder架构: Query和Document联合编码, 捕捉深层交互关系




● 背景介绍- Qwen3-Embedding/Reranker

支持多种类型文本数据




背景介绍-多模态Embedding

CLIP VS VLLM Based Embedding




单独处理文本/图片，无法建模混合模态输入关系
From scratch训练Image encoder，需要大量图文对数据




接受任意模态输入，直接输出向量
基于MLLM continue train，数据量需求更低

● 背景介绍- Qwen3-VL-Embedding/Reranker

支持将文本、图像、视频的对象表征为向量，提供基于向量的相似度计算能力



方法-模型架构



Qwen3-VL-Embedding

- 双塔模型
- 基座: Qwen3 VL Dense 模型
- 表征获取方法: Last Pooling
- 指令遵循

Qwen3-VL-Reranker

- Cross Encoder
- 基座: Qwen3 VL Dense 模型
- 分数获取方法: 下一词预测为 yes 的概率
- 指令遵循

方法-训练数据组成

总量3亿：文本1亿、代码1500万、图片1亿、视觉文档3000万、视频5000万



- 总数据量：3亿
- 数据构成：
 - 文本数据：1亿
 - 代码数据：1500万
 - 图片数据：1亿
 - 视觉文档数据：3000万
- 数据来源
 - 开源数据
 - 内部数据
 - 合成数据


粗粒度质量过滤 → 细粒度类别标注 → 类别均衡采样

1. 粗粒度质量过滤：过低分辨率、异常宽高比、静态场景、损坏片段
2. 细粒度类别标注：
 - A. 使用VLM标注图像、视频类别
 - B. 过滤低置信度、低文本图像相关性数据
 - C. 类别均衡采样

方法-数据合成

图像(分类/问答/检索) + 视频(检索/分类/问答/片段) + 数据挖掘(召回/过滤/难负样本)

多任务数据合成




数据挖掘

- 召回: 基于 embedding 模型, 重新用合成数据的 query 召回 candidate
- 过滤:
 - 正样本过滤: 过滤召回相关度低的正样本
 - 负样本挖掘: 基于正样本相关性分数选择难负样本


方法-训练策略-对比式预训练

一阶段：完全基于合成数据，使用开源模型进行初步过滤，优化目标：对比学习




方法-训练策略-多任务对比学习

二阶段：Embedding: 多任务对比学习 | Reranking: 监督微调 | 高质量+合成数据



方法-训练策略-(模型蒸馏+融合)

三阶段：Reranker标注相关性 → 模型蒸馏 → 模型融合提升未蒸馏任务性能



方法-优化目标

多种负样本策略对比学习：批次内/难负样本/跨查询文档负样本 + 假负样本过滤

$$\mathcal{L}_{\text{retrieval}} = -\frac{1}{N} \sum_i \log \frac{e^{(s(q_i, d_i^+)/\tau)}}{Z_i},$$

$$Z_i = e^{(s(q_i, d_i^+)/\tau)} + \sum_k m_{ik} e^{(s(q_i, d_{i,k}^-)/\tau)} + \sum_{j \neq i} m_{ij} e^{(s(q_i, q_j)/\tau)} + \sum_{j \neq i} m_{ij} e^{(s(d_i^+, d_j)/\tau)} + \sum_{j \neq i} m_{ij} e^{(s(q_i, d_j)/\tau)}$$

- 多种负样本:

- 批次内其他文档作为负样本
- 查询自身的难负样本
- 查询与其他查询作为负样本
- 文档与其他文档作为负样本

$$m_{ij} = \begin{cases} 0, & \text{if } s_{ij} > s(q_i, d_i^+) + 0.1 \text{ or } d_j = d_i^+, \\ 1, & \text{otherwise,} \end{cases}$$

- 对于分类任务：只使用难负样本
- 对于高质量多模态数据：只使用批次内负样本与难负样本
- 假负样本过滤

方法-优化目标

CoSent: 细粒度相关性 | Distillation: 学习reranker | SFT: 生成式微调

CoSent Loss

$$\mathcal{L}_{\text{sts}} = \log \left(1 + \sum_{\hat{s}(q_i, d_j) > \hat{s}(q_m, d_n)} \exp \left(\frac{\cos(q_m, d_n) - \cos(q_i, d_j)}{\tau} \right) \right),$$

- 对 InfoNCE 的推广，适用于相关性标注更细粒度的时候

Distillation Loss

$$\mathcal{L}_{\text{distill}} = - \sum_{i=1}^{k+1} P_{\text{reranker}}(d_i | q) \log P_{\text{embedding}}(d_i | q),$$

- 基于交叉熵，让 embedding 模型学习 reranker 的相似度评估

SFT Loss

$$\mathcal{L}_{\text{reranking}} = - \log p(l | I, q, d),$$

- 基于生成式模型的监督微调优化目标训练 reranker

评估-多模态

MMEB-V2平均性能SOTA；图像检索、视频检索、视觉文档检索均SOTA

Model	Size	Image					Video					VisDoc					All
		CLS	QA	RET	GD	Overall	CLS	QA	RET	MRET	Overall	VDRv1	VDRv2	VR	OOD	Overall	
# of Datasets →		10	10	12	4	36	5	5	5	3	18	10	4	6	4	24	78
Open-Source Models																	
VLM2Vec (Jiang et al., 2025)	2B	58.7	49.3	65	72.9	59.7	33.4	30.5	20.6	30.7	28.6	49.8	13.5	51.8	48.2	44	47.7
VLM2Vec-V2 (Meng et al., 2025)	2B	62.9	56.3	69.5	77.3	64.9	39.3	34.3	28.8	36.8	34.6	75.5	44.9	79.4	62.2	69.2	59.2
GME (Zhang et al., 2025b)	2B	54.4	29.9	66.9	55.5	51.9	34.9	42.0	25.6	31.1	33.6	86.1	54.0	82.5	67.5	76.8	55.3
Ops-MM-embedding-v1 [†]	2B	68.1	65.1	69.2	80.9	69.0	53.6	55.6	41.8	33.7	47.6	76.4	53.2	77.6	64.2	70.8	64.6
RzenEmbed (Jian et al., 2025)	2B	68.5	66.3	74.5	90.3	72.3	50.4	49.7	46.6	38.9	47.3	87.1	55.1	87.2	43.4	74.5	67.2
VLM2Vec (Jiang et al., 2025)	8B	62.7	56.9	69.4	82.2	65.5	39.1	30.0	29.0	38.9	33.7	56.9	9.4	59.1	54.0	49.1	53.1
GME (Zhang et al., 2025b)	8B	57.7	34.7	71.2	59.3	56.0	37.4	50.4	28.4	37.0	38.4	89.4	55.6	85.0	68.3	79.3	59.1
Ops-MM-embedding-v1 [†]	8B	69.7	69.6	73.1	87.2	72.7	59.7	62.2	45.7	43.2	53.8	80.1	59.6	79.3	67.8	74.4	68.9
RzenEmbed (Jian et al., 2025)	8B	70.6	71.7	78.5	92.1	75.9	58.8	63.5	51.0	45.5	55.7	89.7	60.7	88.7	69.9	81.3	72.9
Closed-Source Models																	
IFM-TTE [†]	8B	76.7	78.5	74.6	89.3	77.9	60.5	67.9	51.7	54.9	59.2	85.2	71.5	92.7	53.3	79.5	74.1
Seed-1.6-embedding-0615 [†]	-	76.1	74.0	77.9	91.3	77.8	55.0	60.8	51.3	53.5	55.3	85.3	56.6	84.7	68.6	77.7	72.6
Seed-1.6-embedding-1215 [†]	-	75.0	74.9	79.3	89.0	78.0	85.2	66.7	59.1	54.8	67.7	90.0	60.3	90.0	70.7	82.2	76.9
Qwen3 VL Embedding Models																	
Qwen3-VL-Embedding-2B	2B	70.3	74.3	74.8	88.5	75.0	71.9	64.9	53.9	53.3	61.9	84.4	65.3	86.4	69.4	79.2	73.2
Qwen3-VL-Embedding-8B	8B	74.2	81.1	80.2	92.3	80.1	78.4	71.0	58.7	56.1	67.1	87.2	69.9	88.7	73.3	82.4	77.8

通用文本表征评估：MMTEB Qwen3-Embedding SOTA

Model	Size	Mean (Task)	Mean (Type)	Bitext Mining	Class- ification	Clus- tering	Inst. Retrieval	Multilabel Class.	Pair Class.	Rerank	Retrieval	STS
<i>Open-Source Models</i>												
KaLM-Embedding-Gemma3-12B-2511 (Zhao et al., 2025)	12B	72.3	62.5	83.8	77.9	55.8	5.5	33.0	84.7	67.3	75.7	79.0
llama-embed-nemotron-8b (Babakhin et al., 2025)	8B	69.5	61.1	81.7	73.2	54.4	10.8	29.9	84.0	67.8	68.7	79.4
NV-Embed-v2 Lee et al. (2024)	7B	56.3	49.6	57.8	57.3	40.8	1.0	18.6	78.9	63.8	56.7	71.1
GritLM-7B (Muennighoff et al., 2024)	7B	60.9	53.7	70.5	61.8	49.8	3.5	22.8	80.9	63.8	58.3	73.3
BGE-M3 (Chen et al., 2024)	0.6B	59.6	52.2	79.1	60.4	40.9	-3.1	20.1	80.8	62.8	54.6	74.1
multilingual-e5-large-instruct (Wang et al., 2024a)	0.6B	63.2	55.1	80.1	64.9	50.8	-0.4	22.9	80.9	62.6	57.1	76.8
gte-Qwen2-1.5B-instruct (Li et al., 2023)	1.5B	59.5	52.7	62.5	58.3	52.1	0.74	24.0	81.6	62.6	60.8	71.6
gte-Qwen2-7b-instruct (Li et al., 2023)	7B	62.5	55.9	73.9	61.6	52.8	4.9	25.5	85.1	65.6	60.1	74.0
Qwen3-Embedding-0.6B (Zhang et al., 2025c)	0.6B	64.3	56.0	72.2	66.8	52.3	5.1	24.6	80.8	61.4	64.6	76.2
Qwen3-Embedding-4B (Zhang et al., 2025c)	4B	69.5	60.9	79.4	72.3	57.2	11.6	26.8	85.1	65.1	69.6	80.9
Qwen3-Embedding-8B (Zhang et al., 2025c)	8B	70.6	61.7	80.9	74.0	57.7	10.1	28.7	86.4	65.6	70.9	81.1
<i>Closed-Source Models</i>												
text-embedding-3-large [†]	-	58.9	51.4	62.2	60.3	46.9	-2.7	22.0	79.2	63.9	59.3	71.7
Cohere-embed-multilingual-v3.0 [†]	-	61.1	53.2	70.5	63.0	46.9	-1.9	22.7	79.9	64.1	59.2	74.8
Gemini Embedding (Lee et al., 2025)	-	68.4	59.6	79.3	71.8	54.6	5.2	29.2	83.6	65.6	67.7	79.4
Seed-1.6-embedding-1215 [†]	-	70.3	61.3	78.7	76.8	56.8	-0.0	46.2	85.5	66.2	66.1	75.9
<i>Qwen3 VL Embedding Models</i>												
Qwen3-VL-Embeddng-2B	2B	63.9	55.8	69.5	65.9	52.5	3.9	26.1	78.5	64.8	67.1	74.3
Qwen3-VL-Embeddng-8B	8B	67.9	58.9	77.5	72.0	55.8	4.5	28.6	81.1	65.7	69.4	75.4

评估 - Reranker多模态检索

相较于Embedding模型进一步提升检索能力

Model	Size	MMEB-v2(Retrieval)				MMTEB(Retrieval)	JinaVDR	ViDoRe(v3)
		Avg	Image	Video	VisDoc			
Qwen3-VL-Embedding-2B	2B	73.4	74.8	53.6	79.2	68.1	71.0	52.9
jina-reranker-m0 [†]	2B	-	68.2	-	85.2	-	82.2	57.8
Qwen3-VL-Reranker-2B	2B	75.1	73.8	52.1	83.4	70.0	80.9	60.8
Qwen3-VL-Reranker-8B	8B	79.2	80.7	55.8	86.3	74.9	83.6	66.7


评估 - 视觉文档检索任务

Reranker在视觉文档任务上平均性能取得SOTA

Model	Size	VisRAG	VisDocOOD	Vidore-v1	Vidore-v2	Vidore-v3	JinaVDR	Avg
llama-nemoretriever-colembed-1b-v1 (Xu et al., 2025)	1B	82.4	65.6	90.5	62.1	55.5	66.4	70.4
llama-nemoretriever-colembed-3b-v1 (Xu et al., 2025)	3B	85.5	69.7	91.0	55.5	57.1	67.8	71.1
colnomic-embed-multimodal-3b (Team, 2025)	3B	86.8	71.0	89.7	63.5	56.4	77.6	74.2
colqwen2.5-v0.2 (Faysse et al., 2025)	3B	86.6	70.9	89.5	59.3	52.4	75.6	72.4
tomoro-colqwen3-embed-4b (Huang & Tan, 2025)	4B	89.0	75.9	90.6	66.0	60.2	76.2	76.5
colnomic-embed-multimodal-7b (Team, 2025)	7B	88.7	75.6	90.0	62.0	57.6	78.9	75.5
tomoro-colqwen3-embed-8b (Huang & Tan, 2025)	8B	90.2	76.8	90.8	67.7	61.6	79.2	77.7
<i>Qwen3 VL Embedding Models</i>								
Qwen3-VL-Embedding-2B	2B	86.3	74.3	84.4	65.3	52.9	71.0	72.2
Qwen3-VL-Embedding-8B	8B	88.8	78.3	87.2	69.9	59.0	76.9	76.7
<i>Qwen3 VL Reranking Models</i>								
Qwen3-VL-Ranker-2B	2B	89.7	77.5	90.3	62.5	60.8	80.9	77.0
Qwen3-VL-Ranker-8B	8B	91.1	80.4	91.7	71.3	66.7	83.6	80.8

评估-模型特性 - 维度截断与表征量化


支持截取维度与量化降低存储与计算开销（4-16倍存储成本降低）



- 模型性能随截取的维度下降而下降，但在最开始的时候下降平缓；
- 可以通过截取维度与表征量化来降低部署时的存储与计算开销

评估-模型特性 - 输入视觉粒度

模型性能随输入视觉粒度提高呈上升趋势，但存在边际效应



使用样例 - 文本类型任务

文本分类任务 / 文本检索任务

- 文本分类任务
 - 任务描述：将一篇新闻文章自动归类到预定义的主题类别中，如体育、科技、财经、娱乐等。
 - 输入：“昨日NBA总决赛迎来抢七大战，湖人队最终夺冠。”
 - 标签：体育
- 文本检索任务
 - 用户查询（Query）：“身份证到期了怎么办理换证”
 - 候选文本片段：
 - 身份证换领指南：本人携带旧身份证、户口本到户籍所在地派出所申请…
 - 如何补办丢失的学生证？需携带本人身份证到学校教务处填写申请表……
 - 护照有效期不足6个月怎么办？建议尽快申请换发新护照（需携带身份证）……
 - Top1：
文本 1：“身份证换领指南：本人携带旧身份证、户口本到户籍所在地派出所申请换证，可提前3个月办理。”

使用样例 - 图像类型任务

图像分类任务 / 图像检索任务

- 图像类任务

Instruct: 对给定的动物图片进行分类



Doc1: 猫 (0.95)

Doc2: 狗 (0.05)

- 图像检索任务

Instruct: 寻找符合给定描述的图片

Query:
一个戴着红色帽子的人在
泥泞的道路上骑车



0.7




0.2

使用样例 - 视频类型任务

视频分类任务 / 视频检索任务

- 视频分类任务

Instruct: 对给定的电视节目进行分类



Doc1: 体育赛事 (0.8)

Doc2: 新闻报道 (0.1)


- 视频检索任务

Instruct: 寻找符合给定描述的视频

Query: 棒球手击中了棒球



0.9



0.1

使用样例 - 视觉文档检索

视觉文档检索任务 (OCR Free, 更好的图像理解能力)

Query: 美国第三季度营收
Top1:



垂域多模态检索

短视频 / 电商 / 安防 等垂直领域应用

• 电商

Query: 北欧极简风格的浅灰色布艺客厅沙发



现代沙发 - 客厅

现代沙发, 画面展现了客厅、室内设计、家具、灯等元素, 构图精致色彩丰富

54.7%



现代沙发 - 客厅

现代沙发, 画面展现了客厅、长椅、内部的、房间等元素, 构图精致色彩丰富

53.4%



现代沙发 - 客厅

现代沙发, 画面展现了客厅、椅子、沙发、长椅等元素, 构图精致色彩丰富

52.6%



现代沙发 - 卧室

现代沙发, 画面展现了卧室、橱柜、床、房间等元素, 构图精致色彩丰富

46.6%

• 安防


Query: 右下角的白猫



• 短视频

Query: 厨师在锅中翻炒的烹饪过程片段

1 美食烹饪 - cook



美食烹饪短视频, 内容包含cook, kitchen, chef, food等元素, 时长19秒

美食 cook kitchen

53.7%

2 美食烹饪 - onion




美食烹饪短视频, 内容包含onion, cooking, kitchen, cookhouse等元素, 时长15秒

美食 onion cooking



46.7%

如何使用

ModelScope / HuggingFace / GitHub / API



Hugging Face



统一多模态表征与排序：架构、数据、训练、性能、开源

01 统一多模态架构

基于 Qwen3-VL 构建 Embedding 与 Reranker，支持文本、图像、视频、视觉文档

02 大规模多模态训练

3 亿多模态数据，三阶段渐进式训练：对比预训练 → 多任务联合学习 → 蒸馏与融合

03 全面 SOTA 性能

MMEB-V2、MMTEB 等多项评估均取得最佳性能，视觉文档检索优势显著

04 开源可用

ModelScope / HuggingFace / GitHub / API 多渠道发布，支持维度截断与量化降低部署成本

统一多模态表征与排序

01 全模态统一：文本，图像，视频，音频


02 效果/效率持续优化

03 更多领域覆盖：自动驾驶，医疗图像，多模态记忆，...

04 为人类检索场景服务-> 为Agent 场景服务

THANKS

感谢聆听



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

