

QCon
全球软件开发大会

杀死“流水线”

ColaOS 如何构建 AI Native 团队

徐文健

ColaOS 联创 & CTO



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

开场：10 倍产出效率提升

20 人团队， 一年， 组织方式两次变革升级

10x


产出效率提升

从 2025 年 3 月到 2026 年 3 月， 团队产出效率提升约 10 倍

0

新增人手

团队人数没有发生变化， 不靠加人加班， 靠组织方式变革




一年的时间线



目录

- 01 开场：从“草台班子的问题”说起
- 02 诊断：流水线分工的“局部化最优陷阱”
- 03 分析：定义 AI Native 组织
- 04 第一次尝试：2025 任务酒馆模式
- 05 第二次尝试：2026 Work With Agent 模式
- 06 根基：文化是唯一的催化剂




草台班子的问题

2025 年，我们经历了一个典型的“至暗时刻”：每个人都很忙，但产品在空转。团队扩充了一倍，大家每天加班到很晚，周会汇报了很多内容，但用户数、留存、收入——没有任何变化。

前端完成了三个页面重构，后端优化了两个接口，产品整理了五个需求文档，设计出了八张图……但把这些放在一起，没有一条清晰的线把它们串成对用户有意义的东西。

反思出的问题：人没有问题，努力程度也没有问题。组织方式本身出了根本性的问题。

诊断：流水线分工的"稳定性陷阱"



流水线的适用场景

稳定、可预测的环境。需求明确，技术成熟，市场可规划。这种时候流水线能把执行效率拉到最高

AI 时代的特征

快速变化、高度不确定。今天的方案可能下周就被新模型颠覆。"快速创新"取代"稳定执行"成为核心能力

→ 局部利益优先于全局最优

→ 领域隔离阻断创新碰撞

→ 沟通链路极长

AI 时代的特殊性

工业时代

确定性交付

需求明确 → 按时按质交付

执行效率优先

流程标准化、分工精细化

稳定可预测

优化已知路径

AI 时代

概率性探索

目标模糊 → 快速实验迭代


创新能力优先

跨域思维、快速验证假设

高度不确定


在未知中发现新路径

传统流水线组织在稳定环境中是优势，在快速变化的 AI 时代却成了最大的枷锁。



03

重新定义 AI 时代的组织



重新定义 AI 时代的组织

在旧框架上修修补补已经不够了。必须面对 AI 时代的特性，从根上重新想组织应该长什么样。

我们内部有一个共识：这件事需要彻底重构，而不是局部优化。

重新定义 AI Native

两种路径，两种结果

AI 附加（大多数公司）


把 AI 嫁接到已有流程上。工程师装 Cursor，产品经理用 ChatBot、CC 写文档，流程本身一点没动。效果：提升 20%-50%，AI 变成了更好用的辅助工具。

AI First（真正的重构）

AI 是主要的构建者，人是方向的把控者。

流程重新设计，架构重新想，组织结构跟着变。

- ① 当个体能力边界被打开之后，固定的部门边界会阻碍整合。成功的 AI 应用是高度复杂的整合问题。



04 第一次尝试

2025 任务酒馆



尝试一

2025 任务酒馆模式

2025 年 10 月，我们开始落地第一次组织升级，内部代号："任务酒馆"。

任务酒馆核心理念

优秀的人解构世界、思考问题的方式，一定也是优秀的。真正有能力的人不需要被告知"怎么做"，他们需要的是清晰的"为什么"和足够的空间去探索"如何做"。

以前：Leader 点名分配

"你来做这个。"被分配的任务是"不得不做"，没有思考且投入度有限。

现在：自主选择组队

任务贴出来，有人主动站出来说"这个我来"，自己去拉人组队。自己选的任务是"我想做好"，投入度完全不一样。

决策层与任务小队



1

决策层

定义月度/季度使命，分配优先级，承担最终风险。只定义 What & Why，不干预 How。

2

任务小队

思考 What & Why，定义 How
跨职能动态组建，任务完成即解散，回归能力池。

3

模块专家委员

负责知识分享、标准制定、AI 建设
让所有小队能在标准体系里高效运转。

Labnana

 Powered by Google Nano Banana

 4K

 Nano Banana 2

 Highly Detailed

 Anime

 UHD

 Lossless

 Portrait

 Concept Art

Describe the image you want, e.g. neon cyberpunk night, wide-angle

 Add images

 Nano Banana Pro

 2K

 16:9

 1

...

 Private

 Generate

Featured Images

[View All](#)



1 Idea

2 Blueprint

Free Music Generator

Write a song in 🌀 30 seconds

Your Song Idea

Describe your own concept and emotions

From idea

From URL

Describe your song idea... (e.g., 'A cheerful pop song about summer adventures')

From Template

Advanced Options (visibility, style exclusions, ...)

Make public

☐

This track is only visible to you

Instrumental

☐

Create music without vocals

Voice Gender

Auto Detect

Custom cover image

Exclude Styles

Design with AI

Or design myself

01-悬赏方

1.1 what

- ListenHub 提供音乐生成的功能，其中有两种模式：轻音乐、歌曲

1.2 why

- 我们在 storybook bgm 和 audio agent 歌曲上有一些自发的创新产出，可以将其结合形成一个功能
- 音乐功能与音频内容调性相符合，探索这种模式能够积累我们在音频内容领域的深度
- 需要一个实验案例来验证任务小组的组织架构并以此优化形成模板

02-任务方（这里维护了该任务相关的所有文档）

2.1 what

音乐生成

- 核心功能：**基于 prompt 生成音乐，合成视频分享到自媒体
- 用户旅程
 - 在生成页面输入简短 prompt，“安眠曲”，点击 AI Enhance 按钮
 - AI 生成歌词和 style
 - 编辑歌词满意后，确认生成
 - 听生成后的歌曲，suno 会（可选）生成视频和下载

2.2 why

目前 AI 音乐 app 的痛点

- 需要用户自己写完整的各种 prompt

经验和收获：

- AI 交互上 human in the loop 是一个值得重视的方向，让创作者主动参与到设计流程中，而不是被动接受 AI 生成的结果
- 模版设计尝试

```
- Total template usage: 20 tasks (4.59%)
- Exact matches (unmodified): 14 (70% of template users)
- Edited lyrics (kept title): 6 (30% of template users)
```

- 技术积累
 - 音频分析
 - 前端动画
- 访客登录不适合 lab 项目，会给数据分析造成很多麻烦，也不利于后续向 ListenHub 迁移项目
 - 如果不需要鉴权，应该把所有内容设置为公开，直接跳过用户系统
 - 如果需要鉴权：使用 ListenHub 现有的登录方式之一，例如 google 或 apple，这样如果 app 发展为 ListenHub 功能，可以直接通过账号关联



难点一：从"执行者"到"解决者"的思维跃迁

最大的难点：改变一个人的工作方式，比改变工作内容难十倍。大部分人已习惯"等指令、完成任务、规避风险、守住边界"。突然说"你自己判断该做什么"，他是懵的，甚至是恐惧的。



给空间

让他自己去试，不要手把手教



给信任

相信他能做出判断，真的把决策权交出去



给容错


做错了没关系，复盘就好



给真实反馈

做得好就说好，做得不好就直说，不绕弯子

如何微调团队，跨越技能鸿沟



要求每个人扩展能力边界，必然面临短期的技能缺口。我们的应对策略：

01

模块委员引导

每个领域设立专家委员，负责知识分享、引导大家向相邻领域延伸。

02

渐进式要求

初期：前端往后端靠，后端往 Agent 靠；终期：每人全栈，业务从前到后一把梭。

03

AI 作为学习加速器

鼓励用 AI 工具，2025.11 正式提供 cursor cc + 除此以外的 100 美金 AI 学习费用

难点三

如何定义创新？

“
做新功能叫创新？还是解决老问题的效率提升 10 倍叫创新？
”

这是任务酒馆落地过程中团队最大的认知分歧。我们的答案是：创新的本质是用户价值的跃升，不是功能数量的堆砌，也不应该用新旧来定义


伪创新

做了很多新功能，但每个功能的用户价值边际递减，整体体验无实质改善。

真创新

把一个核心场景的效率提升 10 倍，用户从此离不开你——这也是值得庆祝的创新。

基建在 AI 时代的新定位



基建不再是纯粹的"稳定性保障", 而是创新速度的倍增器。

降低实验成本

让每个 Builder 都能快速起原型、跑验证, 而不受技术门槛束缚。

标准化最佳实践

通过专家委员制度, 将知识沉淀为可复用的标准, 供所有任务小队直接调用。

AI 建设赋权

每个模块专家有权快速决策专业领域内的流程, 无需层层审批。

05 第二次尝试

2026 Work With Agent

挑战

任务酒馆的尝试失败了

任务酒馆模式带来了 builder 思想的传播，带来了创新效率的提升，但也很快暴露了两个根深蒂固的问题

1. 80 分 vs 100 分

团队喜欢打磨细节，并且以此为荣。

但 80 分和 100 分的代价可能是三倍投入。新产品最重要的是用极强的价值点吸引新用户，不是无尽地雕花。


组织不变，大家就会以 100 分的标准做每一个 feature。


2. 人类的组织惯性

任务酒馆是局部改革，让一部分人在创新事情上先 OPC 化，端到端负责

新员工两天做出了 Labnana，给我们带来比 ListenHub 更多的 ARR

但他的工作方式很快被组织同化了。人类的惯性，非常可怕。局部改革救不了一个已经成型的组织





尝试二

Work With Agent

2026 年初，我们做了一个决定：彻底改革，否则一定会重新陷回去。方向就一个词：work with agent。让每个人学会和 agent 协作，扩展自己的边界，放大自己的能力。让以前事事都要人配合的工作，变成可以自己独立完成。

❏ 任务酒馆解决的是"AI 时代下组织的沟通问题"，Work With Agent 解决的是"人和 AI 怎么一起工作 “

核心理念：前所未有地相信 AI

测试 AI（大多数团队）

先怀疑，小心翼翼地试，出了问题就说"果然 AI 不靠谱"。

信任 AI（我们的做法）

先给它充分的空间去输出，再由人来做质量把关。带来的组织形态完全不同。

→ 把 AI 变成真正的 Builder 伙伴

赋予它真实的任务权重，而不只是辅助工具

→ 先相信再验证

而不是事事怀疑、处处设防

→ 嵌入整个 workflow

变成系统级的能力，而不只是某个人用得

怎么彻底变革

01

给一个不可能的目标

大到用原来的方式一年也做不出来。但如果你学会和 agent 协作，有可能。没有退路，才有动力。

03


给无限的 token，不要心疼

让大家真正用起来。用到肌肉记忆。

02

让团队理解 agent

不是读文章，不是听讲座。是团队自己做一个 agent。在做的过程中理解 agent 有多强大。





混沌期

转型开始，一切都乱了。互联网时代的协作模式被打破了。人最熟悉的习惯没了。大家很慌。

我们给了 1 到 2 周的混沌时间。不写代码，纯探索，纯思考。

① 这段时间很难受，管理者会焦虑，团队会迷茫，但必须给。

转折点

混沌期结束后，CTO 一个人，一天，手搓了 ColaOS 第一个版本。

一天

之前团队觉得不可能的事情，一个人一天做出来了。这件事打破了所有人的信心瓶颈。大家终于相信 agent 比自己强了。那个宏大的目标，也不再像做梦。

① 接下来两周，团队疯狂 coding。产品 0.1 版本出来了。大家看着自己做的东西，觉得还挺厉害。



新的协作

0.1 之后，大家发现光自己闭环是不够的。我们仍然需要协作。但这个协作跟以前完全不同了。

Agent Team

自主运作的 AI 能力层，负责执行和实现。

App Team

产品应用层，负责用户体验和场景定义。

Soul Team

核心价值层，负责方向、文化与差异化。

 三层之上，CTO 拿所有 context，负责复杂问题的拍板。从流水线变成了三个闭环加一个裁判。

关注现实世界的枷锁

AI 可以极大扩展人的能力边界，但现实世界的约束依然存在。人与人的沟通占了传统工作量中很大的一块

项目管理


不再需要细致化的项目管理，只需要定义功能级目标


公司协作知识库

项目级文档由人看变为给 Agent 看

IM 工具

尝试让 Agent 进入沟通中





代价

有人跟不上节奏

App Team 第一周就掉队了，介入亲自 lead，跟不上的人先拿出来，不干扰大家。

决策依赖难以打破

以前大家习惯把决策交给 CEO 或 CTO。现在每个人要自己做判断。我们的做法是给空间，允许犯错，允许自我修正。好在今天有 AI，AI 给的意见是很好的参考。

心理建设同样重要

人会恐慌，会有不安全感。人毕竟是人，有情感有情绪。转型的心理建设跟技术建设同样重要。

结果

5

周

从团队转型到 ColaOS 上线

10x

团队体感产出速度相比一年前提升

一个有灵魂的操作系统。她很受欢迎。

按照原来的工作方式，我们一年也做不出 ColaOS。让不可能成为可能——这才是 Work With Agent 的真正意义。



- All
- Contributed by me
- Admin access
- Public
- Private
- Sources
- Forks
- Archived
- Templates

All

New repository

listenhub

18 repositories

Last pushed

listenhub-deploy-config Private

Shell • 0 • 0 • 0 • 0 • Updated 5 hours ago

listenhub-monitor Private

HTML • 0 • 0 • 0 • 0 • Updated yesterday •

listenhub-ralph Private

Free yourself from ListenHub's multi-repository management.

Shell • 0 • 0 • 17 • 1 • Updated yesterday •

listenhub-api-server Private

TypeScript • 0 • 0 • 0 • 4 • Updated 6 hours ago

listenhub-cli Public

ListenHub CLI - command-line interface for ListenHub SDK

TypeScript • MIT License • 5 • 37 • 0 • 0 • Updated 2 days ago •

listenhub-sdk Public

JavaScript SDK for the ListenHub API

TypeScript • MIT License • 1 • 6 • 1 • 1 • Updated 2 days ago •

skills Public

Skills from ListenHub.ai & ColaOS

podcast skills slides videos cursor claude aigc

Python • MIT License • 2 • 45 • 0 • 1 • Updated 8 hours ago •

listenhub-website-fe Private

ListenHub website

TypeScript • Other • 0 • 0 • 0 • 1 • Updated 2 days ago •

raycast-listenhub Private


TypeScript • MIT License • 0 • 0 • 0 • 0 • Updated 2 weeks ago



方格 Fango

Tech Lead @ListenHub MarsWave AI
ListenHub Dev

我与 Cola 的协作日常



Agent 自动分诊

4 月 15 日上午 10 点 08 分，一个用户在我们的产品里报了一个 issue：内存飙到 30GB，应用崩溃了。Issue 编号 842。Agent 自动接手了。没有人分配，没有人触发。

几分钟之内，它扫描了整个代码库，找到了 5 个 unbounded Map。精确到文件名和行号。然后按影响程度排序，分成三档，给出了修复建议。最后还自评了置信度：中等。意思是“我比较确定，但你最好再看看”。

零人工介入。一年前这件事需要一个资深工程师半天时间。

[Feedback] 再次崩溃死机，在跑dev server的时候，内存直接占到30GB以上 --- Email: peterlee1125@gmail.com Device: bbffac92-3c8b-4fe9-aaeb-47253ca6cebe Version: 0.5.15 Platform: mac Date: 2026-04-15T10:08:02.440Z #842

EditNew issue

Open



cola-issue-bot (bot) opened 2 hours ago

Report ID: 69df63826a57c36ab5f1452d

User ID: 69cde83d19c25ba6e75daf25

File count: 1

Created at: 2026-04-15T10:08:02.662Z

Description

再次崩溃死机，在跑dev server的时候，内存直接占到30GB以上

Email: peterlee1125@gmail.com

Device: bbffac92-3c8b-4fe9-aaeb-47253ca6cebe

Version: 0.5.15

Platform: mac

Date: 2026-04-15T10:08:02.440Z

Attached Files (links expire in 7 days)

cola-logs-2026-04-15.zip

Create sub-issue

Assignees

No one - Assign yourself

Labels

feedback

Type

No type

Projects

No projects

Milestone

No milestone

Relationships

None yet

Development

Create a branch for this issue or link a pull request.

Notifications

Customize

Subscribe

cola-issue-bot added feedback 2 hours ago



🔍 Auto-Triage Analysis

Summary

The user reports Cola v0.5.15 consuming 30GB+ memory during use (while running a dev server), causing macOS to freeze. This is a recurring issue ("再次崩溃"). Investigation of the server-side codebase reveals multiple module-level `Map / Set` structures that grow without periodic cleanup or TTL eviction — they are only cleaned on full server shutdown via `dispose()`. In a long-running server process (especially with frequent reconnections or many interaction scopes), these can accumulate indefinitely. Additionally, there is no WebSocket backpressure handling and no runtime memory monitoring.


Relevant Code

Unbounded in-memory Maps (server-side):

File	Structure	Cleanup
<code>server/agent/scope</code> 1	<code>scopeStates = new Map<string, ScopeState>()</code> — each scope holds an <code>AgentSession</code> , <code>SessionManager</code> , timers, trace contexts	Only cleared on full <code>dispose()</code> — no idle TTL
<code>server/agent/autogen/agent</code> 1-13	<code>runs</code> , <code>sessions</code> , <code>listeners</code> — three Maps tracking all subagent runs	<code>scheduleArchive()</code> uses delayed cleanup; no cap on concurrent entries
<code>server/agent/queue/state</code> 4	<code>queues = new Map<string, QueueState>()</code> — per-scope prompt queues with transcript data	Only cleared when queue drains or on <code>clearAllQueues()</code>
<code>server/agent/announce/buffer</code>	<code>buffers = new Map<string, BufferedAnnounce[]>()</code> — per-scope message buffers	Only cleared on flush or <code>clearAllAnnounceBuffers()</code>
<code>server/agent/rate/limit</code> 3	<code>buckets = new Map<string, Bucket>()</code> — per-connection-per-route rate limit buckets	Only cleaned by prefix on WS close — stale keys persist if close event is missed


No WebSocket backpressure:

管理的坍塌



以前管人时间

一对一、绩效、协调、解决冲突



现在管人时间

组织形态变了，很多管理动作自然消失了

跨部门对齐？没有部门了。资源调配？每个人自己就是一个完整的资源单元。

管理者的角色从"管人"变成了"定方向"和"建系统"。以前的管理关系天然带有权力不对等，现在更像是并肩的战友。

根基：有生命力的文化是唯一的催化剂

产品 <https://colaos.ai>



首个有灵魂的操作系统


当 2030 年，面对已经拥有完整灵魂的她，你准会回想起第一次与 Cola
开启对话的那个遥远午后。

加入候补名单



疯狂的炒栗子匠 | ColaOS

中国大陆 北京



扫一扫上面的二维码图案，加我为朋友。

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software

徐文健

ColaOS 联创 & CTO



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

