

具身智能 Agent: 从VLA/VA 模型到物理世界交互的落地实践

李元庆

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人


AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

家庭机器人的“理想”与“现实”



离身智能能力

- 语言理解
- 知识广度
- 视觉识别
- 推理能力

“还不错”

具身智能能力

- 物理交互
- 鲁棒性
- 场景适应
- 持续学习

“还不行”

家庭场景的“四座大山”

交互的多模态与情感化

非结构化的室内环境

“需要被照顾的电子设备”

隐形的需求与意图

出厂即定型，无法真的成长

家庭场景中，机器人的价值不在于它出厂时会多少技能，而在于它能否持续学习这个家庭的习惯、预判需求、并安全地融入日常生活。这要求我们从根本上改变设计逻辑：从“交付功能”转向“交付成长能力”

从“功能固化”到“持续进化”的最新技术栈

Rule-Based

Perception

Navigation

基于规划的Manipulation

- Rules/Constraints


Learning-Based: Modular-Based

Reasoning/AI/Memory/Verification/Locomotion/Evolution

Manipulation: Learning with Auxiliary Tasks

Agent

- OpenClaw
- Claude Code



Skills

- RL: HIL-SERL
- Diffusion Policy

显式特征


Learning-Based: End-to-End

Latent隐式特征
信息复用
模型能力


- NVIDIA WAM
- Physical Intelligence
- Helix

References

- a) World Action Models are Zero-shot Policies
- b) RL Token: Bootstrapping Online RL with Vision-Language-Action Models
- c) A Vision-Language-Action Model for Generalist Humanoid Control




技术层拓展



Learning with Auxiliary Tasks

辅助任务学习是一类训练范式，它在核心操作任务目标之外，引入额外的自监督或弱监督目标，以强化策略学习。这些辅助目标促使模型学习环境、动作与目标的结构化表征，从而提升样本效率、泛化能力与鲁棒性。



主要路径

世界模型

图像/视频预测

对比学习

掩码重建

文本驱动
目标提取

视觉驱动
目标提取

OpenClaw 技术架构

大模型 LLM

understand -> task -> decide

工具 Tools

read/write Shell web calender 邮箱 scripts

记忆 Memory

context state history

调度 Scheduler

轮询 任务调度 automation


通道 Channels

Telegram 飞书 Discord

■ 执行大脑：Pi Agent 与 技能系统



■ 安全与部署层




■ 连接生态：多渠道通信（Channels）



■ 执行终端：Nodes & Apps



Gateway 网关：控制平面





Agent核心架构与优势

■ 三大机制

Corn定时调度机制 = 计划执行能力

支持一次性提醒、周期性任务、标准Corn表达。无需手动配置，可根据对话上下文，主动给自己安排任务

Heartbeat心跳机制 = 主观能动性

Heartbeat.md 文件记录了待办事项和周期性检查任务，基于系统定期自动发送的隐形信息，Agent扫描上下文和清单，时刻处于“待命”状态

Soul.md机制 = Personality 性格

Soul.md 文件可定义Agent的语气、边界和优先级

■ Multiagent架构

多Agent隔离与路由

每个 Agent 都拥有自己的独立区域，拥有独立的工作区、会话记录和记忆库；每个 Agent 只能访问属于自己的对话流，同一个 Gateway 上可同时运行多个专职 Agent。

Agent间协作会话工具

sessions_list: 查看当前有哪些活跃的会话
sessions_send: 向另一个会话发送消息
sessions_history: 查阅其他会话的历史记录
sessions_spawn: 创建新会话来委派具体任务

多样化会话排队模式

Sequential: 串行模式 Concurrent: 并发模式
Collect: 收集模式 Steer: 干预模式
Followup: 跟进模式

■ Pi Agent Core

极简Agent

无需冗长系统提示词和复杂规划模块，<1000 tokens，内置read、write、edit、bash 四个核心工具，覆盖 90% 的需求，其bash工具支持自我调用。**运行逻辑**：入队与加锁→构建提示词→调用模型（含回退）→处理响应


架构分层与核心逻辑

分层架构：Applications（应用层）→ Core（核心层：pi-agent-core）→ Foundation（基础层：pi-ai）
核心运行5个文件：types.ts、agent-loop.ts、agent.ts、proxy.ts、index.ts

多双层while循环&流式应答

- 外层循环：FollowUp 消息驱动，实现任务连续推进；
- 内层循环：ToolCall 和 Steering 消息驱动，“注入消息 → 调用 LLM → 执行工具 → 结果反馈”闭环；
- Steering 中断机制
- 流式应答：最晚转换，上下文实时更新

Robot Agent 流程图



HIL-SERL系统的“Human-in-the-loop”强化学习

HIL-SERL操作策略系统

1. 通过遥控操作机器人收集正负样本，并训练一个二元奖励分类器
2. 收集一小组演示数据，这些数据在强化学习训练开始时被添加到演示缓冲区
3. 在线训练期间，使用二元分类器作为稀疏奖励信号，并提供人类干预。初期，提供更频繁的干预，以演示从各种状态解决任务的方法，并防止机器人执行不良行为。随着策略成功率提高和循环时间加快，逐渐减少干预的次数

核心原理：

1. 样本高效的离线强化学习（RLPD）
2. 稀疏奖励 + 二分类奖励器（告别复杂奖励工程）
3. Human-in-the-Loop 动态干预机制
4. 感知与状态表示优化
5. 数据与流程优化

关键机制：

奖励设计、RL算法（RLPD）、系统设计（模块化、高效）、训练流程（渐进式自主）




Figure 2: Overview of HIL-SERL. This figure illustrates the architecture of HIL-SERL, which comprises three primary components: the actor process, the learner process, and replay buffers. These components communicate asynchronously to facilitate efficient data flow. The actor process receives updated policy parameters from the learner process, interacts with the environment, and sends collected interaction data to the replay buffers. The environment is modular, supporting various external devices and multiple robotic arms. A human operator can intervene via teleoperation tools, such as a SpaceMouse. The learner process samples data evenly from two replay buffers and updates the policy using RLPD. When gripper control is required, a grasp critic is additionally trained with DQN.

结果 在RAM插入任务中，仅32,000次RL转换即可达97%准确率，动态任务如翻转物体展示了预测控制的潜力。相比纯模仿学习，提升了适应性、速度。

结论 HIL可桥接模拟与现实差距，推动机器人向人类级灵巧性发展，适用于工业组装、家庭服务等领域。未来可扩展到多模态输入或零样本学习。

HIL-SERL 系统核心组件

• Actor process

Step: 现实环境，10Hz作为动作执行与观测更新的频率；默认RL agent自己出action，操作员可以随时介入，介入一个固定的动作序列长度，然后将控制权交回

Reward: 稀疏奖励，只判断任务是否成功，成功给1，不成功为0

Reset: 在不同的任务中，采用人工操作或脚本，实现环境的随机化重置，以保证泛化性

• Learner process

在 GPU 上持续训练，使用 RLPD 算法（高效离线 RL）优化策略，均匀采样“人类示范数据”和“机器人交互数据”

网络设计：用一对actor-critic网络来训练出关节动作的策略，再单用DQN去训练夹爪开合的策略

• 双Replay buffer

采集人类示范数据放入Demo Buffer；训练过程，机器人与环境交互数据放入RL Buffer，其中由策略网络推理得到的动作产生的数据，对应Policy Transitions，其中人类操作员介入数据存入Demo Buffer

网络更新：从RL Buffer和Demo Buffer里平等地采样，拿到Training Batch，用于更新网络

Physical Intelligence 全新机器人在线学习架构

■ 大模型负责感知和通用知识，小网络负责在线适应和精细控制

第一层：信息压缩层，即RL Token

- 小型encoder-decoder transformer




Fig. 2: Details on RL token extraction. RLT adds an encoder-decoder transformer to a pretrained VLA. It produces a compressed embedding of the VLA representation (the RL token). This representation then enables data and parameter efficient fine-tuning during online RL.

阶段一：表示学习

阶段二：在线RL

第二层：决策执行层，即轻量级 Actor-Critic

- 输入：RL token VLA 生成的 Reference Action
- 限制：Actor被BC正则化约束，确保在线RL的局部优化
- 优化：训练时随机将部分batch的参考动作置零，保障Actor独立的动作生成能力




Fig. 1: Our method introduces an “RL token” into the VLA by training an encoder and decoder to produce a compact and meaningful representation from a VLA’s internal features. The extracted representation is then used to train lightweight actor-critic networks with sample-efficient online RL, enabling very precise tasks to be fine-tuned with a few hours or even minutes of robot experience.

结果：

- 关键阶段执行速度提升最高 3 倍；
- 拧螺丝全任务成功率从20%到65%；
- 扎扎带从接近0到60%；
- 以太网插入任务只用了约 5 分钟的关键阶段数据就超过了基础策略

第三层：时间抽象层，即动作块级 RL

- RL 策略操作在动作块（action chunk）级别，减少决策次数
- 动作块子采样（subsampling）优化，transition增加，数据利用率提升

NVIDIA 世界动作模型WAM: DreamZero

WAM核心理念

先视频预测 “会变成什么样” 作为 “隐式视觉规划器”，再根据视觉规划生成对应机器人动作

联合建模：建立在预训练的视频扩散模型之上，同时预测未来的视频帧和对应的动作

物理先验：通过学习视频，继承视频数据中的物理动力学常识，知道 “世界该如何演变”，从而推导出 “该如何执行动作”

数据效率：由于具备这种物理直觉，无需大量重复演示，既可从多样化、非重复的异构数据中有效学习



Figure 1: Overview. By jointly predicting video and action, World Action Models (WAMs) inherit world physics priors that enable 1) effective learning from diverse, non-repetitive data, 2) open-world generalization, 3) cross-embodiment learning from video-only data, and 4) few-shot adaptation to new robots.


维度	模型	模型
输入输出	观察→动作（直接映射）	观察 语言→动作（联合预测）
物理学习	无，依赖 静态语义先验	从视频扩散模型继承时空 物理先验
数据利用	依赖重复、结构化任务演示	利用异构、多样化、非重复数据
泛化能力	语义 物体泛化	零样本泛化，任务 环境 形态
迁移能力	依赖动作标注数据，效率低	支持 无标注数据迁移

14B参数自回归扩散 Transformer (DiT)

- 输入端：接收当前的视觉观测、语言指令、机器人本体感知状态
- 核心处理：因果DiT模块，负责联合去噪
- 输出端：双解码器，生成未来视觉帧与可执行动作序列

Joint Flow Matching流匹配与联合去噪

- 输入：双模态（视频、动作）噪声联合建模
- 输出：联合速度场预测



推理加速与闭环控制

- 自回归架构设计：天然适合利用 KV Cache（键值缓存）技术来加速推理
- 38 倍的推理加速&7Hz 的实时闭环控制：系统、实现、模型三层面优化。并行化+缓存优化推理吞吐量；编译器+量化+内核优化，降低硬件开销；DreamZero-Flash，解耦噪声调度实现单步去噪

结果

■ 泛化能力提升超2倍，实现跨环境、跨任务、跨具身泛化
对比VLA模型：平均任务进度提升超过2倍

■ 从多样化异构数据中高效学习，打破对重复演示的依赖
对比VLA模型：平均任务进度提升10%

■ 跨具身迁移能力，纯视频学习+小样本适配新机器人
仅需30 分钟的无标注玩耍数据，就能保留零样本泛化能力

Ye, S., Ge, Y., Zheng, K., Gao, S., Yu, S., Kurian, G., ... & Jang, J. (2026). World action models are zero-shot policies. arXiv preprint arXiv:2602.15922.

一个目标，三个聚焦

在探索中寻找融合点，在家庭中验证有效性

目标：让机器人拥有持续成长能力

从“功能堆砌”
转向“场景深耕”

从“技术驱动”
转向“数据驱动”

从“单机智能”
转向“家庭共生”

期待同合作伙伴与开发者一道，构建开放的进化生态，
让每一台部署的机器人，都成为整个系统成长的贡献者

THANKS

大模型正在重新定义软件



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

