

QCon
全球软件开发大会

淘宝闪购：从骑手智能助手业务落地到 Agent 平台化建设

李克华

淘宝闪购-高级技术专家



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日


- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

- 01 业务介绍
- 02 破局思路
- 03 实战过程
- 04 实战趟坑经验
- 05 未来规划

01 业务介绍

业务背景：淘宝闪购-骑手配送全景





业务背景：业务痛点、难点

For 骑手

- 1、“手累”：操作app极不方便；
- 2、“脑累”：业务复杂，规则多，记不住；
- 3、“不安全”：骑行中操作app不安全；

For 客服

- 1、异常进线多；
- 2、判责审核工作量大；

For 技术


- 1、“能力烟囱”：各业务自建，能力不一；
- 2、“基建不适配”：通用agent平台，不支持时空能力

两核心矛盾： 业务高速增长 VS 骑手配送效率、体验下滑
客服供给 无法匹配 骑手爆发式咨询需求

传统方案：

- 1、“加人”：成本高、周期长；
- 2、“加规则引擎”：灵活性差、无法覆盖长尾场景；
- 3、“关键字检索”：准确率低，体验差

项目结果



总结: 解决一个问题, 进化到赋能一类业务

02

破题思路

破题思路：AI赋能、分层破题



核心目标：降工单、提效率、优体验、降成本

核心关键词：“分层”、“匹配”

避坑：“杀鸡用牛刀”、“小马拉大车”

落地节奏：渐进式求解，有点->面->体

阶段一：搭建答疑助手

单点突破-规则答疑

- 1、提升知识问答准确率；
- 2、提高问答助手服务性能；

体验&提效-解放骑手双手

- 1、搭建语音助手，直接操作工具；
- 2、突破噪音、方言等限制；

阶段二、万能客服

场景协同-复杂问题求解

- 1、构建领域专家；
- 2、协同推进专家subagent建设

深入业务-探索llm能力边界

- 1、AI判责-降本、降cpo
- 2、探索新的研发范式

阶段三、agent平台化

平台化提效

- 1、平台能力构建；
- 2、不可能三角挑战；

领域智能

- 1、更懂物流业务
- 2、时空智能；

平台智能

- 1、创建智能
- 2、进化智能；

03

解题过程

平台实战1：知识问答助手-解决高频业务规则问答




难题：准确率vs性能vs成本

策略：2+4 组合策略

总结：解决“查的准”“查的快”

平台实战1：知识问答助手-语音输入，解决骑手“动口不动手”



难题：方言、噪音、暴雨

策略：三层防御体系

成果：骑手动口不动手、安全高效



平台实战2：构建万能客服SubAgent，解决复杂问题解决



难题：三坑（效率、认知、资源）

策略：合作共建

总结：业务+技术同频

平台实战2：万能客服-骑手AI判责-公平公正判罚



难题：性能、可解释性

策略：异步化、推理引擎、白盒模块

总结：业务*技术双向奔赴

平台实战3: agent平台化-基础建设-效能&不可能三角



难题: 通用、易用、可定制

策略: 分层抽象、分级赋能

总结: 作坊式->工业流水线

平台实战3: agent平台化建设-即时物流行业难题



难题: 数据噪音、时空语义对齐

策略: 清洗噪音、构建时空对齐

总结: 聊天机器人->物流数字专家

03

实战过程趟坑经验总结

行业陷阱：平庸化的知识库RAG

行业陷阱 – 平庸化的知识库 RAG 与深度破解之道

陷阱篇

破解篇



知识库不是垃圾桶，而是 • 精心设计的知识工程 • 持续治理的智能资产 • 深度检索的基础设施

行业陷阱：“乐高积木”幻觉——复杂系统的脆弱性

从“拖拽节点”到“智能探路”——Agent workflow 进化论

行业现状与问题



现实世界业务逻辑充满不确定性、模糊性和长尾异常

用户模棱两可的话

外部 API 非标准格式

生产了大量“玩具级”应用

只能处理理想情况，生产环境效果一般

固定 DAG 流程断裂或产生幻觉

突破之道

不再依赖硬编码流程

From:

固定 Workflow

To:

ReAct (Reasoning + Acting) /
Plan-and-Solve 运行时引擎

引入“反思机制” (Reflection Loop)

每一阶段自我修正

置信度阈值检查

自动重试或策略切换

平台升级方向

Current:

推拉拽 workflow
(中间状态)

Future:

nl2workflow /
self-improving workflow

不要让用户画地图，要让 Agent 自己探路。

● 行业陷阱：agent普遍“reactor”化



04 未来展望

未来规划：迈向主动式、自进化式 智能agent





总结：

分享回顾： 基于骑手痛点→知识问答→万能客服→agent平台化建设

经验总结：

场景为王：扎根于业务痛点，

架构先行：预判业务发展，提前布局

数据驱动：“量化”+“优化”，驱动agent健康发展

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

