

QCon
全球软件开发大会

从Copilot 到 DataAgent: 企业级智能 数据开发治理平台的技术演进和实践

李卓豪

网易智企.数帆数据开发治理平台技术负责人

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

01 背景与演进历程：从Copilot到DataAgent

02 核心技术架构实现

03 关键能力的技术实现

04 落地挑战与评估体系

05 未来展望

06

01

背景与演进历程

从Copilot到DataAgent

数据开发治理平台在数据价值链中的定位和业务痛点



数据应用产品: ChatBI、智能问数

Cli、Skills

指标、表、模型映射

数据开发治理: EasyData

集群任务诊断

NDH: Hadoop & AI 支撑底座

AI浪潮下需求痛点



新项目实施，数据建设初始化效率有不断提升的需求：企业存量数据标准词典挖掘、批量数据入仓、核心字段发现等

初始化效率低



对于持续稳定发展的业务，基线不断地添加新任务，如何高效的保障基线产出，系统性降低风险是核心业务关注，能否智能重构数仓

数仓基线优化



存储计算资源不断消耗，每年都需要运动式的治理，上任务容易下任务难


资源持续优化




新人如何快速的熟悉数据架构、安全可靠地工作；如何专注数据设计自身，而不是数据存储、计算引擎特性

研发效率提升

Copilot探索：提升开发效率




Agent技术爆发：从"开发"到"全场景"的范式跃迁




02

核心技术架构实现

Copilot 架构



Copilot能力跃进：从通用LLM到企业知识增强




LLM 的局限

- ? 幻觉风险**
生成不存在的字段、SQL语法错误
- ! 语境缺失**
不懂内部术语、表关系、业务规则
- T 知识滞后**
无法感知最新业务变更和数据
- X 输出随机**
相同问题每次答案不一样

知识增强跃迁


知识增强 Copilot



知识库核心价值

- M 记忆沉淀**
历史SQL、最佳实践复用
- C 语境感知**
表关系、业务术语理解
- R 规范统一**
标准定义、口径一致性
- S 效率提升**
秒级响应、降低重复工作

知识库架构



AutoETL架构


标准化的业务场景模版抽象，

新数据源系统

根据数据源实际情况进行AI改写模版

模版引擎生效

适配新环境的标准化业务数仓构建



从 Copilot 到 Agent: 可控的自主化演进

Copilot 阶段: 确定性辅助

已解决: 知识沉淀、语境感知、生成质量

模式: 人主导决策、AI辅助执行

局限:

- 需要人工触发、单步响应
- 被动执行, 无法自主规划

能力跃迁: "执行者"到"决策者"

Copilot

Agent

单步响应

→

多步规划

即时生成

→

持续迭代

人类触发

→

目标驱动

辅助工具

→

数字员工

分层解耦: 通用 + 垂直

▸ 通用 Agent 底座

意图理解 | 任务规划 | 反思纠错

▸ 垂直 Sub Agent 插件


数据开发 | 任务运维 | 数据治理

▸ 垂直 Tool、Skill



SQL执行 | 智能运维 | 质量校验

演进策略: 通用Agent承载不确定性, 垂直组件处理确定性, 实现可控的自主化

DataAgent



DataAgent关键模块



DataAgent Case: 智能运维

用户

基线报警：任务 dws_xxx 实例 95021 失败
已阻塞下游 3 个任务

Agent

收到，正在排查实例 95021 失败原因...

- ① 调取调度系统执行日志
- ② 调取 Spark on Yarn 运行日志

Agent

诊断完成：OOM（内存溢出）
当前运行内存：4G
根因：数据量增长导致 Executor 内存不足
建议：调整内存至 6G 后重跑

用户

确认，调整到 6G 重跑

Agent

正在执行重跑... 监控中
实例 95021 重跑成功
基线恢复正常
下游 3 个任务已自动恢复调度

Agent 工具调用链路

提取实例ID

报警信息 → 实例ID: 95021



调度日志

调用 EasyTaskOps CLI 获取任务执行日志



Yarn日志

调用 Spark History API 获取 Executor 运行日志



OOM诊断

模型识别: OutOfMemoryError 当前内存 4G → 建议 6G



执行重跑

调用重跑 API，检查状态 SUCCESS，检查基线恢复

03

关键能力的技术实现

为什么需要 SQL 片段提取？

通用LLM的真实表现

"造假"——编造不存在的表名和字段名

模型不知道你有什么表，它会猜

"漏条件"——遗漏 `is_deleted=0` 等业务规则

隐性知识，新人也不一定知道

"凭感觉"——没有历史范例可参考

每次从零生成，准确率低

"写冗长 Prompt"——用户需手动补全上下文

提示词复杂度 > 直接手写 SQL

SQL片段提取：企业知识资产化

终结"造假"

基于真实SQL，表名、字段100%准确

捕获"漏条件"

自动沉淀业务规则，`is_deleted=0` 内置

告别"凭感觉"

历史范例即插即用，准确率大幅提升


简化"Prompt"

片段即结构上下文，Agent直接召回

SQL片段不是文档，是给 Agent 召回的结构化上下文，是 RAG 的精准知识

SQL片段提取

SQL片段 = 带业务注释的 SQL+ 语义描述



SQL 片段抽取

① 获取真实代码

业务RDS → 完整SQL

② 片段提取

保留SELECT核心逻辑

③ 获取关联元数据

表DDL + 字段信息

④ 结构化输出

综述 · 粒度 · 场景 · SQL

输入：业务计算回调比率特征的真实SQL

```
WITH tmp AS (  
  SELECT material, AVG(video_callback), ...  
  FROM (  
    SELECT flight_id... FROM iad_dwb_prod.dwb...di WHERE d = '...' AND exposure > 0 ) ta  
  JOIN (  
    SELECT ma_id FROM adman.ad_material WHERE d = '...' AND ... GROUP BY ma) tb ON  
    ta.material = tb.material_id GROUP BY material, flight_id)  
  
INSERT TABLE iad_algorithm_prod.link_send_feature PARTITION(d=...)  
SELECT ceil(vid_score*100), vid_sum, ... exp_sum, material, flight_id  
FROM tmp
```

片段及关联的元数据

"表名": "iad_dwb_prod.dwb_evt_iad_ctrfeature_di",
adman_adcore_db_ods_prod.ad_material

"字段": "material , video_callback, flight_id, content_show_type, ..."

"过滤条件": "d, content_show_type",

"SQL片段(去CTE, 保留SELECT核心)":

```
SELECT material, flight_id, AVG(video_callback) vid_score ...  
FROM iad_dwb_prod.dwb_evt_iad...di  
JOIN adman...prod.ad_material  
ON material = material_id WHERE d = '...' AND exposure > 0  
GROUP BY material, flight_id
```

结构化输出

【综述】 通过dwb_evt_iad_ctrfeature_di表关联ad_material素材表，按素材 × 投放计划粒度聚合广告回调指标，构造交叉比率特征。

【粒度】 以素材ID × 投放计划ID为粒度主体，每行代表一个素材在某个投放计划下的回调指标聚合值及其交叉比率特征。

【场景】 构建广告投放链路中的发送特征，通过视频回调等指标的交叉比率，刻画素材 × 计划维度的投放效果，支撑广告投放模型的特征输入与效果预估。

【SQL】

```
SELECT material, -- 素材ID  
        flight_id, -- 投放计划ID  
        AVG(video_callback) vid_score, -- 视频回调均值  
        SUM(video_callback) vid_sum, -- 视频回调总和  
        ... -- 其余比率特征  
FROM iad_dwb_prod.dwb_evt_iad...di -- CTR特征明细表  
JOIN adman...prod.ad_material -- 素材维表  
ON material = material_id  
WHERE d = '...' AND exposure > 0 -- 指定日期且有曝光  
GROUP BY material, flight_id
```

● 如何实现高质量 SQL 生成？

常见 ChatBI 方案

面向业务用户，依赖预定义指标体系，灵活性受限

自然语言



指标/标签



SQL

数据开发方案

面向数据开发 / 分析师，无需预定义指标，灵活可变

自然语言



SQL片段等知识召回



SQL

SQL片段是代码生成的精准知识基础，对代码生成质量至关重要！

SQL代码生成

自然语言



结构化




精准知识




SQL


问题明确&改写




知识召回



代码生成



代码纠错



SQL 代码生成

① 问题改写 自然语言 → 结构化JSON

用户原始问题

我要查询唯品会的合约人群包，两部分人取并集，第一部分是30天内点击过唯品会/淘宝/京东素材的（点击表和素材标签表关联），第二部分是美妆兴趣标签等级 ≥ 2，然后这些人还得是装了唯品会 App

改写后结构化JSON

"问题类型": "数据查询",

"问题改写": "(1)近30天点击过唯品会/淘宝/京东素材用户;
(2)美妆兴趣标签等级≥2的用户。

(1)并集(2)再交集 安装唯品会App的用户",

"过滤条件":

sponsor_group_name : "唯品会/淘宝/京东"

tag_name : "美妆"

cpm_level : "≥2"

app_list : "唯品会"

"假设性回复": 假设查询将从广告素材点击行为和美妆兴趣标签两个维度筛选用户取并集，再与唯品会App安装用户取交集，返回去重后的user_id

② 知识召回 表DDL + 字段元数据

召回：表元数据

dwd.dwd_iad_adx_click_di
murs (user_id), material_id, dt

iad_preformat.dspmaterial...tags_dd
material_id, sponsor_group_name, d

iad_preformat.dmp_adx_rank..level_dd
murs (user_id), tag_name, cpm_level

iad_dwb_prod.dwb_app_install...dd
user_id, app_list

召回：代码片段

```
SELECT t1.user_id FROM
(SELECT dt, murs AS user_id, material_id
FROM dwd.dwd_iad_adx_click_di
WHERE dt >= date_sub(..., 30)
GROUP BY 1,2,3) t1
JOIN
(SELECT d, material_id
FROM iad_preformat.dspmaterial...
WHERE sponsor_group_name
LIKE '%唯品会%' OR ... '%淘宝%' OR ... '%京东%'
GROUP BY 1,2) t2
ON t1.material_id = t2.material_id
AND t1.dt = t2.d
```

③ 代码生成 改写问题+知识+模板→SQL

生成SQL

```
SELECT DISTINCT ta.user_id
FROM (
-- Part1: 30天内点击唯品会/淘宝/京东素材
SELECT t1.user_id
FROM (SELECT dt, murs AS user_id, material_id
FROM dwd.dwd_iad_adx_click_di
WHERE dt >= date_sub(...,30)
GROUP BY 1,2,3) t1
JOIN (SELECT d, material_id
FROM iad_preformat.dspmaterial...
WHERE sponsor_group_name
LIKE '%唯品会%' OR '%淘宝%' OR '%京东%'
GROUP BY 1,2) t2
ON t1.material_id=t2.material_id AND t1.dt=t2.d
UNION
-- Part2: 美妆兴趣标签等级≥2
SELECT murs AS user_id
FROM iad_preformat.dmp_adx_rank...
WHERE tag_name LIKE '%美妆%'
AND cpm_level >= 2
) AS ta
JOIN (
-- Part3: 安装唯品会 App
SELECT user_id
FROM iad_dwb_prod.dwb_app_install...
WHERE array_contains(app_list,'唯品会')
) AS tb
ON ta.user_id = tb.user_id
```

Data Agent 如何调用工具？

传统方式：GUI 自动化

截图识别 → 脆弱，UI 变更即失效

每步都需要 LLM 推理 → 慢且贵

无法批量编排 → 缺乏可组合性

无结构化输出 → Agent 难以解析

CLI 天然适合 Agent

结构化输入输出 → JSON 直接解析

零 LLM 运行时成本 → 确定性执行

管道机制可组合 → 多命令串联编排

对人类可见可调试 → 复现 Agent 行为

CLI 不仅是 Agent 的交互方式，更是 Token 效率的最优解

CLI vs MCP 的核心差距

MCP 方案

MCP 把知识放在了运行时的上下文窗口里

Schema 注入 ~28,000 tokens

工具选择 ~3,200 tokens

50台设备总计 ~145,000 tokens

CLI 方案

CLI 把知识放在了模型的训练数据里

Schema 注入 0 tokens

命令组合 ~800 tokens

50台设备总计 ~4,150 tokens

Token 效率差距: 35 倍

业界验证: 钉钉、飞书、企业微信 72 小时内争相开源 CLI

我们的选择：为 Agent 设计的 CLI

① 默认非交互

Agent 无法处理交互式提示

⑤ 渐进式发现

--help 让 Agent 按需获取

② 结构化输出

--format json 是标配

⑥ 可组合

输出格式一致，管道串联

③ 快速失败

错误告诉 Agent 怎么修

⑦ 有界响应

限制输出量，高信噪比

④ 安全重试

幂等操作 + dry-run 预览

EasyData Cli & Skill

EasyData CLI

三层命令

Shortcuts
(高频快捷命令, 手工封装)

Service Commands
(1:1 映射OpenAPI)

Web API
(前端 API)

Schema管理

构建嵌入

定时刷新

实时刷新

全局命令 & Flags

全局命令

全局Flags

安全认证

AK/SK

OAuth2

存储

配置存储

Token加密存储

Command Schema 存储

帮助

帮助命令

内省

GateWay (HTTP/MCP)

EasyData Cli Skill

配置管理

命令缓存

工作流程

公共Flags

错误处理


重要规则

使用示例

子产品说明

EasyData GateWay

GateWay 将子产品的 OpenAPI 元数据转换为 MCP Schema，再通过 CLI 层暴露为命令行能力，实现一套架构统一对外



OpenAPI

一个服务

GateWay 作为统一入口

MCP Tool

两项协议

HTTP + MCP

CLI Command

三种能力

OpenAPI + MCP + CLI

04

落地挑战与评估体系

SQL的筛选

- 锚定业务场景，离线开发、自分析
- 基于sql行数
- 基于用户sql文件数
- 识别同一个任务在不同开发环境下的版本
- 识别用户之间copy修改

SQL预先处理

- 转义、中文编码、变量宏定义还原
- 辅助信息：业务小组、表、任务负责人、引擎类型
- 超长SQL处理：构建大宽表



微调训练数据准备

SQL去重

- 所有sql 按照时间顺序从小到大排序、遍历；
- 每条新时间戳的sql，对比其前两小时内的其他sql
- 如果2小时内存在一条sql 和当前sql 的篇幅大小增加或减小范围小于 $1/2$ 并且 编辑距离小于 $\text{avg_word_len} * \max(3, \text{sql_word_num}/10)$, 则认为是相似的。
- 删除前两小时内的相似sql，最大时间戳内的相似sql 替换该删除的相似sql。

SQL拆解

- 基于引擎AST做数据切割
- 正常训练
- 分段训练 + 语法完整性校验
- 拆解为子查询单元
- 分层生成：先 CTE 定义，后主查询



从细节优化模型效果

- deepseek 正确的prompt 推理形式

✓ 代码块


```
1 <| fim_begin |> pre_context <| fim_hole |> suf_context <| fim_end |>
```

- 导致sql badcase错误的推理形式

✓ 代码块

```
1 <| fim_begin |> pre_context <| fim_hole |> <| begin_of_sentence |> suf_context <| fim_end |>
```

- 原因：用deepseek初始化后得到的tokenizer，在高版本的transformer 下，encode text 段落时会在段首自动加上<| begin_of_sentence |>。



<| begin_of_sentence |> 在deepseek 的预训练中的作用应该是：拼在代码文件开头处，用于标记代码文件的开始。也起到了切割两个相邻代码文件语义的作用。

关联现象

- 生成和上文风格不一致的错误语句
- 和上文的信息似乎存在严重割裂
- 不懂得从上文推测出补全类型是span补全，写了一个功能独立的行。
- 重复了与下文重复的sql语句

其他细节-潜在埋点建议

- 用户临近时间的点击操作序列，以时间戳为顺序组织
- 用户的SQL代码历史书写记录，用于微调
- 用户对这个SQL补全的评价（赞或踩）、修改意见反馈入口

Text-to-SQL评估体系

评测系统目标

- 统一评分标准：评估维度清晰、兼顾单个sql 和整体能力
- 支持规模自动化：能对数百上千条评测样本做全量回归，支撑版本对比与长期演进
- 支持结果分析：测试过程trace关键链路信息、给哪些维度、复杂度表现不佳

评估指标

- EX：核心指标，是否完全正确
- Intent Match Score，衡量查询意图匹配
- 静态结构对比：SQL结构对比
- 动态结果验证：结果等价判断



高质量评测集

- 用户提供，即人工整理
- 从线上新sql任务提取
- sql自动复杂度打标
- sql数据整理：sql真实跑通，sql有下游依赖
- sql扩展：主要是做算子变异：select、join、where、聚合、order


成熟度分级

- 维度设计：表、字段、条件、聚合、加工
- 权重与综合得分
- L1-L6成熟度等级

Text-to-SQL评估系统



产品AI Native化



05 未来展望

场景化Skill

EasyData 全景 SKILL 架构

基于 CLI + 基础 SKILL 构建的大数据开发治理平台智能能力矩阵



THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

