

QCon
全球软件开发大会

从“不可验证”到“可迭 代”

分析型AI的多智能体工程实践

李哲

淘宝闪购-数据算法负责人
2026年4月



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录


- 01 困境：分析型AI的「不可验证」瓶颈
- 02 破局：「验证者法则」工程框架
- 03 实战：两大关键技术剖析
- 04 洞察与展望

01 困境

分析型AI的「不可验证」瓶颈

分析任务无标准答案

背景：城市经营者的动线与问题归纳



背景：BI团队的双重困境

人力资源稀缺与难以规模化

BI团队长期承担着「城市经营分析师」的角色，定期向城市经营者输出涵盖订单、供给、用户、履约等维度的深度诊断报告。一份高质量报告需BI花费数天完成，涉及复杂取数、多维归因、策略提炼。全国数百个城市，无法靠人工覆盖。

城市经营者的多元需求

城市经营者（城市经理、城市中台等，人数共计上百人）职责涵盖：目标承接、经营分析（从供给、用户、履约维度诊断）、策略制定、资源分配、过程复盘、多业务线协同、过程管理等。

验证者法则 (Verifier's Law)

AI能否攻克一个任务，不取决于其表面复杂度，而取决于该任务是否具备可验证性——即是否存在快速、客观、可扩展、低噪音且能提供连续反馈的评估机制。

—— Jason Wei、Andrej Karpathy 等前OpenAI科学家



速度

验证一次需要多久，
能否快速迭代



客观

是否有明确答案，结
果是否可量化评估



扩展

能否批量验证，适应
大规模场景



噪音

结果是否一致，避免
随机波动干扰

求解与验证的难度图谱

评估分析型AI的突破潜力与实施路径



02 破局

「验证者法则」工程框架

从验证答案转向验证过程，通过特权信息与多智能体架构，将模糊任务拆解为可验证的标准化步骤

核心思想：特权信息 + 多智能体改变验证难度

验证方式的根本转变

不直接验证最终结论是否正确（几乎不可能），而是验证生成结论的过程是否合理（可操作）



验证成本极高

一份经营分析报告涉及多维度数据、复杂归因和策略建议，专家需花费数天验证

标准模糊

经营策略没有绝对正确答案，只有“相对合理”

难以规模化

全国数百个城市，无法靠人工逐一验证

● 核心思想： 特权信息 + 多智能体改变验证难度

将验证点前置到过程环节，实现验证难度的结构性降低





整体方案

分析型 AI 多智能体方案




BI专家层 全链路支撑 (资产/语义/分析思路/评测)



应用层 面向CM/参谋长/城市中台的分析决策报告

Agent层 基于LangGraph的多智能体编排与人机协同框架



LangStack
LangGraph
Langfuse

模型管理
SFT/RL model
qwen3-max
deepseek-r1

工具注册
预计算报告
分析思路检索
语义召回重排
语义取数分析
含权限控制

语义层 语义管理-计算-服务体系

特权信息

1. 路径1: 按照工具下钻 (全链) [订单=淘宝券+超抢手+拼团+18.8券+爆红包+超吃卡+吃货豆+免单+其他券]

a. 如果定位到主因是爆红包

i. 按照人群下钻 (L分层+V分层)

ii. 按照发放核销链路下钻 (订单=DAU/淘宝券发券用户占比/淘宝券人均发券张数/淘宝券订单核销率)

1. 如果定位到主因是DAU, 则 **建议关注xx人群的流失问题**

2. 如果定位到主因是发券用户占比, **建议关注xx人群发券覆盖率偏低**

3. 如果定位到主因是人均发券张数, **建议关注xx人群人均发券张数偏低**

4. 如果定位到主因是券订单核销率=核销量/(订单数) 较大的主力券型, 看核销率下降大的淘宝券名称

a. 按照券明细下钻, **建议xx人群的xx券进行整改**

b. 如果定位到主因是超抢手核销率

i. 按照业务线链下钻

ii. 按照链路链下钻 (订单=商品数量/商品动销率/商品产能)

1. 如果定位到主因是商品数量, 则 **建议关注xx业务线的有效商品数量下降**

2. 如果定位到主因是商品动销率, (相关因素: 总补贴强度、平台补贴强度、商家补贴强度、出清比), **建议关注xx业务线的xx商品核销率**

3. 如果定位到主因是商品产能

a. 按照曝光链路下钻 (日均产能/日均曝光/曝光率), **建议关注xx业务线的xx曝光核销率**

c. 如果定位到主因是爆红包

i. 按照人群下钻 (付费非付费/L分层+V分层)

ii. 按照发放核销链路下钻 (订单=DAU/爆红包发券用户占比/爆红包人均发券张数/爆红包订单核销率)

1. 如果定位到主因是DAU, 则 **建议关注xx人群的流失问题**

2. 如果定位到主因是发券用户占比, **建议关注xx人群发券覆盖率偏低**

3. 如果定位到主因是人均发券张数, **建议关注xx人群人均发券张数偏低**

4. 如果定位到主因是券订单核销率

a. 按照券明细下钻, **建议xx人群的xx券进行整改** (核销量/(订单数) 较大的主力券型, 看核销率下降大的爆红包活动名称)

d. 如果定位到主因是超吃卡

i. 按照mac"频次"下钻 (月订单=MAC/付费MAC渗透率/人均超吃卡数量)

1. 如果定位到主因是付费MAC渗透率

a. 按照人群下钻 (L分层+V分层), **建议超吃卡核销率低xx人群中的付费渗透率**

2. 如果定位到主因是人均超吃卡数量

分析框架

抽象总结的分析方法论, 按分析专题组织 (1个专题对应n个分析框架), 以文档形式为主。


萃取

分析思路

与语义映射后的分析框架, 按分析专题组织 (1个专题对应n个分析思路), 文本形式。

特权信息建设

分析思路萃取




03 实战

两大关键技术剖析


三模式控制架构与可信数据基座

3.1 苦涩的认知迭代




3.1 苦涩的认知迭代

三次关键技术决策：从后训练到单智能体再到多智能体



3.2 三种模式定义



稳定模式

- 适用场景：周报、月报等
- 技术特点：部分数据内容预计算，确保输出结果稳定可靠


平衡模式

- 适用场景：兼顾确定性与探索性需求的中间形态
- 技术特点：半预计算 + 半自助推理的混合策略

灵活模式


- 适用场景：深度专题分析诊断
- 技术特点：AI自主探索，借鉴Deep Research模式

3.3 多智能体设计



角色分工	定位	可用工具	基模
意图智能体 (Recognizer)	负责理解用户的输入，通过多轮对话引导至系统能力范围内，通过澄清机制识别关键槽位，对不合理的请求进行拒答	系统能力校验工具 用户响应工具	qwen
规划智能体 (Planner)	负责任务分解与分析规划，将复杂查询拆解为可执行步骤	预计算报告工具 BI分析思路检索工具	qwen
协调智能体 (Orchestrator)	负责将规划智能体拆解的步骤分发给不同的专家子图用于并行	/	qwen
分析智能体 (Analyst)	负责执行规划智能体指派的步骤，拆解为具体取数任务分派至数据智能体，整合其分析结果后向策略智能体获取业务策略建议	语义检索工具 handoff_to_data_agent handoff_to_strategist	qwen
数据智能体 (DataAgent)	负责执行语义元信息检索和取数分析，为分析智能体提供数据支持	语义检索工具 语义取数分析工具	qwen
代码智能体 (CodeAgent)	增强了数据科学的能力	语义取数分析工具 语义检索工具	qwen
策略智能体 (Strategist)	负责接收分析智能体的数据处理结果与业务需求，检索匹配的业务策略建议并返回	BI策略检索工具	qwen
报告智能体 (Reporter)	负责将分析过程转化为结构化、专业的文本报告，融合审核智能体的修改建议，最终输出满足业务需求的报告	预计算报告工具	qwen
审核智能体 (Critic)	负责对分析结论中的数据逻辑错误进行修正，提出修改建议	/	deepseek
可视化智能体 (Visualizer)	负责将最终文字版的markdown报告转换成图文并茂的html网页	/	deepseek

3.4 规划智能体的迭代优化



1. **语义对齐优化目标**: 最小化分析思路与语义层的距离, 同时保证指标/维度覆盖度


$$\Phi^* = \operatorname{argmin}_{\Phi} [d_{\text{sem}}(T, S) + \lambda \cdot \text{Coverage}_{\text{loss}}]$$

2. **树状计划的路径上下文**: Analyst只看当前路径, Reporter感知全树, 降低token消耗

$$\text{ContextAnal}(v_i) = \text{Path}(v_0 \rightarrow v_i) \setminus \text{FullTree}$$


3. **条件继承机制**: 子节点自动继承所有祖先节点的筛选条件, 杜绝条件丢失

$$\text{Constraints}(v_i) = \bigcup (v_j \in \text{Path}) \text{Filter } s(v_j)$$



上下文优化

1. **奖励核心**: 先以LLM as Judge保证奖励信号精准, 再沉淀规则化奖励提升鲁棒性
2. **评价标准**: 5个维度, 相关性与完整性、框架遵循性、结构规范性、执行逻辑性与描述完整性、规模合理性
3. **迭代逻辑**: LLM打分迭代优化5维信号, 对齐业务痛点, 保障通用质量
4. **规则落地**: 从5维中提炼格式惩罚、语义元信息匹配惩罚两类规则奖励, 规避Reward Hacking
5. **最终融合**: 5维LLM奖励归一化后, 与2项规则奖励加权融合, 权重按迭代效果动态调整。



规划智能体GRPO

3.5 可信的数据基座

核心分歧

- 颗粒度：超级skill or 小而美
- 抽象层级：Agent 交互的对象应该是底层的物理表，还是封装好的“语义层”
- 权责：当查不到数据或查询超时，是谁的责任？

达成共识

- 废弃“NL2SQL”的底层直接操作：公司级应用对错误容忍度极低。Agent不应该直接写SQL查底层大表，而是应该调用指标字典或语义层 API
- 导航 + 查询：先确认“有哪些指标可用、对应的字段名是什么”；再拿着准确的元数据去请求真实数据

3.5 可信的数据底座



3.5 可信的数据基座

相较于传统NL2SQL方案，要求AI理解底层物理表晦涩的字段命名并生成复杂SQL逻辑，极易产生计算幻觉；基于数据语义，我们提供AI更易理解和消费的DSL取数服务，解决大模型落地数据分析时最核心的“幻觉”问题和数据供给问题。

根据能力象限划分L1-L4进行逐层演进，并提供各象限下可提问的问题范式

Level	功能描述	已支撑的核心能力
L1 静态事实数据获取	基于数据语义，打通语义解析到物理资产取数通路，满足AI基础取数诉求	- 过滤：昨天杭州的净G是多少 - 上卷：近7天杭州的净G是多少 - 下钻+排序：昨天杭州各个业务线的订单量，取top_n
L2 动态衍生数据计算	增加衍生数据的计算语义，结合数据虚拟化技术实现“语义定义即生产”，同时构建联邦查询能力，提升AI取数效率	- 同环比：昨天上海订单量的同比情况 - 占比：昨天上海BL订单量在业务线的占比 - 排名：昨天上海BL订单量在业务线的排名
L3 事实数据的推理服务	通过关系语义扩展与分析思路语义化，融合大模型的分步推理能力将复杂的数据分析任务拆解为可执行的简单取数任务，并通过数据语义关联与逻辑推导生成深度数据洞见。	- 异动分析：分析订单量近七天的异动情况 - 波动分析：订单量在业务线维度的归因分析 - 指标公式拆解：净G的用户动线拆解分析 - 主成分分析：分析上海的订单量是否还是以茶饮为主
L4 事实数据的预测服务	通过业务知识扩展（如事件标签、天气特征、行业周期等）与预测算法深度融合，基于L1-L3层数据获取能力与外部动态信息，输出可解释的趋势预测结论	过去7天杭州的经营情况以及改善方案


3.6 案例

分析一下宁波最近订单的涨跌原因，以及给我一些改进建议

3000字


10分钟

8万
tokens



Trace观测

Step	Agent	Execution Level	Log	Trace
1	AnalysisAgent	...	...	...
2	PlanningAgent	...	...	...
3	ExecutionAgent	...	...	...



指标语义

指标名称	指标描述	指标类型	业务口径
近30天人均净交易额	...	交易额	...
近1天_新增_动销商户数	...	交易额	...
近1天_新增_动销商户数	...	交易额	...

04

洞察与展望

从报告生成到决策建议的演进路径

实践痛点与应对

痛点一：解空间巨大，验证缺乏行业标准

经营归因的因果链近乎无穷，无法穷举“最优解”；分析结论没有 ground truth，只能依赖特权信息做软验证，对错难以量化。



1

以“可迭代”替代“可证明”

追求一次正确，通过BI&城市经营者反馈闭环在实践中持续逼近更优解。

痛点二：确定性与灵活性的跷跷板

预计算保证确定性但场景固化，LLM 自主推理带来灵活性但准确性难控，二者此消彼长。



2

三模式架构按需调度

稳定、平衡、灵活模式按场景复杂度动态切换，不做单一押注。

痛点三：弥合语义的鸿沟，无法一蹴而就

业务术语、指标口径、分析意图到数据语义的映射永远存在 gap，每个新场景都可能暴露新的理解断层。



3

语义资产飞轮式沉淀

持续建设可复用的语义资产，在每次交互中不断校准语义，用得越多，理解越准。



从“不可验证”到“可迭代”，是让AI分析经得起检验；从“可迭代”到“自主经营”，是让AI决策跑在变化之前。多智能体不是目的，而是通向经营智能体的工程阶梯。

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

