

xLLM-Rec: 面向生成式推荐的高性能推理

杨培军

AI Infra主架构师



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

个人简介



“

京东零售AI域主架构师，xLLM开源项目架构师/核心贡献者。曾就职于阿里妈妈负责搜索广告架构和AI Infra推理系统研发，现于京东零售智能平台部专注大模型推理及生成式推荐能力建设。

”

杨培军
京东零售 AI Infra主架构师

目录

01 业务背景与挑战

02 行业方案

03 技术方案&创新

04 核心成果


05 未来展望

01

业务背景与挑战

生成式推荐的技术范式变革与核心难题

传统推荐：多阶段级联架构



特征工程依赖

特征工程“矿山”基本被挖掘殆尽，“精心”设计的手工特征，迭代成本骤升且泛化性差

模型工程天花板

现有架构无法有效建模“世界知识”、“用户意图Reasoning”，对多领域、多模态、用户行为等吸收、表达有限


级联架构误差放大

级联多阶段架构，算法目标被分散到不同阶段和不同算法团队去优化，出现了严重的目标割裂和误差传播

GPU资源利用率低

推荐训练、推理MFU 10%以下，LLM在H100上训练时MFU可高达40-50%

生成式推荐：行业级技术升级趋势



端到端生成架构

业界生成式推荐正往端到端生成架构方向快速发展, 初步验证了Scaling Law和Scaling Up的收益潜力



多模态深度融合

引入图像、文本等更多模态信息, 结合MoE等模型结构设计, 实现更丰富的特征表达



Reasoning推理

基于世界知识+全场域联动的Reasoning推理能力, 提升推荐的准确性与多样性



DLRM vs LLM vs GRs: 技术架构对比

关键洞察: GRs (Generative Recommendation System, 生成式推荐) 模型融合了 DLRM 的稀疏特征处理能力和 LLM 的生成能力, 在保持推荐系统核心优势的同时, 引入了LLM模型参数规模和自回归生成范式, 实现更准确、更多样化的推荐结果。

	DLRM 传统推荐模型	LLM 大语言模型	GRs 生成式推荐模型
Feature Engineering	ID化、分桶、交叉组合统计特征...	✗	✓ 稀疏长序列建模, 需求与特性同DLRM
	✗	Tokenizer/DeTokenizer	✓ Tokenizer/DeTokenizer
Embedding Model	稀疏ID Embedding: 10G~1TB级 大规模稀疏参数	✗	✓ 稀疏ID同DLRM
	✗	Vocab Embedding, G级别	✓ Vocab Embedding, G级别
Dense Model	复杂模型结构: DNN+Attention等变种结合; Dense大小几十M	✗	✓ 行为序列建模同DLRM
	✗	Transformer为主体; Dense参数量1B~1T	✓ Dense Transformer/HSTU等, Dense大小0.1B~10B
生成范式	Point-wise Scoring	Autoregressive generation	Autoregressive generation + Beam Search

核心技术挑战

01

系统融合挑战

 **TB 级稀疏参数** 推荐系统的大规模稀疏嵌入参数

 **十B 级稠密参数** LLM 的稠密参数规模

🕒 **工业级部署要求端到端时延控制在百ms以内**

02

技术生态切换挑战

 **TensorFlow生态** 原有搜推体系基础



 **Torch生态** 生成式推荐所需

↔ **需要完成技术生态的平滑切换，确保业务连续性**

03

技术范式瓶颈

LLM计算Kernel和Beam Search机制在生成式推荐推理场景下，存在以下核心瓶颈：

 **重复访存**

 **Block频繁拷贝**

 **混合Mask计算**



 **端到端时延过高**

❗ **LLM 的优化技术栈并不总是能在生成式推荐场景直接生效**

02 行业方案

业界主流方案与我们的差异化路径



业界主流方案 - 生成式推荐推理

A

方案一

编译优化路线

技术路径

离线训练整图导出，使用TensorRT（GPU）直接编译优化

优势

- 充分利用硬件加速能力
- 静态图优化潜力大

局限性

- 难以处理动态Beam Search逻辑
- 缺乏对KV Cache的精细化管理

B

方案二

大模型框架复用

技术路径

直接复用大模型推理框架加速方案（FlashAttention/PagedAttention等），基于TensorRT-LLM框架

优势

- 成熟的Attention优化
- 社区生态丰富

局限性

- 未针对推荐场景优化，Continuous Batching调度成本高
- Beam Search效率存在性能瓶颈


xLLM-Rec: xLLM生成式推荐

大模型

多模态

文生图/视频

生成式推荐



高性能


提升吞吐、降低时延
最大2.3+倍

易开发

主流模型天级
适配上线


高可用

智能集群调度
高效Failover容错架构



欢迎入群聊

xLLM 用户群



xLLM 项目地址: <https://github.com/jd-opensource/xllm>
<https://github.com/jd-opensource/xllm-service>

xLLM 技术报告: <https://arxiv.org/pdf/2510.14686>

03

技术方案&创新

面向Beam Search和混合Mask的系统性优化

Beam Search性能分析

技术背景：在生成式推荐中，系统以自回归方式生成3个token id（代表一个商品Item）。在每个Step中，Beam Search会并行扩展并保留概率最高的多个候选序列，保证推理结束时得到整体最优的推荐商品。





Figure 2: An overview of the modeling approach used in TIGER.



Beam Search流程实例



重复访存

各候选序列共享Prefill上下文，Decode Attention计算每个序列单独访问KV

Cache

造成相同数据被多次加载，内存带宽成为瓶颈



Block频繁拷贝

KV Cache按照Block管理且需对齐，候选序列在更新时需要拷贝旧序列的KV Cache

引入了频繁的复制开销，严重影响推理效率




时延过高

传统Beam Search的筛选在Host侧进行，需要数据拷贝到内存，同时CPU处理筛选过程耗时过长。

端到端时延难以满足推荐系统要求，端到端百ms时延约束



混合Mask性能分析



生成式推荐模型输入序列Masking示例

关键问题

- **序列结构复杂**: 生成式推荐场景通常会将输入序列划分为多个语义区段，每个序列段可独立配置为 Full 或 Causal 注意力模式，形成混合结构。
- **开箱性能差**: FlashAttn并无法有效应对这种场景，其他开源实现如FlexAttn / torch compile虽然可以处理这种复杂的Mask，但性能差。
 - ✓ 大Shape全局 Mask 生成 / 搬运 / 存储成本高
 - ✓ 存在冗余计算问题，Block分块可能会圈进去白色区域

xGR创新方案




Figure 6: Design overview of xGR.

🏆 核心创新点


1 **KV Cache分级管理**
共享缓存 + 非共享缓存

2 **xAttention优化**
三阶段Attention计算

3 **Schedule优化**
整图下沉Device执行，减少CPU参与

4 **混合Mask优化**
Kernel内部生成异构Mask，防止显存爆炸

创新1: KV Cache分级管理机制



共享缓存

Shared Cache - 在Prefill阶段生成，所有候选序列共享同一份Cache

- ✓ 避免了重复存储和冗余计算
- ✓ 显著减少内存占用
- ✓ 提升Prefill阶段效率



非共享缓存

Unshared Cache - 在Decode阶段，每个候选序列独立生成新的KV Cache

- ✓ Token粒度进行动态管理
- ✓ 支持细粒度更新和回收
- ✓ 保持存储连续性

创新2: xAttention计算优化

💡 核心思想

对比传统的Page Attention, **xAttention** 将attention计算拆分为三个独立部分, 实现更高效的计算模式。

📊 三阶段计算流程

1 共享部分处理


对所有序列的 **Shared Cache** 进行统一计算

2 非共享部分处理

对每个序列独有的 **Unshared Cache** 进行计算

3 合并与归一化

基于 Softmax 融合两部分输出, 生成最终注意力结果



⚖️ 与传统方案对比

✗ **传统Page Attention** 每个序列独立加载全部Cache

✓ **xAttention** 共享部分统一计算, 减少重复加载

创新3: Schedule优化与Device侧执行

🔑 核心策略

将Beam Search核心逻辑 **下沉至设备侧** 实现，结合约束解码的早停机制，将整个候选序列的打分、排序与筛选，完整在GPU device设备上高效执行。

⚙️ 优化收益



减少数据传输

减少大规模D2H (Device to Host) 数据传输开销



发挥并行能力

充分发挥GPU并行计算能力，大幅提升推理效率



降低关键路径

减少CPU参与，降低关键路径耗时



约束解码早停

结合约束解码的早停机制，提前终止无效计算





Figure 10: Valid path constraint during token generation.



创新4：增量分段Mask计算

关键思路：将自定义掩码注意力转化为前缀 KV 复用 + 增量片段计算问题，以分层缓存 + 细粒度计算阶段拆分，实现无损精度、极致性能的优化。



核心优化

- **区域化分块策略：**按掩码稀疏性拆分多个子计算stage，Target 段二段式精细化调度
- **局部掩码：**子stage仅维护专属小mask，同时局部mask在kernel内部生成，消除全局 Mask 搬运与同步开销
- **级联 Online Softmax：**子stage独立计算 + 结果累加，规避大矩阵单次计算，硬件流水化拉满
- **无效区域零计算：**直接裁剪掩码屏蔽块，彻底剔除无效 QK / Softmax 与 KV 访存

04 核心成果

从实验到生产环境的全面验证

性能收益：搜推迁移案例



首页生成式推荐

性能提升

+92.4%

🕒 TP99时延优化

优化前
76ms



优化后
26ms

时延降低 65.8%

✅ 迁移落地xGR方案，性能显著提升



生成式搜索

性能提升

1x+

🕒 TP99时延优化

优化前
118ms



优化后
47ms

时延降低 60.2%

✅ 线上高峰时期毛刺现象明显缓解



生产环境验证

xGR方案在首页生成式推荐和生成式搜索两大核心业务场景成功落地，性能提升显著，时延大幅降低。

性能对比数据

TRT-LLM

TensorRT-LLM
业界开源SOTA

baseline


xGR

xGR (我们的方案)
业界性能SOTA水准

~1x



相比TensorRT-LLM性能提升约1倍



业务收益：核心场景落地



搜推场景

首页推荐 + 搜索

资源节省

支撑首页生成式推荐/搜索等核心业务场景落地，节省近一半卡资源

UCTR提升

+10.3%

UCVR提升

+6.9%

✓ 核心业务指标显著提升



OxygenRec场

景
多场景覆盖

覆盖场景

百补

包邮

结算页

爱购

性能指标

端到端TP99

<
70ms

业务效果

UCTCVR提升 **+2.27% ~ 6.07%** (显著)



首页推荐



生成式搜索



百亿补贴



结算页

学术价值

xGR**创新性**技术方案，在核心典型业务场景效果提升明显，撰写论文投稿SC26。

论文链接

<https://arxiv.org/pdf/2512.11529>

05 未来展望

生成式推荐的技术演进方向

技术趋势预判



Sparse Scaling Up

核心方向

用户序列中的稀疏特征仍然非常重要

技术目标

在全站全域数据以及全生命周期万级用户长序列建模的加持下，实现**TB级别Embedding的十分钟级别更新**

↑ 稀疏特征持续演进



Dense Scaling Up

核心方向

基于世界知识+全场域联动的Reasoning推理

技术目标

引入图像、文本更多模态，结合MoE等模型结构设计，实现**10B级别模型的高性能推理**

↑ 稠密模型规模扩大



Generation Paradigm

当前主流

广度优先的束搜索（Beam Search）生成方式

演进方向

借鉴大语言模型（如DeepSeek）中的**MTP并行解码技术**，以及扩散模型（Diffusion Model）的并行生成能力

↑ 生成范式多样化



技术演进洞察


生成式推荐技术正在从单一模态向多模态融合演进，从判别式向生成式范式升级，从中小规模向大规模Scaling Up发展。xGR为这一演进路径提供了一种技术优化方案，支持未来更大规模、更复杂场景的落地应用。

生成式推荐正在重新定义推荐系统

Generative Recommendation Is Redefining The Recommendation System



联系交流
欢迎技术探讨



论文链接
arXiv:2512.11
529

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

