

QCon
全球软件开发大会

AI-in-SRE Loop: 当 AI 成为核心业务后, SRE 的下一站

从 AI 业务稳定性到 Agent 运维体系的工程化实践

田云龙 | 资深高可用架构师 | 2026.04.16



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

01 开场与问题重定义：为什么传统 SRE 视角不够了

02 方法论：AI-in-SRE Loop如何重新看待 AI 稳定性

03 双重AI系统与Harness：如何给Agent加护栏

04 落地案例与多Agent协同：哪些场景最值得先做

05 评估治理与演进路径：如何避免做成Demo

06 铁律、总结与Q&A：能直接带走的原则

开场 · 为什么要重塑 AI 时代的 SRE

AI 不再是实验业务，AI 就是生产系统本身

一次模型异常，不只影响效果，还会同时影响体验、收入、GPU 成本和链路稳定性。
SRE 的保障对象，必须从服务扩展到模型、推理链路和 Agent 决策链。

AI稳定性为什么完全不一样

这不是传统稳定性的轻微升级，而是稳定性对象、约束条件和止损方式都发生了变化。

	传统系统	AI 系统
稳定性对象	服务 / 代码 / 配置 / 机器	服务 + 模型 + 推理链路 + 数据链路 + Agent 决策链
主要约束	发布、依赖、容量、机房、容灾	Prompt、Tool、Workflow、Memory、权限、模型行为
止损方式	扩容、回滚、熔断、切流	降级、限流、回滚、策略切换、人工接管、受控执行

核心结论：AI 时代的 SRE 不再只是保障“服务可用”，而是要保障“系统可判断、可止损、可被接管”。

AI 时代的 SRE，面对的是双重 AI 系统

SRE 不只是保障 AI 业务系统，也要保障参与研发、运维、值班和治理流程的 AI 系统。

第一类：被保障的 AI 系统

- 搜索问答、推荐排序、广告模型、推理服务
- 特征与数据链路、模型服务、GPU 与资源链路
- 它们直接决定体验、效果、成本与资源消耗

风险关键词：模型异常、链路抖动、数据漂移、成本失控

相互影响

第二类：参与保障的 AI 系统


- 告警分析 Agent、发布守护 Agent、巡检 Agent
- 容量评估 Agent、诊断 Agent、复盘 Agent
- 它们开始参与判断、建议和受控执行

风险关键词：幻觉、越权、误判、执行策略失稳

所以 SRE 的边界已经从“保障 AI 业务系统”扩展到“保障系统 + 保障 Agent 决策链和执行链”。

AI-in-SRE Loop: 为什么必须有稳定性闭环

既然稳定性对象变了、保障主体也变了，SRE 就不能停留在人工发现和人工处理，而要把 AI 放进稳定性闭环里。



本质上，AI-in-SRE Loop 要解决的是：让系统更早看见事实、更快形成判断、更稳受控止损，并把经验持续回灌为下一次能力。

Harness与受控执行：为什么必须给Agent上工程护栏

生产系统需要的不是“更自由的 Agent”，而是“更可控的 Agent”。Harness 的价值，就是把创造性留在判断层，把确定性落实在执行层。

约束输入

限定问题模板、上下文来源与证据范围

约束推理

把开放推理收敛为检查清单、决策树和标准 Workflow

约束执行

所有动作都必须经过 Tool、权限校验、审批、审计与回滚

约束反馈

结果自动沉淀为报告、案例、规则和知识

受控执行路径

只读建议

SRE 确认

有限自动化

自动回滚 / 人工接管

核心原则：先增强人，再自动化；先把边界收住，再把动作逐步放开。

● workflows - AI 提效后

从“执行者”转向“环境设计者”：描述意图、验收标准、边界条件，AI 在统一上下文与护栏内完成更多执行。

工程师 workflows - AI 提效后

从「执行者」到「环境设计者」：描述意图、验收标准，AI 全程参与执行



闭环：E4 运维发现的故障模式 -> 回流 E1 洞察 Skill -> 识别系统性改进点 -> 驱动新一轮需求立项与开发，形成正向飞轮

场景落地：为什么小红书这3类场景最值得先做

GUI -> LUI 的转化不是先做万能平台，而是先挑高频、证据链清楚、动作可控的场景，把人工动线真正改写掉。

筛选原则

- 高频：每天都在发生
- 高损失：影响体验、效果或成本
- 证据链清楚：能回到指标、日志、变更
- 动作可控：能先给建议，再逐步放开执行
- 能回灌：一次处置能沉淀为 Skill / Workflow

告警分析 / 降噪

- 人工动线很长
- 最适合先做“自动收集上下文 + 根因判断”
- 目标：让 AI 完成 80% 分析、50% 受控处置

推荐新笔记诊断

- 问题体感强、影响直接
- 最适合先做 Watchlist + 证据链诊断
- 目标：把专家经验变成值班可复用能力

巡检治理


- 覆盖率 / 有效性需要持续验收
- 最适合先做“自动核验 + 矩阵报告 + 优先级”
- 目标：从找问题升级到推闭环

后面我不会平铺很多 case，挑这 3 类最有代表性的场景，直接看“传统方式怎么做，AI 方式怎么改写”。

告警分析举例：人工动线如何被 AI 重写


告警场景最有代表性，因为它天然跨监控、发布、变更、资源多个系统，最能体现“人串平台”到“Agent 编排”的变化。

目前告警介入的人工动线



跨平台人工串联

结合 AI 后流程：AI 完成大部分分析和部分受控处置



80% 分析 / 50% 处置

最本质的变化：从“人到处找证据再判断”，变成“Agent 先把证据链补齐，再把判断推给人确认或受控执行”。

告警分析落地展示

左边看真实告警卡片，右边看能力全景，重点不过程多，而是让“单告警 -> 诊断闭环”一眼能看懂。

真实告警卡片和简报

XRay 告警机器人

P3

告警

[Prod][海外] RedImageV3 图片处理错误

服务

redimageservice-service-default · S1

告警规则

[RedImageV3] 图片处理错误

触发条件

表达式

value >= 5.0

持续

连续 2 次满足

当前值

18, 20

触发时间

14:28:16

数据时间

14:47:30

推送时间

14:48:31

⚠ 此告警未被认领，请尽快认领！

静默：

1小时 6小时 12小时 24小时

[查看事件] [认领事件] [静默] [规则配置] [指标详情] [变更事件]

✅ 已诊断：连接池耗尽（置信度 87%）

点击查看 →

诊断是否准确？

👍 准确

👎 不准确

X

XRay Agent

📊 昨日告警诊断简报

2026-04-07

🤖 Agent 判断

昨日有 2 个问题值得关注，建议今天处理：
① 连接池耗尽连续 3 天触发（creator-service），根治方案已生成但未执行
② 内流新笔记规则诊断成功率仅 57%，疑似规则阈值偏松，建议调整

🔥 creator-service 连接池连续 3 天触发，建议根治

已生成排障方案（回滚 + 配置修复），等待执行确认。如不处理，今日大概率再次触发。

查看根治方案

暂时忽略

⚙ 内流新笔记规则诊断成功率 57%，建议调整阈值

该规则近 7 天触发 14 次，其中 6 次诊断结论为「无明显异常」，可能是阈值过于敏感。

帮我分析阈值建议

查看规则详情

23

总告警

19

已诊断

82%

成功率

查看完整报告 →

87%

单条告警已能直接给出高置信诊断

能力全景

XPilot 告警智能诊断 · 产品全链路

三大场景协同，从 SKILL 配置到日报闭环的完整 AI Native 链路

🔗 场景 A · SKILL 绑定配置

告警规则 × 故障 SKILL 关联

🔗 场景 B · 实时告警诊断

告警触发 → AI 自动诊断 → Hi IM 推送

📅 场景 C · 每日告警日报

每天 12:00 推送业务总结告警分析

A1 业务解化故障 SKILL

业务侧针对高频告警场景，在技能广场创建故障 SKILL（如「新笔记下跌故障」「GC 异常故障」）

技能广场

xpilot/skill

A2 绑定告警规则

两种方式完成绑定：
① 技能广场页面：SKILL 卡片 → 绑定告警规则 → 搜索/筛选/批量选择
② 对话配置：「帮我查看推荐相关告警规则，把 1、3、5 绑定到新笔记下跌故障 SKILL」

页面配置

对话式配置

A3 配置生效 & 验证

绑定完成后，对应告警触发时自动调用关联 SKILL 执行诊断，支持查看绑定关系、测试运行、版本管理

绑定关系管理

测试运行

B1 告警规则触发

XRay 告警规则命中，生成告警事件，匹配已绑定的故障 SKILL

告警触发

Xray Rules Engine

B2 Hi IM 推送告警卡片

XRay 助手推送告警事件卡片到值班群，展示告警基本信息，底部显示「AI 诊断中...」状态

Hi IM 卡片

推送群

B3 SKILL 自动执行诊断

后台调用绑定的故障 SKILL，拉取指标/日志(Logview)变更数据，完成根因分析。卡片底部更新为「诊断完成-根因 + 置信度」

SKILL 执行

根因 + 置信度

B4 用户深度排障

点击「接着聊」→ 右侧 AI 对话侧边栏展开，诊断信息作为上下文，用户可继续追问、生成复盘、触发处置动作

Hi IM 侧边栏

处置 & 复盘

C1 定时聚合昨日数据

每天 12:00，按业务线/产品线汇总昨日所有告警事件：总量、级别分布、时段热图、服务分布

定时任务

按业务线聚合

C2 AI 根因聚类分析

对所有诊断结果做聚类：TOP 根因分布、重复告警识别、未诊断告警标注、告警风暴检测

AI 聚类

根因 TOP N

C3 规则优化建议

基于告警数据给出规则优化建议：误报率高的规则（可调阈值）、重复根因（可合并规则）、覆盖异常（建议新增规则）

优化建议

误报 / 漏报

C4 日报推送到业务群

以结构化卡片形式推送到各业务群，支持点击下钻查看详情，或在 XPilot 继续追问分析

Hi IM 推送

可交互卡片



SKILL 引擎
关联 SKILL 注册 / 调度 / 执行



规则绑定层
告警规则 × SKILL 映射关系



Xray 数据层
指标 / 日志 / Trace / 变更



AI 推理层
根因分析 / 聚类 / 置信度



Hi IM 推送层
卡片消息 / 对话侧边栏 / 日报

场景关系 & 数据流向

A → B

配置完成是实时诊断的前提，SKILL 未绑定的告警规则，触发后无法自动诊断，仅推送基础告警卡片。

B → C

实时诊断产生的根因数据，是日报聚类分析的数据源。诊断覆盖率越高，日报分析越准确。

C → A

日报的规则优化建议，反馈 SKILL 绑定配置的调整（如高频误报规则解绑 SKILL，或为漏配规则补充绑定）。

从绑定规则、推送卡片，到自动诊断和日报沉淀，链路已经成体系，不再是单点脚本。

● 推荐效果诊断：不是快一点，而是把专家经验工程化

这一类 case 的关键，不是多看一个面板，而是把“查哪里、怎么看、如何证明”这三件事一起沉淀成可复用能力。

现象：首页推荐效果曝光占比异常下跌



传统方式

- MTTR：小时级
- 高度依赖资深 SRE
- 单条对比易误判

AI 方式

- MTTR：十分钟级
- 任何值班同学都能独立执行
- 结论必须带证据

更值得记住的是：它不是简单加速，而是把专家经验沉淀成 Watchlist、证据链和双模式运行。

新笔记诊断结果展示

按“诊断报告 -> 关键根因 -> 建议动作”三段看，更利于大家理解。

1. 诊断报告

🔍 诊断报告：2026年3月20日 04:00-13:00 新笔记分析

📊 核心指标异常判定

指标	当前均值	昨天均值	差异	判定
1H新笔记占比	3.38%	3.66%	-7.78%	🔴 异常下跌 (>5%)
24H新笔记占比	34.86%	35.65%	-2.20%	🟡 正常范围

结论：1H新笔记占比异常下跌 7.78%，触发 SOP 异常阈值

⚠️ 高风险变更（6个🔴）

时间	实验名称	变更人
11:05	2026内流呼吸灯融合公式优化	今江
11:17	呼吸灯多兴趣召回	昼川
11:20	2026内流呼吸灯融合公式优化	今江
11:30	呼吸灯多兴趣召回	昼川

- 呼吸灯实验变更 导致召回策略调整
- DSSM_EMB_I2I_OUTOF24H_1000PV 召回渠道暴跌 98%，显著影响新笔记供给
- 该渠道专门为「超24小时但不满1000PV」的笔记设计，是长尾新笔记的重要召回源

📁 建议排查方向

1. 立即检查呼吸灯实验变更 — 特别是 11:30-11:50 之间的影响
2. 确认 DSSM_EMB_I2I_OUTOF24H_1000PV 渠道 — 是否被实验配置意外关闭/限制
3. 检查召回Quota — 呼吸灯召回增加是否挤压了新笔记Quota

这是典型的「实验变更 → 召回渠道受限 → 新笔记供给下跌」故障链。

2. 关键根因

🔴 召回渠道异常

渠道	当前	昨天	比率	状态
DSSM_EMB_I2I_OUTOF24H_1000PV	1.5	62.0	0.02	🔴 暴跌98%
DSSM_OUTOF24H_1000PV	0.9	1.1	0.81	🔴 异常

关键发现：DSSM_EMB_I2I_OUTOF24H_1000PV 召回量从昨天 62.0/min 暴跌至 1.5/min，跌幅 98%!

💡 初步诊断

时间线分析：

1. 04:00-11:00 — 正常（无高风险变更）
2. 11:05-11:49 — 6个呼吸灯实验密集变更
3. 12:46-13:00 — 1H新笔记占比出现 7.78% 下跌

AI 不是只报“异常”，而是已经能把根因和下一步动作一起结构化给出来。

治理闭环与影响面计算：为什么会走向规模化治理

当治理从单服务检查走向共享骨架和规模化影响面分析，下一步自然就会走到统一编排中枢。

治理闭环



影响面计算

关键问题不再是单服务有没有风险，而是哪些能力属于共享骨架、会跨场景放大影响。



只有把共享骨架看清楚，影响面才可能从“靠经验判断”升级为“可计算分析”。

当治理从单点检查走向共享骨架和规模化影响面分析，下一步自然就是：把多场景能力收进统一编排中枢。

巡检治理结果展示

先看风险优先级，在看容量风险和止损建议，我们还有服务告警矩阵有效性检查，篇幅问题没贴。

风险优先级

览
鸿鹄平台) - P0
HA平台) - P0
HA平台) - P1
HA平台) - P2
处理) - 43条
处理) - 21条

架构风险 (HA平台) - P0

风险数量: 31 条

风险类型	数量
所有多活链路需要配备rgw内网切流编排预案, 具备内网流量纠偏能力	15
预案腐化	11
集群不满足容灾达标要求	2
MySQL连接参数没有设置socketTimeout	1
redis禁止访问大key	1
服务间依赖关系在ha链路拓扑标记为弱依赖,未配置熔断	1

架构风险 (HA平台) - P1

风险数量: 161 条

风险类型	数量
高可用服务不可切换	105

容量止损建议

容量止损建议

判断逻辑:

- GPU服务: GPU水位 / GPU阈值 与 容量水位 差异 <15% → GPU资源不足, 需扩容
- CPU服务: CPU水位 / CPU阈值 与 容量水位 差异 <15% → CPU资源不足, 需扩容
- 差异 ≥15% → 资源水位良好, 排查其他因素 (内存/磁盘/网络/下游延迟)
- 未配置阈值 → 人工排查

1. arkhouyi-90-default (qcnj2/S0)

- 容量水位: 103% CPU水位: 45% GPU水位: -
- 规格: 700 Pod × 30C | GPU: - | MEM: 60G
- 负责人

CPU水位良好, 排查其他因素 (内存/磁盘/网络/下游延迟)
CPU水位 45% / 阈值 55% = 82% ≠ 容量水位 103%

2. lve-note-02-merger-default (rcsh1/S0)

- 容量水位: 103% CPU水位: 58% GPU水位: -
- 规格: 17 Pod × 13C | GPU: - | MEM: 20G

先用风险视图判断优先级，再用容量、告警、架构分析建议给出止损动作，治理才算真正可执行。



为什么很多团队会自然走到统一编排中枢

真正需要统一的不是界面，而是任务识别、证据装配、治理边界和知识回灌这四件事。

上下文割裂

- 监控、日志、Trace、变更、资源散在不同系统。
- 统一中枢先解决“看见事实”的问题。

流程割裂

- 不同人处理同类问题路径不同。
- 统一中枢把高频路径沉淀为 Skill 与 Workflow。

治理割裂

- 审批、审计、灰度、回滚分散在各处。
- 统一中枢把受控执行边界集中管理。


知识割裂

- 事故复盘、案例、Watchlist 难以复用。
- 统一中枢把一次经验沉淀成持续可用能力。

所以“统一编排中枢”不是为了做一个更大的平台，而是为了让多场景能力在同一套边界里持续复用。

统一编排中枢：AI Native SRE 的生产级骨架

基于统一入口、统一编排、统一 Tool、统一上下文和统一治理，让多场景能力不再是零散脚本或单点 Copilot。



AI SRE指标体系

AI SRE不是做出来，而是评出来、管出来，没有评估的Agent，只是 demo，没有治理的自动化，只是风险转移

指标原则：指标不是为了好看，而是用来判断一个Agent是否能从只读建议进入人机协同，再进入受控执行

01

效果指标

诊断准确率、RCA TopN 命中率、建议采纳率、误报率、漏报率。

02

效率指标

MTTA、MTTR、巡检耗时、报告生成时延、问题闭环时长。

03

安全指标

越权率、误执行率、回滚成功率、人工接管率、例外审批占比。

04

运营指标

场景覆盖数、知识复用率、自动沉淀率、闭环率、策略保鲜率。

演进路径：从 Copilot 到 Autopilot

不要把自动化的理解成一步到位，真正可行的路径一定是先单场景闭环，再逐步放开。



落地规范

这些方法不是为了做一个更聪明的 Demo，而是为了让 Agent 从能答，升级到敢接生产、也能被治理。

可审计

动作要带 traceId、审批链和操作记录，做不到可追溯就不该进生产。

可回滚

执行链必须有失败兜底和恢复路径，高风险动作始终保留人工触发。

可解释

每条建议都要回到指标、日志、配置或事件证据，低置信结论不能直接执行。

可接管

自动化失效时，人必须能迅速接回控制权，切换到人工流程不能有断点。

算得清

收益、风险、资源成本要一起设计，自动化放得开，也要收得住。



反面经验：最容易做错的 4 件事

1. 一上来就追求Multi-Agent

- 单场景都还没闭环，就开始堆角色和编排。
- 更稳的做法是先把一个高频场景做深，再决定是否平台化。

2. 让Agent 直接自由操作生产

- 把创造性直接带进执行层，风险会被急剧放大。
- 真正进入生产前，必须先有 Harness、权限、审计和回滚。

3. 只看Demo体验，不看eval与治理

- 回答像不像人，不等于能不能进生产。
- 没有评估、审计和灰度能力，Demo 很难变成生产能力。

4. 只做单次提效，不做回灌与复用

- 一次提效很容易，持续复用才是真正壁垒。
- 报告、案例、Watchlist、SOP不回灌，团队会不断重复交学费。



总结：从 AI-in-SRE 到 Agentic SRE

SRE 的角色升级

- 保障对象从服务 SLA 扩展到模型、算力、链路和 Agent 决策链。
- SRE 会逐步从故障响应执行者，走向机制设计者、策略治理者和平台编排者。

更现实的落地顺序

- 先从一个高频、证据链清楚、动作可控的场景开始做。
- 先把 Skill / Tool / Workflow 跑通，再决定是否进入统一编排和有限自动化。

适用范围

没有复杂平台也可以从单场景开始做，先把证据链、Workflow 和知识回灌跑通。

组织变化

组织分工会从“人肉响应”转向“机制设计 + 策略治理 + 平台协同”，这也是SRE下一站的真实变化。

真正不会被 AI 替代的，不是会处理故障的人，而是能把经验沉淀成系统能力、把 AI 驯化成可控生产力的人。

01 如果没有复杂平台，也值得做 AI SRE 吗？

02 多 Agent 和自动化，什么阶段才应该放开？


03 怎么判断一个 Agent 能不能进生产？

QCon
全球软件开发大会

THANKS

大模型正在重新定义生产系统

AI不是来替代 SRE，而是通过SRE 设计的 Agent，
让系统更快地学会稳定运行。



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

