

QCon
全球软件开发大会

AI 大模型重塑垂域任务： 淘宝闪购搜推商品理解的全新建模

董正心

阿里巴巴淘宝闪购 算法工程师

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

01 淘宝闪购搜推内容理解背景

02 搜推内容理解任务介绍

03 垂域统一训练范式

04 垂域多模态大模型数据&训练

05 大模型标注&质检飞轮

06 小结

01

淘宝闪购搜推内容理解背景

商品内容理解

为什么要做?

➤ 提升搜索体验

准确理解商品类目和属性，让用户用自然语言快速找到目标商品，降低搜索失败率

➤ 精准个性化推荐

深度解析商品特征，构建商品匹配模型，提升点击率和转化率

➤ 优化商品展示


生成高质量标题和卖点，帮助商家提升商品曝光度和购买吸引力

➤ 平台治理与风控

识别属性错误、类目错放等问题，维护平台商品质量和用户权益

系统整体架构图

搜推系统架构 & 商品理解/Query理解



- Query理解（红色）：位于系统入口，负责理解用户搜索意图
- 商品理解（蓝色）：位于商品侧，负责理解商品属性、类目、卖点

两者作用在召回和排序阶段，决定最终展示结果

核心定位

我们的垂域大模型处于搜推系统的"大脑"位置，是连接用户意图与商品信息的桥梁



Query理解

1. Query纠错




2. Query改写



3. Query-NER



4. Query类目预测




5. Query-tagging



商品理解

1. 类目预测



2. CPV预测



3. 卖点生成



4. 标题改写



5. 同品归一



商品理解&意图理解：应用场景



02

搜推内容理解任务介绍

商品理解：类目预测

任务介绍

类目预测是平台管理海量商品的最基础的手段。

根据商品信息，在类目体系范围内，判断商品所属的最合适的分类节点（如“手机”、“女装/连衣裙”）。

示例：

输入商品信息

“苹果iPhone15Pro256GB手机”

输出预测类目

“叶子类目=手机”



类目错 → 筛选器失效 → 搜索不相关 → 推荐不准 → 转化率低
类目对 → 筛选有效 → 搜索精准 → 推荐个性化 → 转化率高

LLM-QA任务

零少样本泛化能力强

复杂语义理解能力

多模态理解能力



User: 结合图片和文本信息，这张图片里是一个商品，请问它属于哪一类商品？商品可以区分为以下类别：一级类目...

User: 结合图片和文本信息，已知该商品一级类目为xxxx，请进一步判断该商品属于以下哪个类别：二级类目...

一级类目：xxxx

二级类目：xxxx

三级类目：xxxx

四级类目：xxxx

预测类目路径

xxxx > xxxx > xxxx > xxxx

商品理解：CPV预测+卖点生成

任务介绍

属性预测是连接“用户意图”与“商品供给”的最细粒度桥梁。

识别并结构化商品的关键特征，包括属性项(Property)及其对应的属性值(Value)。

示例：

输入商品信息

“白色纯棉圆领T恤 M码”

输出cpv预测结果：


“颜色=白色;材质=纯棉;款式=圆领;码数=M码”

卖点：


“纯棉透气，简约大方”

LLM+RAG

解决实体边界破碎问题
复杂语义理解
泛化新属性
检索外部知识库



多模态理解商品信息
多样性丰富
端到端生成，链路高效



多任务孤岛

各任务独立微调导致重复训练、资源浪费，任务间知识无法共享协同

知识遗忘

灾难性遗忘现象：垂域训练导致通用知识和能力显著下降，基础推理能力受损



数据依赖

高度依赖高质量垂域标注数据，数据稀缺或噪声大时效果急剧下降

泛化局限

跨域迁移能力弱，面对分布外数据时鲁棒性差，难以适应动态变化

03

垂域统一训练范式

研究背景

研究背景

1. 通用 LLM 的局限性

- 尽管通用大模型在通用任务中表现优异
- 但在外卖领域的研究相对稀缺，存在领域适配问题

2. 外卖平台的智能化需求

- 核心需求：理解用户购买意图、分析商品相关信息
- 在提高用户便利性的同时，对智能性提出了更高要求
- NLP 技术在此过程中发挥关键作用

核心挑战

挑战一：数据稀缺问题

- 外卖领域与电商领域存在显著差异
- 现有 NLP 数据集无法满足外卖平台在商品信息和用户意图方面的特定需求
- 迫切需要构建专门针对外卖领域的中文 NLP 数据集

挑战二：训练方法效率问题

- 外卖领域任务多样性高、数据特异性强
- 现有训练方法导致：高计算资源消耗、复杂的训练过程、缺乏有效的领域适应框架、缺乏领域特定模型
- 迫切需要更高效、节省资源的训练框架

12 个 OFD 领域 NLP 任务

标题生成 (ITG)

根据商品属性生成简洁标题，或者根据用户需求生成C端展示标题

属性提取 (IAE)

从商品标题提取品牌、系列等属性

类目预测 (ICP/ICPSI/ICPMRD/QCP)

基于标题/店铺/多轮对话预测商品类目

同品匹配 (ISP/ICSPU)

SPU/CSPU 预测，属于同一个SPU/CSPU的商品会被聚合到一起

Query 标注 (QT)

识别用户搜索查询中的词性标签

搜索相关性 (QIRR/QIRF/QSR)

Query-商品/店铺相关性评估

160万+ 指令样本

18.7万 测试样本

涵盖 12 个 OFD 相关 NLP 任务

包含无监督数据用于 PPO 训练

Table 2: Data Details in FoodInstruct

Task Category	Task Name	Query or Item	Retail or Food	Train Size	Test Size	Unsupervised Size
Title Generation	Item Title Generation	item	retail	1198	600	200
Information Extraction	Item Attribute Extraction	item	retail	79777	21943	7000
	Query Part-of-Speech Tagging	query	retail & food	424377	47152	15000
Category Prediction	Item Category Prediction	item	retail	7637	1909	600
	Item Category Prediction with Shop Information	item	retail	341493	53915	18000
	Item Category Prediction using Multi-turn Dialogue	item	retail	49501	9872	3000
	Query Category Prediction	query	retail & food	70324	8449	2800
Product Matching	Item CSPU Prediction	item	retail	40343	5000	1600
	Item SPU Prediction	item	retail	327503	5000	1600
Search Relevance	Query-Item Relevance for Retail	query-item	retail	71415	7933	2600
	Query-item Relevance for Food	query-item	food	91794	10197	3000
	Query-Shop Relevance	query-shop	retail & food	142210	15800	5000




Figure 2: Examples in FoodInstruct.

FoodInstruct



Post-Training强化学习框架：两阶段

业界常用方案

LLM的Post-Training的两种经典模式：

- 一种是仿照ChatGPT的SFT+RM+PPO的模式，需要调大量超参
- 一种是SFT+DPO的模式，相对简化整个流程

我们的两阶段后训练框架：

阶段1.SFT+DPO+PPO


阶段2.垂域任务微调

易实现的简化流程：

- step1.SFT: base模型初始化 + SFT训练集 + lora
- step2. 偏好数据: SFT模型 + SFT训练
- step3. RM: SFT模型初始化 + 偏好数据
- step4. DPO: SFT模型初始化 + 偏好数据
- step5. PPO: DPO模型初始化 + RM模型 + SFT测试

优势：

- 降低训练数据依赖
- 低成本后训练
- 高效适配垂域任务



*KDD'25 ADS Track 《FoodGPT: Reinforcement Post-Training of Large Language Models in the Food Delivery Domain》

Post-Training强化学习框架

DPO

$$\mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} \right) - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right] \quad (1)$$

RM

$$\mathcal{L}_{\text{RM}}(\theta) = -\frac{1}{\left(\frac{K}{2}\right)} \mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [\log (\sigma (r_{\theta}(x, y_w) - r_{\theta}(x, y_l)))] \quad (2)$$

PPO

$$\text{Objective}(\phi) = \mathbb{E}_{(x, y) \sim D_{\pi_{\phi}^{\text{RL}}}} \left[r_{\theta}(x, y) - \beta \log \left(\frac{\pi_{\phi}^{\text{RL}}(y | x)}{\pi^{\text{DPO}}(y | x)} \right) \right] + \gamma \mathbb{E}_{x \sim D_{\text{pretrain}}} [\log \pi_{\phi}^{\text{RL}}(x)] \quad (3)$$


核心经验

- 1 DPO 的主要价值在有监督语料上，通过偏好数据让模型学习负样本，纠正错误倾向
- 2 PPO 的主要价值在大量无监督数据上，在 DPO 之后再 PPO 效果更好
- 3 PPO 使用 DPO 模型初始化，更低学习率 (1e-8)，迭代 1~2 个 epoch 即可

FoodInstruct 消融实验&任务表现

Model		ISP	ICSP	ICP	ICPMD	ICPSI	IAE	QCP	QIRF	QIRR	QPoST	QSR	ITG	Avg
ICL Baseline	gpt4o + few shot	66.37	62.09	83.78	69.05	90	65.47	82.19	74.03	85.17	52.74	75.72	85.67	74.36
	deepseek R1 + few shot	82.49	71.44	79.9	79.6	90.95	68.96	88.66	76.52	74.83	80.2	81.29	88.17	80.25
Baseline	Qwen2.5 + SFT	91.36	93.58	91.51	94.04	94.03	83.27	92.52	87.56	91.83	80.13	91.01	94.84	90.47
Ours	FoodGPT + SFT	91.56	93.76	92.3	94.12	93.07	83.17	92.19	88.83	92.3	84.23	91.67	95.35	91.05

Model		ITG	ICSP	ICP	ICPMD	Avg
baseline	Qwen2.5 + SFT	94.84	93.58	91.51	94.04	93.5
	Llama3.1 + SFT	91.29	93.44	90.73	92.13	91.9
	deepseek-llm + SFT	74.63	87.94	91.36	94.25	87.05
ours	FoodGPT + SFT	95.35	93.76	92.3	94.12	93.88



性能提升

12 个任务中的表现

9/12

任务提升

+0.58%

平均提升

+4.1%

最大增益

训练迭代次数

5

Baseline Epochs

2

FoodGPT Epochs

训练数据需求

100%

Baseline

40%

FoodGPT

关键结论

FoodGPT 作为 OFD 领域的基础模型，显著减少下游任务所需的监督数据量和计算成本。

04

垂域多模态大模型数据&训练

多模态问题与挑战

1 开源VLM缺乏垂域知识

通用视觉语言模型在饿了么外卖/零售场景下表现不佳，缺乏对食品、餐饮商品的细粒度理解能力。

2 商品图像识别精度不足

现有模型难以准确识别商品图片中的细粒度信息（配料、口味、包装规格等）

3 任务导向能力不足

通用VLM偏向对话能力，而业务需要的是面向特定任务的精准预测能力。

示例：

绿箭草本清润含片金银花蜂蜜柠檬



通用VLM模型回答：图片中主体是一个深色背景下的白色圆形口香糖包装。包装上有一个橙色的圆形图案，中央绘有一个半透明的柠檬片和黄色的蜂蜜，以及一些蜜蜂。包装上还印有“DOUBLEMINT”、“Wrigley's”、“Doublemint”、“爽口含片”、“薄荷醇”等字样。包装下方还有一串英文“EAGLE”、“SODA”、“CANDY”等字样。包装的右侧还有一个椭圆形的橘色长条。

多模态训练数据生成方案

研究背景

1. 缺乏垂域多模态caption数据

通用caption数据的关注重点与垂域任务有gap，缺乏垂域任务的关键决策信息。

2. 缺乏垂域多模态VQA数据

如果只用垂域任务来做混合训练，限制了指令的多样性、复杂性，可能会产生灾难性遗忘，严重丧失通用知识，导致回答质量下降。

研究目标

生成垂域多模态数据

对垂域数据进行了生成合成，一是为了提高指令的多样性和复杂性，二是为了补充更多的领域知识，在垂域任务上带来增量提升。围绕餐饮图谱、零售图谱以及商品信息展开。


- 高效生成，降低标注成本
- 保证数据量级、内容多样性
- 餐饮&零售数据差异化生成

特点	Caption 数据	VQA 数据
任务类型	生成任务 (图像→文本)	判别任务或生成任务 (图像+问题→答案)
信息粒度	全局描述 (整体场景)	细粒度理解 (特定物体、关系)
交互性	单向 (视觉到语言)	双向 (需理解问题并定位视觉内容)
数据复杂度	较简单 (描述为主)	较高 (需多模态推理)
典型模型应用	图像描述生成、跨模态检索	视觉问答、交互式对话系统
形式	pair对: (图像, 描述)	三元组: (图像, 问题, 答案)

1. **Caption 数据**: 帮助模型建立基础的视觉-语言对齐能力。
2. **VQA 数据**: 进一步提升模型对细节和复杂问题的处理能力。
3. **混合训练**: 例如 LLaVA等模型通过交替训练两种任务，增强多模态理解与生成能力。



多模态训练数据生成方案



基础数据来源

更关注垂域任务相关的判断条件:
商品名/副标题、商品类目、商品图片、商品描述、店名、店铺类目、商家自填属性、算法图谱数据.....

任务难度演进

简单指令

(图片描述、图片细节问答)




复杂指令

(图片细节描述、cot视觉推理)

多模态训练数据生成方案

1. 2stage—Caption



商品信息+图+属性列表schema->商品属性->详细描述


2. Self—KG—Caption

商品名	商品类目	商品图片	食材	主食	操作方式	口味	盛器
腊肠拼酸豆角煲仔饭	主食米面粉类>米类>饭类>煲仔饭/石锅饭		大米, 腊肠, 豇豆, 辣椒	米饭	焖	咸, 川香, 微辣, 酸	煲仔

Output: 这道菜品名为“腊肠拼酸豆角煲仔饭”，是一款以煲仔盛装的经典米饭菜肴。选用优质大米作为主食，经过焖煮使米饭软糯入味。配料包含腊肠、豇豆、和辣椒，其中腊肠切片，咸香可口，豆角经过酸辣调味，夹杂着微微的酸味和川香辣味，刺激味蕾。辣椒的加入为整道菜增添了少许辛辣气息，适合喜食微辣的食客。整体口感丰富，层次分明，是一道兼具咸、香、辣、酸四种风味的特色煲仔饭。

仅依赖商品自身信息，垂域特色

3. 套餐数据



套餐商品作为重要的治理目标，通常包含多个子商品，图片信息复杂，与单品有明显区别。

- 首先精心设计多条种子问题，问题类型和领域要足够丰富。
- 对于每条样本首先使用基于套餐描述的 caption 合成方式生成详细的图片 caption。
- 用图片的 caption、种子问题构成 prompt，要求模型生成指令，并进行回答。


优势:

- >针对每一条样本的特点提出不同的问题
- >结合商品信息进行准确地回答




多模态训练数据生成方案

1. KG-Self-Instruct




通过领域内知识 (标题/属性/描述) 作为问答方向, 引导模型对图片进行自我问答

3. Star-Cot



2. MM-Evol

在生成的n个QA里随机抽取k个QA进行演进, 进行图文对齐同时提高指令复杂度和多样性



迭代式生成, 通过自我验证答案的正确性推理思维链, 得到cot数据。两种方向:

方向1) 给问题推理答案

- step1. 问题-> 新答案
- step2. 新答案 + 旧答案 -> 判断新答案是否正确
- step3. 新答案不正确 -> 给问题+答案, 得到推理过程



方向2) 给问题+答案, 得到推理过程



垂域多模态大模型训练方案

在训练数据准备好后，垂域训练分三个训练阶段：

- stage1: 预训练阶段，在已初始化的LLM和ViT基础上继续训练，更新全部模型参数。（本期没做）
- stage2: 领域指令对齐阶段，进行领域知识问答&垂域多任务混合，在训练指令跟随能力的同时提升领域理解能力，主要做全参SFT训练。
- stage3: 垂域任务微调，具体到单个任务上，提高任务表现。



核心训练策略与收益

多任务混合训练

将多种垂域任务数据混合训练

收益：非标类目预测提升 +2.41%

渐进式训练策略

从通用对齐 → 领域对齐 → 任务特化，逐步递进

收益：避免灾难性遗忘，保持通用能力

任务导向型训练

面向特定业务任务设计训练目标，而非通用对话能力

收益：垂域任务精准预测

数据配比优化

通过实验确定最佳数据配比，平衡通用能力与垂域性能

收益：模型泛化能力显著提升

消融实验1：LoRA微调 vs 全参训练

实验结论 全参训练相比LoRA在垂域理解能力上表现更优，能学习到更多领域知识

关键发现 LoRA基座+LoRA微调效果反而下降，基座训练需要全参训练来保证领域知识学习

收益 垂域任务全参SFT相比base提升 +2.36%

消融实验2：LoRA秩 (Rank) 的影响

实验结论 数据量较少时（千级别），增大LoRA秩无显著提升，效果反而下降

Scaling Law 如果数据量少，即使增大模型容量（rank），带来的收益也很有限

最佳实践 小数据量任务建议rank=16，5 epoch即可达到最优效果

消融实验3：VLM vs LLM纯文本能力对比

关键发现 更小的VLM在纯文本任务上超越更大的LLM，多模态训练增强了文本理解能力

模型效率 更小的VLM模型(7B)达到更大LLM(14B)的效果，参数效率更高

能力迁移 多模态预训练带来的视觉-语言对齐能力迁移到了纯文本任务

消融实验3：VLM vs LLM纯文本能力对比

关键结论 仅用50%数据，通过比例调整达到全量数据相近表现

最优配比 Caption:VQA:任务 = 50%:15%:35%，任务数据占比提升带来显著收益

数据效率 合理配比 > 数据堆砌，质量与配比同样重要

05

大模型标注&质检飞轮

数据飞轮迭代优化数据质量

基于大模型的数据飞轮：

目前已经在业务场景中广泛应用，作为**基础能力建设**，**降低对标注人力的依赖**；

先由大模型生成或预标注数据，再经过预检/多模型投票/置信度评估筛选出高质量样本；低置信样本进入人工复核；复核后的数据反馈回训练集，推动模型持续迭代提升，形成“**生成—筛选—人工校正—回流训练—再提升**”的闭环。



- 大幅降低标注成本
- 保证数据质量
- 提高标注效率
- 实现持续迭代

06

小结

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The
Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

