

QCon
全球软件开发大会

构建可扩展，可隔离的 AI Agent 运行环境

阿里云 AgentRun 产品技术负责人：赵庆杰

InfoQ 2026 · AI Agent Infra

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

AI Agent 时代的基础设施变革

阿里云 AgentRun 企业级 Agent 平台

关键技术能力深度解析

客户实践与案例分享

Agent Infra 的核心挑战与设计原则

未来展望与总结

01

AI Agent 时代的 基础设施变革

从 Prompt Engineering 到 Harness
Engineering



企业级 Agent 开发面临的六大挑战

1

开发模式多样 难以持续演进

不同层次开发者需要无代码/低代码/
高代码多种模式，期望持续演进

2

高性能安全 执行环境难构建

Agent 需安全隔离的执行环境运行代码
自建成本高、性能差、安全隔离困难

3

模型和工具 服务稳定性差

Agent 依赖大模型和外部工具服务
缺乏统一的容错和治理机制

4

效果评估和 持续优化困难

Agent 运行是黑盒，无法评估效果
不知道如何优化，成本不透明

5

企业数据安全和 合规挑战

涉及知识库、用户数据等敏感信息
数据安全和合规是最大顾虑

6

多 Agent 协同 缺乏基础设施

Agent 间通信、状态管理、失败恢复
分布式编排与调度复杂度高

AI 工程方法的三次演进

Prompt Engineering 2022-2024

关注如何表达需求
打磨单次对话里的指令
研究怎么提问、给出示例

Context Engineering 2025

关注怎么提供恰到好处的信息
上下文裁剪、压缩、按需检索
在有限 context window 下组织背景资料

Harness Engineering 2026

关注如何构建系统
运行环境 + 工具调用 + 记忆 + 评估
 $\text{Agent} = \text{LLM} + \text{Harness}$

核心洞察：一旦模型能力过线，瓶颈就会外移。智力本身不再是瓶颈，瓶颈转移到了系统层。

Agent = LLM + Harness: 六大关键组件



信息层（准备信息）→ 执行层（推动执行）→ 反馈层（复盘结果）



为什么 AI Agent 基础设施成为核心竞争力

训练即部署

Agent 能力的上限由环境质量决定

Cursor 用真实用户 coding 环境训练 Composer

Windsurf: 环境质量对模型表现影响最大

Harness 被模型吸收

模型公司把"模型+Harness"当整体优化

tool search、programmatic tool use 等

能力已被模型内生

Harness 即数据飞轮

真正有价值的数据: Agent 跑出来的执行轨迹

Harness 不再只是脚手架

而是模型能力生成的土壤

Multi-Agent 协同时代

从个人 Vibe Coding 到多 Agent 协同开发

峰值日消耗 12 亿 Token

需要完善的 CI/CD 与 Harness 体系

03


阿里云 AgentRun 企业级 Agent 平台

以高代码为核心、生态开放、灵活组装的一站式 Agentic AI 基础设施平台



函数计算 AgentRun 助力企业加速 AI 创新

AgentRun是以高代码为核心、生态开放、灵活组装的一站式 **Agentic AI 基础设施平台**，为企业级 Agent 提供开发、调试、部署、运维的全生命周期管理。助力企业和开发者专注于 AI 业务创新，无需自建和管理底层基础设施，让 Agentic AI 真正进入企业生产环境。





函数计算 AgentRun: 产品定位与架构

以高代码为核心、开放生态、灵活组装的一站式 **Agentic AI** 基础设施平台
为企业级 **Agent** 提供开发、调试、部署、运维的全生命周期管理

构建	运行时	部署	稳定	效果	安全
高低代码一键转换 拥抱主流 AI 开发框架 AgentScope/LangChain/ADK Qoder 智能生成	开箱即用 Sandbox Agent/Code/Browser/AIO 安全隔离、高性能 毫秒级弹性	全栈 Serverless 极致弹性、按需付费 免运维 零到百万级并发	AI Gateway 治理 模型 Fallback 熔断降级 并发控制	全链路可观测 Agent/Rag/Tool 评估 数据飞轮 持续优化	VPC/IDC 互通 数据不出域 凭证管理 权限隔离

AgentRun 四大核心优势

Serverless 基础设施

- 自动应对 0 到百万级并发
- 毫秒级冷启动和弹性伸缩
- 按量付费，不使用不计费
- 无需管理服务器/容器/K8s

零运维、极致弹性、按量付费

企业级 Runtime 与安全隔离

- 高性能多语言 Sandbox
- 多维度隔离(会话亲和/请求隔离)
- 统一模型代理、熔断降级
- MCP 标准化治理

高性能、高安全、开箱即用

开源开放 无框架锁定

- 兼容 AgentScope/LangChain 等 5+ 框架
- 无代码一键转高代码
- 深度集成 RAGFlow/Mem0
- 模块化使用，可散件集成

数据不出域，灵活集成，平滑演进

全链路 可观测与评估

- 端到端全链路 Trace
- 细粒度成本归因
- 实时性能监控、智能异常诊断
- Agent/Rag/Tool 多维度评估

看得清、管得住、优化快

AgentRun 赋能 Agent 研发全生命周期闭环



04 关键技术能力 深度解析

Runtime & Sandbox / 上下文工程 / 可观测与
评估

企业级 Runtime 与安全隔离: Agent & Sandbox 运行时

Agent Runtime	Code Sandbox	Browser Sandbox	AIO Sandbox
AgentScope / LangChain LlamaIndex / CrewAI / ADK 轻量化函数 毫秒级弹性	多语言代码执行环境 内置 Python/Node/Java 安全隔离, 防数据泄露 支持 Skills 挂载	浏览器自动化环境 Web 爬取与信息提取 表单填写与页面交互 截图与内容分析	全能沙箱环境 Computer Use 能力 复杂工作流编排 GPU 算力解耦

百万级
函数 & 会话规模

毫秒级
冷启动加速

60%↓
平均 TCO 降低



会话亲和与隔离 / Sandbox 实例动态挂载

会话亲和 & 会话隔离

会话亲和 (MCP 场景强诉求)

同一用户请求始终路由至同一实例

避免 SessionID 丢失和工具调用失败

支持 MCP SSE / Streamable HTTP /

Header Field / Cookie 四种亲和类型

会话隔离 (Sandbox 场景强诉求)

一个 Session 独占一个函数实例

避免不同请求间的数据残留和泄漏

POSIX 标准多租存储安全实践框架

Sandbox 实例动态挂载

传统架构的问题

多租户数据共享有安全风险

无法满足每个实例路径不同的需求

挂载存储路径变化不确定

Serverless AI 解决方案

会话粒度存储粘性

会话与特定租户存储子目录强绑定

层次化纵深防御体系

mount /user-id/session-id 独占目录

上下文工程：记忆系统 / 知识库 / MCP & Skills

Memory 系统

- 情景记忆 / 语义记忆 / 技能记忆
- 全量会话记忆与会话缓存
- 记忆可追溯、可定义、可优化
- 采用开源 Mem0，数据不出域

知识库 / RAG

- 插拔式支持企业知识库
- 拥抱开源 RAGFlow
- 上下文模式 + 工具模式
- 跨平台知识检索

MCP & Skills

- MCP + Function Call 双协议
- 海量工具一键集成
- AI 自动生成工具代码
- Skills 支持 Sandbox 和动态挂载

可插拔设计：生态开放、灵活组装 —— 一键托管或绑定已有部署（VPC/IDC），企业数据不出域



全链路可观测与 Agent 评估

AI 全栈统一监控

基于 Prometheus 构建 AI 全栈监控大盘

模型性能分析

Token 成本分析

GPU 资源异动分析

端到端链路追踪

基于 OpenTelemetry Trace 全链路追踪

用户终端 → 网关 → 模型应用

→ 模型服务 → 外部工具

Agent 质量评估

在线评估: 运行时 Trace 自动评估

离线评估: Trace 生成数据集对比实验

评估指标: LLM / Tool / Token / Score

数据飞轮持续提升

反馈评估 → 数据标注 → 测试集回放

→ 模型微调 → 持续迭代

清晰捕捉变更对质量的影响



模型运行时与 AI Gateway 治理

Serverless 模型运行时

开箱即用的模型部署

内置 vLLM / SGLang / Ollama / LMDeploy

最快 30s 转化为 OpenAI 兼容 API

2 万+ 热门模型一键托管到云上环境

弹性交付

DevPod 二次开发

弹性交付 GPU, 低峰缩 0

CPU/GPU/MEM 算力解耦

1/N GPU 卡灵活切分

AI Gateway 治理能力

统一模型代理

支持 30+ 模型服务提供商直连

通义千问 / DeepSeek / OpenAI / Gemini

企业级治理

多模型负载均衡与 Fallback

并发控制与限流

响应缓存与超时控制

统一凭证管理

Token 用量统一管理

05

AgentRun 企业级实战


FunClaw — 基于 AgentRun 打造企业级
Agentic AI 助手方案

企业级 Agentic AI 整体方案架构



FunClaw 是 AgentRun 团队自研并实战验证的企业级方案

FunClaw 平台架构图



超级 Agent：智能中枢与能力生态

超级 Agent 作为统一智能中枢，以自然语言为入口完成任务理解、拆解、编排与执行。

智能分发与任务编排

- 具备自然语言理解和意图识别能力
- 将复杂需求智能分解为多个子任务
- 自动选择最合适的 Agent 或工具执行
- 从对话到 PPT 制作，统一入口完成
- 实现真正的一站式 AI 服务体验

能力生态整合管理

- 支持创建自定义 Agent，连接万种能力
- 注册接入外部平台 Agent 和工具
- 构建个性化能力生态系统
- 可视化统一管理所有能力资源
- 打破平台壁垒，让 AI 能力形成协同效应

两种交互模式：简单任务直接响应；复杂任务进入多 Agent 协作，由 Manager 拆解、Worker 执行、系统汇总。

FunClaw 企业级部署与安全隔离

一键部署安全加固方案

- 开源一致体验，资源用量可预估
- Serverless 隔离运行环境，支持大规模弹性扩展
- 中心化 AI 网关避免 API Key 泄露
- 全链路日志审计，HTTPS 加密访问

FC Sandbox 自定义部署

- MicroVM 级别运行环境隔离
- 会话隔离：一会话一实例
- 动态挂载独立存储，结束自动清零
- VPC 安全组 + 网络 ACL 白名单

运行隔离

网络隔离

存储隔离

权限隔离

会话隔离

五重安全防线：每个会话独享函数实例，任务结束即销毁，零残留

企业级管理：SSO 集成 / 组织权限 / 资产中心 / 灰度发布 / 全链路审计合规

FunClaw 一键部署架构与弹性计费

基于阿里云 Serverless 构建完整部署链路，可一键拉起云端 FunClaw 实例。

模型支持：智谱 GLM-5 / 千问 Qwen3.5-Max / DeepSeek 等主流基座模型

弹性计费模式

- 活跃计费：CPU 利用率高时正常计费
- 闲置计费：CPU 低负载时自动降本
- 日间扩容 / 夜间缩容，自动伸缩
- 资源用量可预估，统一出账

安全加固特性

- HTTPS 访问加密
- 黑白名单权限隔离
- SLB 统一入口监听
- 全链路 SLS 日志审计

NAS/OSS 文件系统

- 静态角色描述文件 (SOUL.md)
- 每日记忆文件 + Skills 文件
- 记忆可编辑 / 抽取 / 复用
- 快速上传导入多种 Skills

02 Agent Infra 的 核心挑战与设计原则

从开发者痛点到 Harness Engineering 最佳实践

Harness 设计原则：信息层 —— 精准比求全更重要

Trick 1: 渐进式披露

把信息做成分层加载系统

Level 1: CLAUDE.md — 元规则入口

Level 2: SKILL.md — 按需调用能力包

Level 3: 参考文件/脚本 — 完成任务的细节

Trick 2: Tools 越少而精越好

Agent 的强大不在于工具箱里有多少把扳手

Claude Code 约 20 个工具，仍在审视是否需要

Vercel 精简工具后速度和可靠性显著提升

Trick 3: Context Window 甜蜜区间

上下文利用率超过阈值后性能开始下降

Opus 4.6 长上下文维持七成检索命中率

顶级工程师保持 context 利用率在 60% 以下

Trick 4: Subagent 做 Context 隔离

复杂任务分配给独立 subagent

每个 subagent 在更小更干净的 context 中

主线程只做调度和收口 (Context Firewall)



Harness 设计原则：执行层与反馈层

执行层：给 Agent 一套执行规划

Research → Plan → Execute → Verify

每个阶段单独 session，单独 context

"Enter plan mode for ANY non-trivial task"

"If something goes sideways, STOP and re-plan immediately — don't keep pushing."

—— Claude Code 负责人 Boris Cherny

人最该介入的地方：事前规划而非事后审核

一行糟糕的计划，长出几百行糟糕的代码

反馈层：Agent 的复利飞轮

"Anytime you find an agent makes a mistake, you take the time to engineer a solution such that the agent never makes that mistake again."

—— Mitchell Hashimoto

构建反馈闭环：

- 有效验证手段使产出质量提升 2-3 倍
- 自动迭代模式：做→验→不过→继续
- 每次失败都让系统永久变好

Autoresearch 闭环思路：

提出 idea → 实验 → 观察 → 保留/丢弃 → 循环

Multi-Agent 协同: 从 Vibe Coding 到 Coordination Engineering

Agent 层级与 组织架构

- 放弃"一台机器"上持续聊天模式
- 角色划分: Dev / Architect / Memory Keeper
- Ground Rules 注入所有 Agent

Harness Engineering 基础设施需求

- Sandbox: 安全隔离执行环境
- Team Memory: 团队记忆系统
- Agent Dropbox: 协作文件共享
- Agent 邮箱: 独立通信系统
- CI/CD: 完整回归测试环境

从 L1 到 L4 的演进

- L1 Prompt Engineering
- L2 Context Engineering
- L3 Harness Engineering
- L4 Coordination Engineering
- 最终: Intention Engineering

06

未来展望 与总结

AI Agent Infra 的下一步



AI Agent 基础设施的未来趋势

从 Harness 到 Coordination

L1 问答质量 → L2 认知边界 → L3 执行闭环 → L4 组织协同

Multi-Agent Networks 成为下一代产品形态

类似"Agent 协作版飞书": 监工看板 + 协作 IM 平台

Agent 原生存储与数据范式

文件系统 + SQL 的融合 (Agent-Native Storage)

Agent 需要的不只是数据库, 而是"理解一切"的存储平台

支持百亿级 Agent 租户的存储云平台

模型与 Harness 深度耦合

模型公司端到端做 Harness, 应用公司也开始训模型

Continuous Learning: 基于自己的 Harness 和业务数据做开源模型 RL

"每行代码的保质期可能只有 2 个月"

企业级 Agent 基础设施平台

Serverless + 安全隔离 + 开源开放 + 全链路可观测

无代码到高代码平滑演进, CI/CD 天然集成

阿里云 AgentRun: 做企业级 Agent 的最佳运行底座

总结: AI Agent 基础设施的核心要点

行业趋势

- AI 工程方法持续演进: Prompt → Context → Harness Engineering
- 核心竞争力转向系统层: Harness = 环境 + 工具 + 记忆 + 评估
- Multi-Agent 协同从实验走向生产, 需要完善基础设施

AgentRun 的答案

- Serverless 基础设施: 零运维、极致弹性、0 到百万级并发
- 企业级 Runtime: 高性能 Sandbox、会话亲和/隔离、动态存储挂载
- 开源开放: 兼容主流框架、数据不出域、平滑演进
- 全链路可观测: Agent 不再是黑盒, 数据飞轮持续提升效果

一句话总结

大模型正在重新定义软件 —— AgentRun 让企业级 Agent 跑得更快、更稳、更安全。

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The Software



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

