

QCon
全球软件开发大会

Ming-flash-omni: 全模态统一大模型的关键技术与实践

郭清沛

蚂蚁集团百灵多模态基础模型技术负责人



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人


AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

多模态大模型发展趋势：更多模态、理解生成一体化



应用需求和技术发展将推动多模态模型走向全模态理解和生成统一架构

从应用上看

- 未来超级入口的需要，人的自然交互形式是“认知”（理解）与“表达”（生成）的闭环，全模态的交互是人类感知物理世界的主要方式(除触觉外)。


从技术上看，统一的目标是“协同”

全模态统一大模型：

- 模态统一：音、视、图、文 模态协同理解；
- 任务统一：理解和生成任务协同


全模态统一大模型相关概念和定义

原生多模态、全模态大模型、理解与生成统一、全模态统一大模型




构建全模态统一大模型的核心挑战



挑战 1: 模态统一 (基于统一架构 实现全模态协同理解)



挑战 2: 任务统一 (基于统一架构实现理解任务与生成任务的协同)



挑战 3: 数据异构性和模型异构性: 缩小全模态大模型和LLM MFU gap, 提升全模态训练效率



全模态统一大模型的每一项核心技术突破, 都将引发行业范式的深层变革

- **模态统一—原生多模态技术突破:** 视觉感知成为LLM的标配, 消除语言模型与多模态模型之间的界限;
- **任务统一—统一表征范式的突破:** 终结理解与生成的长期割裂, 实现全模态能力的真正合一

Ming-flash-omni 全模态统一大模型的解决方案

挑战 1: 模态统一 (基于统一架构 实现全模态协同理解)

A1: 桥接式方案

(基于现有LLM进行功能拓展)

多模态输入

↓
特定编码器

↓
适配器/连接器

↓
冻结的大语言模型

A2: 原生统一方案

(从底层构建统一表征架构)

Pretrained
LLM

+

模态扩充

↓
模态扩充 during LLM Pretraining

跨模态融合架构 + 全模态协同训练

范式迁移

基础问题

Ming-flash-omni 全模态统一大模型的解决方案

挑战 1: 模态统一 (基于统一架构 实现全模态协同理解)

A1: 桥接式方案

(基于现有LLM进行功能拓展)

多模态输入

↓
特定编码器

↓
适配器/连接器

↓
冻结的大语言模型

A2: 原生统一方案

(从底层构建统一表征架构)

Pretrained
LLM

+

模态扩充

↓
模态扩充 during LLM Pretraining


跨模态融合架构 + 全模态协同训练

范式迁移

基础问题


Ming-flash-omni模态统一：跨模态融合架构

基于MoE的跨模态融合架构：音、视、图、文协同训练



效果对比: Multirouter v.s Single Router

Router	MMStar	OCRBench	MMMU	AI2D	MMB	Avg	Avg
图文单独	48.21	57.9	42.22	69.95	71.21	57.89	
单独audio							5.61
baseline	46.49	53.3	42.56	68.2	68.47	55.804	5.57
Multi-Router	45.74	57.7	45.22	69.69	70.618	57.79	5.05



AnyExperts[2]: 按需激活，每个token重要度不同,何必强制统一K?




[1] Jing, L., Gao, Y., Wang, Z., Y., Wang, W., ... & Guo, Q. (2025). EvoMoE: Expert Evolution in Mixture of Experts for Multimodal Large Language Models. AAAI 2026

[2] Gao, Y., Lan, W., Zhao, H., Liu, S., & Guo, Q. (2025). AnyExperts: On-Demand Expert Allocation for Multimodal Language Models with Mixture of Expert, CVPR 2026


Ming-flash-omni模态统一：跨模态融合架构

基于MoE的跨模态融合架构：音、视、图、文协同训练

AnyExperts[1]: 按需激活，每个token重要度不同,何必强制统一K?



效果对比:
TopK v.s
AnyExperts



可视化
重要token

[1] Gao, Y., Lan, W., Zhao, H., Liu, S., & Guo, Q. (2025). AnyExperts: On-Demand Expert Allocation for Multimodal Language Models with Mixture of Expert, CVPR 2026

Ming-flash-omni 全模态统一大模型的解决方案

挑战 1: 模态统一 (基于统一架构 实现全模态协同理解)

A1: 桥接式方案

(基于现有LLM进行功能拓展)

多模态输入

↓
特定编码器

↓
适配器/连接器

↓
冻结的大语言模型

A2: 原生统一方案

(从底层构建统一表征架构)

Pretrained LLM

+

模态扩充

↓
模态扩充 during LLM Pretraining

跨模态融合架构 + 全模态协同训练

范式迁移

基础问题




Ming-flash-omni模态统一：音、视、图、文模态协同训练

全模态协同训练[1]




数据配比/训练阶段规划

- 各模态的数据量不同
- 任务复杂度不同，收敛速度不一致



+

MultiModal Multi-Task Balanced Training Strategy



[1] Guo, Q., Song, K., Feng, Z., Ma, Q., Gao, S., ... & Zhou, J. (2025). M2-omni: Advancing omni-mllm for comprehensive modality support with competitive performance.

Ming-flash-omni 全模态统一大模型的解决方案

挑战 1: 模态统一 (基于统一架构 实现全模态协同理解)

A1: 桥接式方案


(基于现有LLM进行功能拓展)

多模态输入

↓
特定编码器

↓
适配器/连接器

↓
冻结的大语言模型




A2: 原生统一方案

(从底层构建统一表征架构)

Pretrained LLM

+

模态扩充



模态扩充 during LLM Pretraining

跨模态融合架构 + 全模态协同训练

范式迁移

基础问题

模态统一训练范式迁移: 原生统一方案



早期多模态融合（即使在较低视觉 Token 比例下）能让模型更自然地学习平衡的表示，从而获得最佳的全模态性能。
[1]

[1] Team, K., Bai, T., Bai, Y., Bao, Y., Cai, S. H., Cao, Y., ... & Shang, Z. (2026). Kimi K2. 5: Visual Agentic Intelligence.

构建全模态统一大模型的核心挑战

挑战 1: 模态统一 (基于统一架构 实现全模态协同理解)

A1: 桥接式方案 (基于现有LLM进行功能拓展)

多模态输入
↓
特定编码器
↓
适配器/连接器
↓
冻结的大语言模型



A2: 原生统一方案 (从底层构建统一表征架构)

Pretrained LLM + 模态扩充
↓
模态扩充 during LLM Pretraining

跨模态融合架构 + 全模态协同训练

挑战 2: 任务统一 (基于统一架构实现理解任务与生成任务的协同)

B1: 模型级统一 (通过共享骨干网络支持多任务)

统一多模态骨干网
↓
[理解 Head] [生成 Head]
↓ ↓
文本 像素/Token




B2: 表征级统一 (建模统一的潜空间表征)

输入数据
↓
共享潜空间表征
(Unified Shared Space)
↓
理解与生成协同建模

挑战 3: 数据异构性和 模型异构性: 缩小全模态大模型 和 LLM MFU gap, 提升全模态训练效率


数据异构性

(张量形状差异大、负载不均、显存碎片化)



模型异构性


(模态编码器计算不均、严重流水线气泡)




Ming-flash-omni 全模态统一大模型的解决方案

挑战 2：任务统一 (实现理解任务与生成任务的协同)

B1: 模型级统一
(通过共享骨干网络支持多任务)



B2: 表征级统一
(建模统一的潜空间表征)




目标：基于统一架构实现理解与生成任务协同

Ming-flash-omni：全模态理解和图像/语音生成任务统一


分阶段训练：全模态理解侧训练+ 生成侧训练

1) 集成生成任务同时，保持理解效果 2) 实现理解能力促进生成

图像生成[1]: Meta-X架构，根据Context提取图像 输出生成控制条件



语音合成[2]: thinker-talker架构，先思考(输出文本)，再表达(合成语音)



[1] AI, I., Gong, B., Zou, C., Zheng, D., Yu, H., Chen, J., ... & Huang, Z. (2025). Ming-lite-uni: Advancements in unified architecture for natural multimodal interaction.

[2] Xu, J., Guo, Z., He, J., Hu, H., He, T., Bai, S., ... & Lin, J. (2025). Qwen2.5-omni technical report.



Ming-flash-omni：图像理解和生成任务统一存在的问题

Ming-flash-omni 基于Meta-Query方案的图像生成 获取的是高层语义，缺乏细粒度、结构及文字信息：



图像生成和编辑任务

细粒度视觉知识（属性、空间关系）无法有效传递至生成端。

缺乏端细粒度感知



图像编辑任务

缺乏 参考图 结构化信息，ID难保持

缺乏ID保持及参考图结构理解能力



文字生成

语义 -> 文字
缺乏低层特征

缺乏高保真文字生成能力



Ming-flash-omni：图像理解和生成任务统一解决方案

图像生成和编辑任务

细粒度视觉知识（属性、空间关系）无法有效传递至生成端。

缺乏端细粒度感知



核心思路

构造理解和生成的统一目标，
提升生成侧细粒度感知能力

解决方案

一种理解和生成的统一表达：生成式分割 即 编辑



精确编辑依赖
精确感知

准确编辑物体，必须先精确感知其边界——感知成为生成的前提条件。



编辑质量提供理
解监督信号

生成质量直接反映理解精度，两者优化目标自然统一。




获得精细空间
语义控制

有效解决文本到图像生成中的组合性难题。

Ming-flash-omni：图像生成和理解任务的协同

一种理解和生成的统一表达：生成式分割 即 编辑，分割任务 -> 图着色任务(图像编辑任务)




指代分割任务

图像编辑任务

Type	Model	RefCOCO (val)↑	RefCOCO+ (val)↑	RefCOCOg (val)↑
Vision.	VLT	67.5	56.3	55.0
	CRIS	70.5	62.3	59.9
	LAVT	72.7	62.1	61.2
	PolyFormer-B	74.8	67.6	67.8
SAM.	LISA-7B	74.1	62.4	66.4
	PixelLM-7B	73.0	66.3	69.3
	OMG-LLAVA	75.6	65.6	70.7
Uni.	Nano-banana*	15.7	13.9	14.9
	Qwen-Image-Edit*	30.3	28.8	34.0
	Ming-Flash-Omni	72.1	65.2	65.4

Type	Model	GEdit-Bench-EN (Full set)↑			GEdit-Bench-CN (Full set)↑		
		G_SC	G_PQ	G_O	G_SC	G_PQ	G_O
Edit.	Instruct-Pix2Pix	3.58	5.49	3.68	-	-	-
	AnyEdit	3.18	5.82	3.21	-	-	-
	MagicBrush	4.68	5.66	4.52	-	-	-
	Step1X-Edit	7.09	6.76	6.70	7.20	6.87	6.86
	Qwen-Image-Edit	8.00	7.86	7.56	7.82	7.79	7.52
	Z-Image-Edit	8.11	7.72	7.57	8.03	7.80	7.54
	UniWorld-v1	4.93	7.43	4.85	-	-	-
Generalist.	OmniGen	5.96	5.89	5.06	-	-	-
	OmniGen2	7.16	6.77	6.41	-	-	-
	BAGEL	7.26	6.82	6.52	7.24	6.85	6.50
	Ming-Flash-Omni	8.11	7.87	7.64	8.02	7.95	7.62



Ming-flash-omni：图像理解和生成任务统一解决方案



图像编辑任务

缺乏 参考图 结构化信息，ID难保持

缺乏ID保持及参考图结构理解能力



文字生成

语义 -> 文字
缺乏底层特征

缺乏高保真文字生成能力

解决方案



ID保持：双信息流设计

1

结构级信息流

参考图像 → VAE编码 → 与噪声潜变量拼接 → 自注意力增强参考图结构和身份一致性



2

语义级信息流

参考图像 → 可学习查询 token → 全局语义编码 → 提升编辑内容保真度与准确性

高保真文字生成：Glyph-ByT5路径



Prompt提取
从用户Prompt提取文字内容



Glyph特征
生成字形特征表示

像素渲染
生成像素级精确文字


ByT5编码
进行字节级编码表示

条件融合
与可学习查询token结合输入

Ming-flash-omni：语音理解和生成任务统一解决方案



Large Language Model



基于**连续自回归的极简架构**，实现在**一句话音色克隆**中，对于方言、情绪、语速、语调、音量的**细粒度控制**，并且支持长播客生成，实现数学、化学公式的正确朗读

方言控制

- 只需提供任意**一句话即可克隆音色**，说出地道的粤语和四川话
- 在 WSYue-TTS-Eval 和 WSC-TTS-Eval 上的**粤语和四川话**生成**准确率 96% 和 86%**

情感控制

- 一句话音色可控支持通过指令来控制音频的喜怒哀乐
- 在 CV3-Eval Emotional 上的**平均 acc 为 78%**，高于 CosyVoice3；
- 中性情感prompt**音频生成带情感的音频效果突出

音色设计

- 支持**自然语言定义音色**
- 内置 **100+ 精品音色**、以及经典角色音色，无需 prompt 音频，直接获得音色矩阵

Put it all together: Ming系列能看、能听、能说、能画的全能AI

首个模态支持上全面对标GPT4o的开源模型:输入音频、视频、图片、文本,输出文本、图片、语音



Ming-lite-omni v1.5 Ming-lite-omni Qwen2.5-Omni Qwen2.5-VL
MetaQuery-XL Janus-Pro 7B Kimi-Audio

Image Editing



Make the sheep wear tiny glasses

Image Generation



A photo of a toaster

A photo of a cake

Image Style Transfer



Kawaii

Audio Generation

SEED-TTS-zh-ver

SEED-TTS-en-ver

Audio Understanding



粤语: 麻烦介绍一下杭州



杭州有着悠久的历史, 如西湖、灵隐寺、雷峰塔等著名景点

Audio Chat




粤语: 麻烦介绍一下杭州



杭州有着悠久的历史, 如西湖、灵隐寺、雷峰塔等著名景点


Audio Chat

Video Chat



Q: 请描述视频内容

A: 视频中一位女性正在做瑜伽



Visual Grounding



Q: Where is the Shih Tzu in the image?
Answer in [x0, y0, x1, y1] format.

A: [0, 608, 100, 923]

GUI Understanding



Q: In the given image, could you find and tell me the coordinates of search bar?

A: click(x=0.384, y=0.082)


OCR



日期: 2016-12-01
18:14
机号: 039单号:
000056
收银员: 0121
货号 数量 单价 金额
味全每日C胡萝卜蔬果
原汁300ml
146838 16.00 6.00

Put it all together: Ming系列能看、能听、能说、能画的全能AI

首个模态支持上全面对标GPT4o的开源模型:输入音频、视频、图片、文本,输出文本、图片、语音



Model Scaling?
是否随着模型尺寸增大,全模态
理解和生成效果提升?



- GitHub: <https://github.com/inclusionAI/Ming>
- Hugging Face: <https://huggingface.co/inclusionAI/Ming-flash-omni-2.0>
- ModelScope: <https://www.modelscope.cn/models/inclusionAI/Ming-flash-omni-2.0>

首个千亿参数规模的开源全模态统一大模型




* GLM4.5v [♦ Step2-Audio](#) [♦ Cosyvoice3](#) [♥ Qwen-Image](#) [♦ Qwen-Image-RL](#) [♦ Qwen-Image-Edit](#)
Metrics marked with an underline are not in the original technical report; they were obtained by us via public API or local deployment.


Ming-flash-omni 全模态统一大模型的解决方案

挑战 2：任务统一 (实现理解任务与生成任务的协同)

B1: 模型级统一
(通过共享骨干网络支持多任务)



B2: 表征级统一
(建模统一的潜空间表征)




目标：基于统一架构实现理解与生成任务协同




任务统一：Ming在统一模态表征的探索


MingTok[1]



MingTok-Audio[2]



语音和图像可以使用相同的
泛式实现统一表征：



- 用连续表征对理解和生成任务效果最好
- Latent 低维表征做自回归输出
- Semantic高维表征做自回归输入

[1] Huang, Z., Zheng, D.,... & Zhou, J. (2025). Ming-UniVision: Joint Image Understanding and Generation with a Unified Continuous Tokenizer.
[2] Yan, C., Jin, H., ... & Huang, Z. (2025). Ming-UniAudio: Speech LLM for Joint Understanding, Generation and Editing with Unified Representation.

构建全模态统一大模型的核心挑战

挑战 1: 模态统一 (基于统一架构 实现全模态协同理解)

A1: 桥接式方案 (基于现有LLM进行功能拓展)

多模态输入
↓
特定编码器
↓
适配器/连接器
↓
冻结的大语言模型

A2: 原生统一方案 (从底层构建统一表征架构)

Pretrained LLM + 模态扩充
↓
模态扩充 during LLM Pretraining

跨模态融合架构 + 全模态协同训练

挑战 2: 任务统一 (基于统一架构实现理解任务与生成任务的协同)

B1: 模型级统一 (通过共享骨干网络支持多任务)

统一多模态骨干网
↓
[理解 Head] [生成 Head]
↓
文本 像素/Token


B2: 表征级统一 (建模统一的潜空间表征)

输入数据
↓
共享潜空间表征
(Unified Shared Space)
↓
理解与生成协同建模

挑战 3: 数据异构性和 模型异构性: 缩小全模态大模型 和 LLM MFU gap, 提升全模态训练效率


数据异构性

(张量形状差异大、负载不均、显存碎片化)




模型异构性

(模态编码器计算不均、严重流水线气泡)




Ming-flash-omni : 训练优化-数据异构/模型异构

(a) Baseline Megatron-LM (Unoptimized)




Model Heterogeneity Issue

Modality-Specific Pipeline Layout




(b) Ming-flash-omni (Our Optimized Infrastructure)


Solution 1: Sequence Packing



Solution 2: Flexible Parallelization




Solution 3: Custom Kernel Optimization



Input Data: Encoders: Encoders: Decoders: Computation: Solid --> Communication Overlap:



Ming-flash-omni : 训练优化-数据异构/模型异构






针对非对称架构带来的流水线气泡，采用灵活并行策略（Flexible Parallelization）独立配置组件参数，实现端到端训练效率69.7%提升。



百灵Ming系列开源后在社区受到了广泛关注

多模态大模型Ming-Omni 开源的多个版本在huggingface同类模型趋势榜单(any to any)位列榜首，并入选huggingface热点论文榜。





Ming-flash-omni : 语音合成能力展示


基于构造高质量方言生成数据集构建，
通过文本指令来生成地道的方言

跨语种方言生成



基于高质量audio caption指令数据，实现多样化的音色设计能力，从方言到情感、到角色，细粒度打造目标音色

情感风格音色设计



方言音色设计




Ming-flash-omni Skill: 让 OpenClaw能看、能听、能说、会画



体验升维，具备活人味的
专属数字管家


One Skill is ALL you
need





Ming-flash-omni 应用：给 OpenClaw 装上眼耳嘴和身体

Ming-Omni API





Ming-flash-omni 应用：给 Claude code / OpenClaw 装上眼耳鼻和身体



THANKS

统一全模态，不只是“把模态放在一起”
而是让架构、算法、训练、工程一起闭环

蚂蚁百灵 Ming 系列全模态模型



AiCon

全球人工智能开发与应用大会

上海站

探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

