

淘宝闪购AI 驱动 UI 自动化提效实践

项泳彪 | 资深测试开发专家



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

🕒 6月 📍 上海

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：6月26-27日

- AI Infra 系统工程
- 多 Agent 协作与实践
- 多模态融合
- 模型训练与推理创新
- 数据平台与特征服务

🕒 8月 📍 深圳

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：8月21-22日

- Agentic AI
- 轻量化与高效推理
- 多模态应用
- AI + IoT 场景实践
- AI 工业化落地

🕒 10月 📍 上海

👥 1200人

QCon

全球软件开发大会

会议时间：10月22-24日

- AI Agent
- Vibe Coding
- 智能可观测
- 推理基建
- 模型攻防
- AI x 创造力

🕒 12月 📍 北京

👥 1000人

AiCon

全球人工智能开发与应用大会

会议时间：12月18-19日

- 大模型架构创新
- 多模态 AI 产业融合
- 具身智能
- AI for Science
- 大模型安全

目录

- 01 传统UI自动化困境
- 02 AI+UI自动化业界方案调研
- 03 淘宝闪购AIUI自动化方案
- 04 AIUI平台技术实现
- 05 落地效果及创新用法尝试
- 06 一点思考

01

传统UI自动化困境

传统UI自动化局限性

传统UI自动化测试主要依赖于 **元素定位** 和 **脚本编写** 来实现自动化测试。在一些简单、稳定的业务场景中表现良好，但在面对以下挑战时显得力不从心



随着产品迭代速度加快，UI 界面变化较频繁，传统的 UI 自动化测试高度依赖元素定位，需要持续投入大量时间和精力来维护和更新脚本，实际的落地运用效果不尽如人意

产品 UI 变更频繁



不同平台（如 Web、H5、iOS、Android 等）的 UI 自动化框架存在差异，即使产品在不同平台上的操作相差无几，传统的自动化测试也需要针对不同平台分别编写和维护脚本，这导致大大增加了测试工作量

跨平台兼容性问题



复杂的 UI 界面和交互元素（如：动态生成的内容、图片中的文字、iframe 框架、画布等），传统的元素定位方法难以准确识别，需要特殊处理，导致测试结果不可靠

复杂界面元素识别



复杂页面的 UI 交互逻辑可能导致自动化脚本冗长、结构混乱，降低了自动化脚本的可读性，同时也增加了后续理解和维护脚本的难度。

可读性和可维护性

02

AI+UI自动化业界方案调研

AI带来新的可能

探索引入基于AI的UI自动化测试方案，通过 AI 视觉理解与自然语言处理能力，动态解析 UI 元素逻辑关系，自动生成可执行的脚本指令
大模型 AI+UI 自动化具有以下几个核心优势：

UI 元素智能识别



利用 AI 视觉技术，智能识别 UI 界面中的各种元素，包括文本、图片、图标等。即使产品界面发生变化，也能快速准确地找到对应的元素，极大提升测试的灵活性和准确性，降低人工维护的成本。

跨平台通用性



基于页面截图进行识别和操作，在不同平台上的自动化脚本编写调试体验一致。针对不同平台的细微 UI 差异，实现一次编写、多平台运行，极大地简化跨平台测试的工作量。

高精度与鲁棒性



AI 视觉技术具有强大的图像处理和模式识别能力，能够处理各种复杂的 UI 场景（如：动态内容、模糊图片等），确保测试结果的高精度和鲁棒性。

可读性和可维护性



基于自然语言描述的自动化脚本，可读性和可维护性较好。

共性 UI 问题检测



定制的 Prompt 提示词，可实现共性 UI 问题的巡检发现。
例如：UI 样式问题诸如白屏、报错、空坑、元素堆叠、异常内容NaN等；页面数据问题诸如：小数点精度。

业界方案1 | OmniParser + Qwen2.5-VL + Playwright



利用 OmniParser 对 **页面元素预识别和标注**，以辅助大模型（Qwen2.5-VL）进行决策，并最终通过 Playwright 执行操作

优势：

- OmniParser 加速大模型对元素的定位速度，在简单场景下识别准确性较高；执行层（Playwright）与识别层（OmniParser+Qwen2.5-VL）解耦，具备较高的灵活性。

局限与挑战：

- **识别精度与鲁棒性**：Omni Parser 在复杂场景下（如下拉筛选、自定义组件）存在元素遗漏、定位偏差、假阳性（不该被打标的被标记）等问题。**调整参数，仍难以完全解决**，影响大模型分析执行的准确性
- **开发成本高**：引入 Omni Parser 需额外开发资源用于图片解析、模型调试，**增加了方案复杂度**
- **大模型决策依赖性**：Qwen2.5-VL 的执行操作准确性高度依赖 OmniParser 的打标质量
- **数据安全问题**：OmniParser 对元素标注时，会调用外部开源模型交互，可能有数据泄露风险



业界方案2|Midscene 框架 + Qwen2.5-VL + Playwright


以 Midscene 作为核心 SDK，集成元素识别与基础操作，并通过 Qwen2.5-VL 提升元素识别能力，最终通过 Playwright 进行底层操作执行

优势

- Midscene 结合 Qwen2.5-VL 在基础场景下元素识别准确性较高
- 集成元素识别与基础操作功能，相较于分离方案，可降低初期开发成本
- 调试交互与可视化报告体验较好

局限与挑战

- **扩展性不足**：Midscene 的元素识别与操作强绑定，导致在处理复杂操作（如拖拽、文件上传）和动态断言方面存在局限，需要大量二次开发才能满足需求
- **能力受限**：Midscene 现有能力较为基础，在执行调度、异常重试、缓存策略及动态元素识别等自动化测试能力方面均显不足，仍需大量定制化开发
- **集成与调试挑战**：Midscene 与 Playwright 的结合，在报告可视化、执行稳定性（单步骤波动性高）和调试效率方面仍需深度优化



03

淘宝闪购AIUI自动化方案

纯视觉方案

淘宝闪购AIUI自动化方案

- 采用 Qwen2.5-VL + 文本描述 识别当前页面，大模型给出要操作的内容和坐标，转化成执行框架动作进行操作的方案
- 设计React 的架构，基于目标多次拆解动作

充分发挥大模型能力



1

直接视觉理解与意图识别 降低元素定位维护成本

大模型的 AI 识别能力远超传统基于 DOM 结构或图像特征的识别方法，能够处理更复杂的 UI 场景，如动态内容、图片中的文字、乃至模糊图像等，从而保障测试结果的**高精度与鲁棒性**
模型效果**不依赖算法识别元素的质量**

实现高度的灵活性与解耦



2

Qwen2.5-VL 专注于“思考”（理解用户意图、识别目标、给出坐标），执行框架专注于“执行”，**分层优化内部模型，无数据风险**


满足跨平台与高精度要求



3

Qwen2.5-VL 直接处理页面截图，天生具备**跨平台通用性**，“一次编写，多平台运行”

技术架构



- 一套能力，同时支持PC/APP，产品体验保持一致
- 自然语言形态用例
- AGENT纯视觉理解、意图拆解和执行分离的方式
- AIAGENT层更重、执行框架更轻，用户无需感知


04

AIUI平台技术实现

各模块方案

技术架构|用例平台

实时交互



PC端:


本地浏览器嵌入ChromeDevtool调试器前端->远程playwright headless浏览器暴露debug端口->WebSocket实时通信、实时渲染

- Websocket特殊情况下断连，无感自动重试

APP端:

DevicePlayer组件集成，前端实时租用设备、预览云端手机屏幕

技术架构|用例平台



产品页面、用例编写调试区、模型执行过程展示区


- 集成浏览器渲染执行环境、动态执行过程可视化
- 支持通过鼠标、键盘与嵌入式浏览器实例进行双向交互
- 执行环境隔离性
- 毫秒级的渲染状态更新与输入反馈延迟

技术架构|用例平台

单步调试

单步骤/多步骤调试，降低用例脚本修改及调试成本

单步调试完成后实时预览步骤的执行过程和执行结果，辅助定位失败原因





技术架构|用例平台



用例编写提效

打通服务端接口/端到端自动化平台，提升用例编写便捷性，让AIUI更灵活

- 后端数据校验工具，一套AIUI自动化同时覆盖前后端校验
- 上下文打通：后端自动化执行结果支持应用于后续步骤

前后置通用步骤组件化打包，多用例引用

- eg:同一个测试用例但测试数据不同




```
1 点击我知道了，点击快速录菜
2 [[e2eTool:...,params:{"flowId":"...", "env":"t
3 [[e2eTool:...,params:{"flowId":"...", "env":"t
4 在商品名称中输入${yourName}
5 校验页面是否存在${yourName_tmp}
6
```

这里需要以别名区分



用例平台|浏览器插件



- 配套 Chrome 浏览器插件，在本机快速对被测页面进行用例步骤的单步或多步调试，AI测试融入用户工作现场
- 完成调试后，一键把用例步骤同步至用例平台保存

执行调度

支持设置用例的执行顺序、用例&步骤重试次数



动态限流、动态扩缩容，避免高峰期执行堵塞

- 自动感知即将有大量用例执行或存在用例执行等待，无感扩容

- 蓄洪&负载均衡

心跳感知

- 机器重启、服务异常等异常打断执行
- 定期写入心跳监测执行记录是否存活，发现记录无心跳时，从中断步骤恢复执行



执行AIAGENT

Agent统一支持PC、APP端跨平台的自动化用例执行


- 调度层传递设备信息、自定义 Prompt(规划、断言)、用户等
- 意图拆解与执行分离，方便聚焦优化

意图识别：获取执行前截图，结合上下文信息，汇总给大模型，大模型识别用户意图，意图识别结果转换成需执行的坐标和操作类型

AI输出：Next Action（动作）+ coordinate（坐标）+ value（输入value， 可空）； Reasoning（思考过程）

执行：调起执行环境执行具体操作

结果断言：用户断言目标 + 执行前截图、执行后截图，大模型判定



执行AIAGENT


大模型与工程手段、使用方式的配合

- 时间戳替换
- 工程侧兜底：部分VL返回的异常结果（如action预期为type,但错误返回left click）
- 用例编写（指令）技巧，调整描述方式大部分问题能解决

英文标点、断句、日期选择、屏幕滑动%

- 没有用多裁判模型

Other information for you:
The current date and time is: \${Date}
Timestamp: \${Timestamp}



“点击[希望投放时间段]选择框,开始日期选择5月27号,结束日期选择5月29号”




全自主规划AGENT

目标：提升用例编写效率和执行效率，提升用例储备量 & 高效支持新功能测试

舍弃意图拆解和执行分离的方式，采用模型执行过程自主规划，一个指令多步循环

- 调整mcp tool工具参数描述/顺序，增加单步总结参数
- 多步操作后，额外提示模型反思，模型自主决策下一步操作，防止陷入死循环
- 站点地图：控件结构，AI理解xpath
- Token消耗：用例步骤减少、但自主探索花费token增多，整体比步骤化略大



UI自动化执行框架|实例管理

playwright实例

生命周期

每个自动化用例执行前初始化 Playwright 实例，
执行结束后销毁实例释放资源（独占）

实例负载均衡

定制化负载均衡能力，优先级区分实时调试与实验室执行



实例上限

单个Playwright实例对内存占用 300MB至1GB
如果不限制单机上的实例数量，可能会迅速耗尽机器内存或CPU资源

蓄洪

实例数量的动态变化、无感扩容

UI自动化执行框架|动作封装适配

框架层实现所有操作逻辑，UI自动化用例无需AI/人工生成代码

操作动作和 AI Agent 适配以实现对浏览器页面/真机的操作

- agent规划动作范围限定

根据不同actionType执行对应的操作，操作后截图返回结果

ACTION	动作描述
OPEN_APP	打开网页
NAVIGATE	页面跳转
LEFT_CLICK	点击页面坐标
TYPE	输入
CLEAR	清空焦点输入框
MOUSE_MOVE	移动鼠标到坐标
HOVER	移动鼠标并悬浮
SCROLL_DOWN	向下滚动
SCROLL_UP	向上滚动
SCROLL_LEFT	向左滚动
SCROLL_RIGHT	向右滚动
SCREENSHOT	截图
GET_TRACE	获取trace并上传oss
WAIT	等待
REFRESH	刷新
CLOSE	关闭
INPUT	输入
CLICK	点击
RIGHT_CLICK	右键点击
RECORD_VIDEO_START	后台录制视频开始
RECORD_VIDEO_STOP	录制视频结束
DOUBLE_CLICK	双击
LEFT_CLICK_DRAG	拖拽
UPLOAD_FILE	上传文件
PAGE_CLOSE	关闭当前page
GO_BACK	返回上一个页面
CHECK_DEVICE_STATU	维护实例
REINIT_ALL_INSTANCE	重新初始化实例
ENTER_SEARCH	回车搜索
SWIPE	滑动
RETURN_KEY	输入法返回



UI自动化执行框架

典型问题适配

预部署：修改docker文件将chrome插件目录挂载，规避每次部署重新下载chrome

登陆：cookie填充、local storage设置token支持登录

环境隔离：隔离标header填充

上传文件

调试端新开tab：前端监听page变更、感知

network超时未加载

跨环境登录方案:线下主干环境作为中转来（平台线上分组请求线下分组）

Trace上报：playwright执行完成获取trace上报到oss，支持校验


PC

复用totoroAPI，集成蚂蚁sdk、集团手机云sdk执行

统一使用生产服务、无需跨域

APP执行框架

执行报告



Debug 模式、调度或手动执行、插件调试时查看统一报告

设计一套测试执行报告 SDK，按规的数据格式传入数据，即可渲染报告的展示

- 基于过程截图集合生成轮播视频

执行报告

01

用例步骤展示：用例回放中展示所有用例步骤，点击用例执行的任一步骤，可以快速查看执行情况。

02



视频播放模式：支持整个用例或单个步骤播放，同时动态渲染浏览器操作动作

03

大模型交互可观测：支持查看用例步骤中大模型思考过程、思考结果、断言结果、操作前后截图等。

04

浏览器信息：支持回查用例执行过程中，浏览器网络控制台的网络请求及前端 Console 打印内容。



UI样式AI检测

阶段一：PROMPT工程 让AI具备符合淘宝闪购测试规范的UI样式检测知识

不同的问题类别

- 白屏/报错检测准确率高；主观问题（空坑）准确率低
- 类别枚举，案例few shot

prompt调整无效

- 探究模型思考方式

评测集

你是一个UI视觉测试专家，正在一家**公司担任资深UI测试工程师。现在给你若干**APP的截图，请结合**业务相关的业务领域知识，仔细分析以下图片，判断页面是否存在UI内容展示异常，并提供详细说明，重点关注以下三类UI内容展示异常问题：

1. 特殊值显示
 - NaN (Not a Number)
 - undefined
 - null
 - void
 - \n
 - \t
 - 占位符，如\${name}，\${variable}}等
2. 数据类型转换异常
 - 日期格式显示为时间戳
 - 数据精度异常，例如59.9999999没有截断

3. 字符编码问题
 - 乱码（如显示为00000000）
 - HTML实体未解码（如`&`、`&`）
 - Unicode 转义序列未解析（如\u4f60\u597d）
 - UTF-8字符显示异常
 - 特殊字符显示为方块

请针对每个图片进行分析，并严格按照如下格式输出：

```
```json
{
 "issues": [
 ...
],
 "pass": true | false # 是否通过检测，true为通过，false为未通过
}
```

一个例子：

找到这张图片的状态栏、导航栏、标签栏的位置，判断这些组件之间是否存在超过40px的空白



#### 状态栏、导航栏、标签栏的位置

1. 状态栏：
  - 位置：屏幕顶部，显示时间（15:17）、电池电量（50%）、信号强度和Wi-Fi图标。
  - 高度：大约20px（标准状态栏高度）。
2. 导航栏：
  - 位置：状态栏下方，包含返回按钮（<）、分享按钮（三个点）和收藏按钮（圆形图标）。
  - 高度：大约44px（标准导航栏高度）。
3. 标签栏：
  - 位置：页面中部，包含“详情”、“评价”和“搭配”三个标签。
  - 高度：大约44px（标准标签栏高度）。

#### 组件之间的空白

- 状态栏与导航栏之间：
  - 空白距离：0px（状态栏直接位于导航栏上方）。
- 导航栏与标签栏之间：
  - 空白距离：约100px（包括商品标题、价格等信息区域）。
- 标签栏与其他内容之间：
  - 空白距离：约20px（标签栏下方的商品描述和图片区域）。

#### 判断是否存在超过40px的空白

- 状态栏与导航栏之间：不存在超过40px的空白（实际为0px）。
- 导航栏与标签栏之间：存在超过40px的空白（实际约为100px）。
- 标签栏与其他内容之间：不存在超过40px的空白（实际约为20px）。

#### 结论

在这张图片中，导航栏与标签栏之间存在超过40px的空白（实际约为100px），而状态栏与导航栏之间、标签栏与其他内容之间的空白均未超过40px。因此，最终答案是：

存在超过40px的空白，位于导航栏与标签栏之间。

所以，答案是。

```
{
 "thought": "", # 给出你的思考过程
 "issues": [
 {
 "category": str, # 问题类型
 "thought": str, # 描述当前截图存在的问题，然后一步一步描述你的思考。
 "coordinate": [x, y] # 问题页面元素的中心坐标点
 },
 ...
],
 "pass": true | false # 是否通过检测，true为通过，false为未通过
}
```

# UI样式AI检测

## PROMPT工程|问题类别

页面完全空白

"404"、"系统错误"、  
"页面走丢了"、"网络异常"

白屏报错

异常字符"NaN"、  
"undefined"、"null"

商品划线价前缺少  
"¥"符号

价格、百分比等浮  
点数小数点后保留  
超过两位小数

内容异常

多个Toast提示重叠

组件被其他同级组  
件遮挡或溢出屏幕

内容侵入手机状态  
栏区域（顶部显示  
时间、电池等系统  
信息区域）

元素堆叠

多个相同功能的导  
航组件，例如两个  
返回箭头

多个含义相同或相  
近的Toast提示框

重复元素

商品主图空白

豆腐块空白

页面仅存占位骨架  
结构

空坑

吸顶位置没有准确贴  
合顶部

吸顶在滚动时跟随其  
他元素一起移动

吸顶元素与下方元素  
的距离过近

吸顶异常

某按钮点击无效

操作有效性



# UI样式AI检测

## 阶段二： SFT

1. 模型认为加载中的页面属于白屏
2. 模型认为业务逻辑报错也属于页面报错，如无法配送到当前地址
3. 模型无法理解什么是组件溢出到状态栏
4. debug版本的APP存在debug悬浮标，被模型认为是报错或堆叠
5. 模型对于判断小数精度能力表现较差，常认为0.1也属于保留超过2位小数
6. 一些测试店名比较抽象，模型认为属于乱码
- 7.... ..

类别	不通过	总数	通过率
内容异常	31997	399730	92%
白屏/报错	45387	438528	90%
元素堆叠	33101	891586	96%

### 每日人工分析降噪

COT方式提供真实案例给大模型，图片token过大导致大模型注意力涣散)

开启高分辨率参数，解决坐标识别不准问题

优化prompt，坐标点转为bbox框

### SFT尝试

“内容展示异常”类别，SFT后的模型效果显著提升（35.7%到51.8%）

部署资源消耗较多、人工修正样本耗时  
人工梳理图片集、正负样本交织 → 大模型产出图片描述


人工修正

数据湖

模型部署

SFT

# UI样式AI检测|案例





# 页面数据AI巡检

## 使用场景：

检测页面可见数据的正确性

适用于页面数据指标检测、**跨页面**或**跨步骤数据关系**检测等

## 与用例执行AGENT差异：

基于意图识别的动态步骤规划；

Agent基于整体任务的意图识别，不再按换行分步

全局上下文支持校验使用



05

# 落地效果及创新用法尝试

测新、回归、性能、业务巡检

# AIUI自动化使用场景



# AIUI自动化使用效果







# AI自主兼容性测试

## AI自主规划测试目标和路径

- 不用写任何步骤/意图引导
- 明确的路径规划逻辑指导：常规业务功能、操作选择(深度优先/广度优先)、操作路径汇总记录、循环限制、最深路径限制
- 借助图数据库高效遍历路径

步骤详情

第1步 2025-08-28 15:12:32

第2步 2025-08-28 15:13:01

第3步 2025-08-28 15:13:33

第4步 2025-08-28 15:14:31 当前问题图片

第5步 2025-08-28 15:14:50

第6步 2025-08-28 15:15:19

第7步 2025-08-28 15:16:21

第8步 2025-08-28 15:16:47

当前页面深度为0,需要测试各...

已测试过食品安全按钮,接下来...

已测试过食品安全和商品管理,...

当前页面存在报错信息,需要验...

当前页面已经测试过,需要返回...

当前页面深度为1,已测试过营销...

已测试过食品安全、商品管理和...

当前页面深度为1,且已经测试了...



# 跨页面信息一致性AI巡检

传统方式：全链路价格一致性治理实践中，传统问题排查高度依赖人工介入

基于接口日志的复现方案虽能获取部分数据，却难以还原真实用户界面的渲染结果

针对热搜词自动触发端到端的AIUI链路回溯，精准还原用户视角下的完整操作路径(回溯有依据)，AI提取价格等核心信息、比对



配送费表达差异




价格表达差异



# AI助力秒开性能分析

## 不依赖埋点的性能分析



## AI视觉关键帧识别，帧间差异检测 + 内容稳定性判断

帧间差异：SSIM过滤掉相似度高的帧

起始帧：捕捉点击操作后，页面容器首次发生非白屏、非系统转圈的像素突变

结束帧：排除 Banner 轮播、微动特效干扰，判定核心元素（主图、文字、功能位）完全上屏且布局不再跳动

AI判断帧是否是发生变化或渲染完成

成功识别 \*个线上性能问题

### 秒开测试报告

#### 总结

测试时间	页面类型	端	渠道	平均时长(ms)	标准	是否通过
2025年11月7日		Android	ET			未通过

#### 详细数据

ID	页面类型	渠道	机型	执行时间(ms)	开始帧数	开始帧	开始帧下一帧	结束帧数	结束帧	链接
2544	频道	ET	VIVO S5	2980ms	669	<a href="#">图片链接</a>	<a href="#">图片链接</a>	818	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	三星Galaxy Note10	2440ms	583	<a href="#">图片链接</a>	<a href="#">图片链接</a>	705	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	VIVO Y77	2660ms	468	<a href="#">图片链接</a>	<a href="#">图片链接</a>	601	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	华为 nova 8 Pro	2620ms	624	<a href="#">图片链接</a>	<a href="#">图片链接</a>	755	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	荣耀 80	2320ms	530	<a href="#">图片链接</a>	<a href="#">图片链接</a>	646	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	三星 Galaxy S24	N/A	-	无链接	无链接	-	无链接	<a href="#">详情</a>
2544	频道	ET	VIVO Z5	2200ms	481	<a href="#">图片链接</a>	<a href="#">图片链接</a>	591	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	vivo V2279A	2500ms	745	<a href="#">图片链接</a>	<a href="#">图片链接</a>	870	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	VIVO S9	2800ms	493	<a href="#">图片链接</a>	<a href="#">图片链接</a>	633	<a href="#">图片链接</a>	<a href="#">详情</a>
2544	频道	ET	华为 畅享 9 Plus	300ms	580	<a href="#">图片链接</a>	<a href="#">图片链接</a>	595	<a href="#">图片链接</a>	<a href="#">详情</a>

#### 备注

- 1.开始帧：页面开始变化的第一帧
- 2.结束帧：页面完全加载完成的第一帧
- 3.与实际线上统计的性能可能存在500ms（点击响应耗时）左右误差



# 一些踩过的坑

## agent智能化程度Vs成本取舍

纯自主规划智能化程度高、token消耗大

## 安全风险

涉及到写操作业务场景（比如：删除、编辑、上下架等），基于大模型AI的方案可能会导致操作错误（风险较高）



## AI手段Vs工程策略

白屏空坑检测对接OpenCV小模型 + AI大模型

## 效率


大模型耗时长，从其他环节提效

执行：同一设备上连续调试多个用例  
排查：失败归因错误码分析+人工反馈

# 一些踩过的坑

## 安全风险

案例：由于账号权限修改，初始页面A被重定向到首页，用例描述期望修改\*\*价，大模型执行出现幻觉，实际修改了真实\*\*费



- 账号权限：严控账号权限，尽可能使用测试账号而非真实账号、账号权限最小化
- 权限恢复：无法使用测试账号，使用工具在用例执行前收回权限，执行后放开
- 断言丰富：用例中多设置断言，如：当前页面包含预期内容，修改的字段是否符合预期，店铺是否正确
- 场景限制：尽量避免使用AIUI平台运行可能造成线上问题/资损风险的用例，如：修改\*\*费
- 检测：AI检测用例资损风险



# 一些踩过的坑

## APP真机层稳定性

### 前置准备成功率

装包、登录、页面跳转、截图前置准备过程可视化（视频）  
登录逻辑插件化、自维护  
LLM判断是否成功进入APP（AI+OpenCV确认加载全）  
初始弹窗管控、中途弹窗未处理（自主规划）

### 黑屏

登录前和跳转前主动解锁唤醒机器、解锁黑屏  
App未安装或已安装未启动，或启动后被系统回收，执行前强拉起



### 扩机型

公共池+自有设备接入（相对稳定）  
设备预分配  
设别异常（硬件故障、系统卡顿、网络异常）主动重试、切换新设备

### 分辨率

设备分辨率、截图分辨率不同导致点击坐标不准确



# 06 一点思考

取舍、未来方向(进行中)

## 方案选型

- 业界每种方案都存在各自问题和局限性，本质区别体现在对页面信息的获取方案不同（DOM 树/图像/DOM+图像，提取页面部分信息/全量信息），
- 每种方案都有需要解决的技术难点，没有“完美”的方案

## Prompt 提示词Vs SFT

- 高质量Prompt提示词能够解决大部分问题。
- 建议优先尝试优化 Prompt 提示词，相比投入资源进行 SFT ROI更高



## 全流程提效

- 尝试从人写用例->AI执行 到AI全程智能托管测试、AI全权代理
- 测试托管到需求托管

## 大模型幻觉、风险

- 幻觉问题尚无法完全避免
- 对大模型的返回结果增加一层工程兜底机制

# 一点思考

## 全流程提效

目前正在试点用例数字人自主执行、打通AI全托管

- 无需手动编写自然语言描述用例，基于需求AI自主生成
- 完善测试(造数)工具和相关skill、测试经验和用例信息，AI自主执行(MCP)、迭代修复代码BUG
- 工具for人 到 agent/skill for agent的转变
- open Claw, IDE-AGENT等产品形态的变化



# THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The  
Software



# AiCon

全球人工智能开发与应用大会

上海站

## 探索 AI 应用边界

Explore the limits of AI applications

2026 年 6 月 26-27 日 / 上海张江科学会堂



参会咨询

### 专题：世界模型与多模态智能突破

专题出品人：朱政

极佳视界 / 联合创始人 & 首席科学家



### 专题：Agent 系统架构与工程化实践

专题出品人：鲁浩楠

OPPO / 大模型算法负责人



### 专题：AI 原生数据工程

专题出品人：王彦辉

火山引擎 / 数智平台产品总监



### 专题：Agent 安全、评测与可信治理

专题出品人：马传雷（岳立）

支付宝 / 业务风险技术部负责人



### 专题：Agent 数据、记忆与运行时基础设施

专题出品人：邓亚峰

EverMind / CEO



### 专题：企业级研发体系的重构

专题出品人：沈浪

快手 / 研发效能负责人

